ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO

Phân tích các yếu tố ảnh hưởng đến mức độ hài lòng của khán giả đối với phim điện ảnh: Nghiên cứu trên tập dữ liệu MovieLens và TMDB

Giảng viên hướng dẫn: TS. Đỗ Như Tài

Thành viên nhóm:

Nguyễn Vũ Hào - MSSV: 3122410098

Trần Duy Khương - MSSV: 3122410192

Võ Thị Thương - MSSV: 3122410408

Tp.Hồ Chí Minh, 2025

LỜI CẢM ƠN

Chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Đỗ Như Tài, Giảng viên hướng dẫn học phần Phân tích dữ liệu tại Trường Đại học Sài Gòn. Thầy đã tận tình hướng dẫn, truyền đạt những kiến thức quý báu và hỗ trợ chúng em trong suốt quá trình học tập và thực hiện báo cáo này.

Những kiến thức và kinh nghiệm mà thầy chia sẻ, đặc biệt là về Thống kê Mô tả, Trực quan hóa Dữ liệu, và các phương pháp Phân tích Đơn biến/Hai biến, không chỉ giúp nhóm sinh viên chúng em hiểu rõ hơn về các phương pháp phân tích dữ liệu mà còn rèn luyện khả năng xử lý và trình bày dữ liệu một cách khoa học.

Chúng em cũng xin chân thành cảm ơn Quý Thầy/Cô trong Khoa đã tạo điều kiện thuận lợi trong suốt quá trình học tập. Đồng thời, chúng em xin gửi lời cảm ơn đến các bạn cùng lớp đã chia sẻ, trao đổi, và hỗ trợ trong quá trình thực hiện đề tài.

Mặc dù nhóm đã nỗ lực cố gắng hoàn thiện báo cáo một cách tốt nhất, song do kiến thức và kinh nghiệm còn hạn chế, bài báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được những góp ý quý báu từ Thầy để nhóm có thể hoàn thiện hơn trong tương lai.

Chúng em xin chân thành cảm ơn!

MỤC LỤC

LỜI CẢM ƠN 2

MỤC LỤC BẢNG 5

MỤC LỤC HÌNH ẢNH 6

I. Lý do chọn đề tài 8

II. Mục tiêu nghiên cứu 9

III. Câu hỏi nghiên cứu 9

IV. Đối tượng và phạm vi nghiên cứu 10

V. Phạm vi dữ liệu 10

CHƯƠNG 2: CHUẨN BỊ DỮ LIỆU (DATA PREPARATION AND INTEGRATION) 12

I. Mục tiêu 12

II. Kết nối dữ liệu 12

III. Làm sạch dữ liệu 19

CHƯƠNG 3: KHÁM PHÁ DỮ LIỆU (EDA - Exploratory Data Analysis) 22

I. Phân tích biến mục tiêu Rating 24

1. Phân tích đơn biến 24

2. Phân tích hai biến 28

3. Phân tích đa biến 37

CHƯƠNG 4: PHÂN TÍCH CÁC YẾU TỐ ẢNH HƯỞNG ĐẾN RATING 42

I. Yếu tố tài chính (Budget, Revenue) 42

1. Phân tích tương quan 42

2. Trực quan hóa 42

3. Phân cụm K - Means 45

4. Linear Regression theo từng cụm 46

5. Phân tích hệ số, rút ra kết luận và trả lời câu hỏi 51
II. Yếu tố nội dung (Thể loại, Độ dài phim) 53
1. Thể loại 53
2. Thời lượng phim 62
III. Yếu tố nhân sự & thời gian (Cast/Crew, Year) 65
1. Số hóa sức mạnh nhân sự 66
2. Huấn luyện XGBoost Regressor 66
3. Phân tích SHAP 67
4. Vẽ biểu đồ (SHAP Dependence Plots) 67
5. Tầm quan trọng 69
6. Các phân tích liên quan 70
CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ 77
I. Tóm tắt các kết quả nghiên cứu chính 77
II. Hàm ý quản trị 78
III. Hạn chế của đề tài và Hướng phát triển 78

MỤC LỤC BẢNG

Bảng 1 Bảng Users 12
Bảng 2: Bảng Movies 13
Bảng 3: Bảng Ratings 13
Bảng 4: Bảng dữ liệu TMDB Movies 15
Bảng 5: Bảng dữ liệu TMDB Credits 15
Bảng 6: Dữ liệu thống kê sau khi làm sạch 20

MỤC LỤC HÌNH ẢNH

Hình 1: Trang web dữ liệu của Movielens 11
Hình 2: Trang web lấy dữ liệu từ TMDB 11
Hình 3: Dữ liệu sau khi merge của TMDB 16
Hình 4 Dữ liệu sau khi merge của Movielens 17
Hình 5: Dữ liệu sau khi merge của Movielens và TMDB 18
Hình 6 Bảng dữ liệu tổng 19
Hình 7 Biểu đồ top 10 đạo diễn có tổng doanh thu cao nhất 23
Hình 8: Phân bố điểm rating của người dùng MovieLens 24
Hình 9 Kết quả thống kê mô tả 25
Hình 10 Phân bố các biến định lượng 26
Hình 11: Top 10 thể loại phổ biến nhất 27
Hình 12: Mối tương quan giữa các biến số và rating 28
Hình 13: Biểu đồ phân phối điểm số theo Đạo diễn 30
Hình 14: Độ lệch chuẩn điểm số đánh giá 31
Hình 15: Biểu đồ đánh giá rating dựa trên thời lượng phim 32
Hình 16: Phân bố rating theo nhóm tuổi người dùng 33
Hình 17: Phân bố rating theo giới tính 34
Hình 18: Biểu đồ rating trung bình theo thể loại 35
Hình 19: Biểu đồ ảnh hưởng của Ngân sách và Doanh thu đến đánh giá 36
Hình 20: Phân phối và mối quan hệ giữa các biến số 37
Hình 21: Biểu đồ mô tả sự tương tác giữa Popularity, Runtime và Rating 39
Hình 22: Biểu đồ rating trung bình theo thể loại và nhóm ngân sách 40
Hình 23: Biểu đồ trực quan hóa Ngân sách và Doanh thu 42
Hình 24: Phân phối chất lượng phim theo quy mô ngân sách và biểu đồ scatter 44
Hình 25: Biểu đồ phân cụm K-Means của 3 nhóm phim 45
Hình 26: Linear Regression theo từng cụm 47
Hình 27 Biểu đồ residuals của cụm 0 48
Hình 28: Biểu đồ residuals của cụm 1 49

Hình 29: Biểu đồ residuals của cụm 2 50
Hình 30: So sánh hệ số coefficient của 3 cụm 51
Hình 31: Bộ dữ liệu sau khi tách các thể loại 54
Hình 32: Biểu đồ đánh giá trung bình theo Thể loại 55
Hình 33: Điểm trung bình theo thể loại 56
Hình 34: Bộ dữ liệu sau khi tính Weighted_Score 59
Hình 35: Dữ liệu sau khi được train 60
Hình 36: Biểu đồ phân bố Weighted_Score và rating 61
Hình 37: Biểu đồ tương quan giữa runtime và rating 63
Hình 38: Quy trình thực hiện đánh giá dựa trên yếu tố đạo diễn, diễn viên 66
Hình 39: Biểu đồ Phụ thuộc SHAP (SHAP Dependence Plot) 68
Hình 40: Biểu đồ So sánh mức độ ảnh hưởng của Director Power, Actor Power và Release Year 69
Hình 41: Ma trận cộng hưởng: Đạo diễn và diễn viên 71
Hình 42: Kết quả Top 10 bộ phim cho từng loại 73
Hình 43: Biểu đồ Phân tán phân tích Ngoại lệ 73
Hình 44: Ma trận nhầm lẫn: Dự báo sa sút và bứt phá 75
Hình 45: Kết quả dự báo phân loại 75

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

I. Lý do chọn đề tài

Trong bối cảnh ngành công nghiệp điện ảnh phát triển mạnh mẽ, nhu cầu hiểu rõ mức độ hài lòng của khán giả ngày càng trở nên quan trọng đối với các nhà sản xuất phim, nhà phát hành và các nền tảng xem phim trực tuyến. Sự hài lòng của khán giả không chỉ phản ánh chất lượng tác phẩm mà còn quyết định thành công thương mại, mức độ lan tỏa và uy tín của bộ phim trên thị trường. Do đó, việc phân tích các yếu tố ảnh hưởng đến sự hài lòng là cần thiết nhằm giúp các bên liên quan đưa ra chiến lược sản xuất, marketing và phân phối phù hợp.

Bên cạnh đó, sự phát triển của khoa học dữ liệu và kho dữ liệu phim trực tuyến đã tạo ra cơ hội lớn cho nghiên cứu định lượng. Hai tập dữ liệu phổ biến nhất hiện nay là MovieLens và The Movie Database (TMDB), vốn cung cấp thông tin phong phú về đánh giá người xem, đặc điểm phim, thống kê doanh thu, lượt bình chọn và nhiều thuộc tính liên quan. Đây là nguồn dữ liệu mở, có độ tin cậy cao, thường được sử dụng trong nghiên cứu khoa học và trí tuệ nhân tạo.

Tuy nhiên, phần lớn các nghiên cứu trước đây chủ yếu tập trung vào xây dựng hệ thống gợi ý phim hoặc dự đoán xếp hạng, thay vì phân tích sâu các yếu tố ảnh hưởng đến mức độ hài lòng của khán giả. Khoảng trống này cho thấy cần có một nghiên cứu kết hợp dữ liệu từ MovieLens và TMDB để khám phá những yếu tố có tác động lớn đến đánh giá người xem, chẳng hạn như thể loại, độ dài phim, điểm đánh giá trung bình, số lượng bình chọn, năm phát hành, độ phổ biến, hoặc ngân sách sản xuất.

Xuất phát từ những lý do trên, đề tài "Phân tích các yếu tố ảnh hưởng đến mức độ hài lòng của khán giả đối với phim điện ảnh: Nghiên cứu trên tập dữ liệu MovieLens và TMDB" được lựa chọn nhằm: Khai thác và kết hợp hai nguồn dữ liệu lớn để tạo cái nhìn toàn diện hơn về hành vi đánh giá của khán giả, Xác định những yếu tố quan trọng tác động đến mức độ hài lòng, từ đó hỗ trợ nhà sản xuất đưa ra quyết định chiến lược, Góp phần bổ sung khoảng trống trong các nghiên cứu về dữ liệu điện ảnh hiện nay.

Với tính thực tiễn cao và ý nghĩa khoa học rõ rệt, đề tài có khả năng đóng góp giá trị cho lĩnh vực phân tích dữ liệu cũng như ngành công nghiệp phim ảnh.

II. Mục tiêu nghiên cứu

Mục tiêu của nghiên cứu này là xác định và phân tích các yếu tố ảnh hưởng đến mức độ hài lòng của khán giả đối với phim điện ảnh, được thể hiện thông qua điểm đánh giá (rating) trên hai tập dữ liệu MovieLens và TMDB. Thông qua việc kết hợp và xử lý dữ liệu từ hai nguồn này, nghiên cứu hướng đến: Xác định các yếu tố đặc trưng của phim (thể loại, độ dài phim, năm phát hành, độ phổ biến, ngân sách, doanh thu, vote_count, v.v.) có mối quan hệ với mức độ hài lòng của khán giả, Đo lường mức độ ảnh hưởng của từng yếu tố đến điểm đánh giá (vote_average), Đề xuất nhận định và hàm ý giúp nhà sản xuất hoặc nhà phát hành phim cải thiện chất lượng nội dung và chiến lược tiếp cận khán giả dựa trên các yếu tố quan trọng.

III. Câu hỏi nghiên cứu

Để đạt được mục tiêu xác định các yếu tố ảnh hưởng đến mức độ hài lòng của khán giả, nghiên cứu tập trung trả lời các câu hỏi sau:

Những yếu tố nào của phim (thể loại, thời lượng, năm phát hành, độ phổ biến, số lượng bình chọn, ngân sách, doanh thu, v.v.) có ảnh hưởng đến mức độ hài lòng của khán giả?

Rating có phân bố chuẩn không? (normal distribution) Có outliers không? Có imbalance trong categorical variables không?

Biến nào có correlation mạnh với rating? Có non-linear relationships không?

Có interaction effects không? (VD: budget cao + action genre = rating cao)

Ngân sách là "Nhiên liệu" hay "Gánh nặng"?

Ngân sách (Budget) hoặc Doanh thu (Revenue) có mối liên hệ tích cực hay tiêu cực đối với rating trung bình của phim?

Mối quan hệ giữa ngân sách và rating có đồng nhất cho tất cả các bộ phim, hay khác biệt đáng kể giữa các nhóm phim có đặc điểm tài chính - nội dung khác nhau?

Các Thể loại (Genre) phim khác nhau có xu hướng nhận được mức rating trung bình khác nhau đáng kể không? Độ dài phim (Movie length) có ảnh hưởng đến việc người dùng đánh giá cao hay thấp?

Vai trò của Đạo diễn/diễn viên có tên tuổi lớn có tương quan mạnh mẽ với rating người dùng cao hơn không? Năm sản xuất (phim cũ/mới) có ảnh hưởng đến rating trung bình không?

Liệu có thể dự đoán một bộ phim sẽ rơi vào nhóm "sa sút" hay "bứt phá" dựa trên các tiêu chí sẵn có hay không?

IV. Đối tượng và phạm vi nghiên cứu

Đối tượng của nghiên cứu là mức độ hài lòng của khán giả đối với phim điện ảnh, được thể hiện thông qua điểm đánh giá (rating/vote_average) trong các tập dữ liệu MovieLens và TMDB. Đồng thời, nghiên cứu xem xét các đặc trưng của phim (thể loại, thời lượng, năm phát hành, độ phổ biến, số lượng bình chọn, ngân sách, doanh thu, v.v.) nhằm xác định những yếu tố có thể ảnh hưởng đến sự hài lòng này.

Phạm vi dữ liệu: Nghiên cứu sử dụng dữ liệu từ MovieLens (đánh giá của người dùng) và TMDB (thông tin chi tiết về phim), được giới hạn trong tập dữ liệu công khai do hai hệ thống cung cấp.

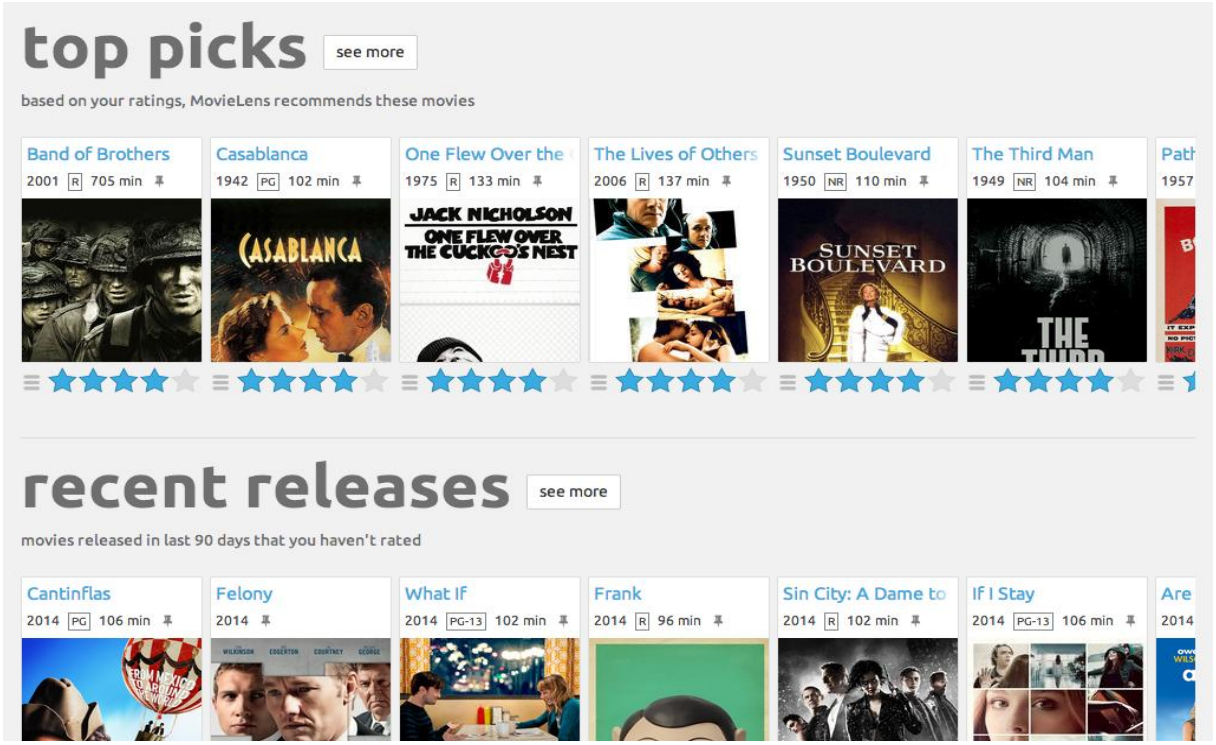
Phạm vi thời gian: Không giới hạn cụ thể về năm phát hành, phụ thuộc vào phạm vi dữ liệu có trong hai tập dataset.

Phạm vi nội dung: Nghiên cứu tập trung vào phân tích định lượng để xác định mối quan hệ giữa các yếu tố đặc trưng của phim và mức độ hài lòng của khán giả; không đi sâu vào phân tích nội dung phim, bối cảnh xã hội hay chất lượng nghệ thuật theo hướng định tính.

Phạm vi địa lý: Không giới hạn quốc gia vì dữ liệu được tổng hợp từ người xem toàn cầu.

V. Phạm vi dữ liệu

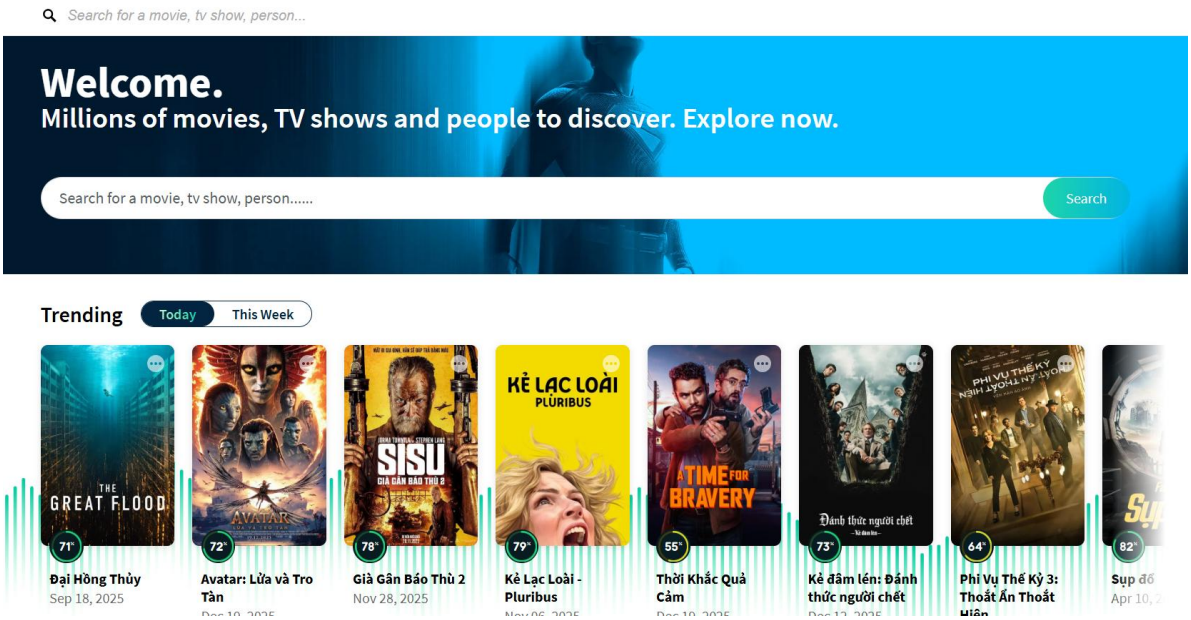
MovieLens 1M Dataset: 1 triệu lượt đánh giá từ ~6000 người dùng và ~4000 bộ phim.



Hình 1: Trang web dữ liệu của Movielens

TMDb 5000 Movies Dataset: Cung cấp thông tin mở rộng về từng phim: ngân sách, doanh thu, runtime, thể loại, popular, keywords, cast, crew, …

Chỉ các bộ phim có khả năng đối sánh tên (title matching) hoặc đối sánh ID giữa hai nguồn mới được đưa vào phân tích.



Hình 2: Trang web lấy dữ liệu từ TMDB

CHƯƠNG 2: CHUẨN BỊ DỮ LIỆU (DATA PREPARATION AND INTEGRATION)

I. Mục tiêu

Phần này mô tả cách dữ liệu từ hai nguồn được chuẩn hóa, làm sạch và kết nối với nhau để phục vụ phân tích.

II. Kết nối dữ liệu

Dữ liệu MovieLens gồm 3 dat:

1. Bảng Users

Cột (Column)	Ý nghĩa
UserID	Mã định danh của người dùng (ID duy nhất).
Gender	Giới tính của người dùng (M/F).
Age	Nhóm tuổi hoặc mã tuổi của người dùng (ví dụ: 1 = dưới 18, 18, 25, 35...).
Occupation	Mã nghề nghiệp của người dùng (một số nguyên biểu diễn từng loại nghề khác nhau).
Zip-code	Mã bưu điện (ZIP) hoặc khu vực mà người dùng sinh sống.

Bảng 1 Bảng Users

2. Bảng Movies

Cột (Column)	Ý nghĩa

MovieID	Mã định danh của người dùng (ID duy nhất).
Title	Tên phim kèm năm phát hành (ví dụ: **Toy Story (1995)**).
Genres	Các thể loại phim, phân tách bằng dấu ` | ` (ví dụ: Animation|Children's|Comedy).

Bảng 2: Bảng Movies

3. Bảng Ratings

Cột (Column)	Ý nghĩa
UserID	ID người dùng đã đánh giá phim.
MovieID	ID của bộ phim được đánh giá.
Rating	Điểm đánh giá do người dùng chấm (thường từ 1 đến 5).
Timestamp	Thời điểm đánh giá (dạng UNIX timestamp - số giây tính từ 1/1/1970).

Bảng 3: Bảng Ratings

Dữ liệu TMDB gồm 2 bảng:

1. Bảng TMDB Movies

Cột (Column)	Ý nghĩa
Budget	Ngân sách sản xuất phim (USD).

Genres	Thể loại phim, lưu dưới dạng chuỗi JSON (Action, Comedy…).
Homepage	Trang web chính thức của bộ phim.
Movie_id	ID phim trong cơ sở dữ liệu TheMovieDB.
Keywords	Các từ khóa mô tả nội dung phim.
Original_language	Ngôn ngữ gốc của phim (ví dụ: `en`, `fr`).
Original_title	Tên gốc của bộ phim.
Overview	Tóm tắt nội dung phim.
Popularity	Mức độ phổ biến của phim trên TMDB.
Production_companies	Danh sách công ty sản xuất phim (JSON string).
Production_countries	Danh sách quốc gia sản xuất phim.
Release_date	Ngày phát hành phim.
Revenue	Doanh thu phòng vé (USD).
Runtime	Thời lượng phim (phút).

Spoken_languages	Danh sách ngôn ngữ được sử dụng trong phim.
Status	Tình trạng phát hành (Released, Post Production…).
Tagline	Slogan/tagline của phim.
Title	Tên phim phát hành chính thức.
Vote_average	Điểm đánh giá trung bình trên TMDB.
Vote_count	Số lượt đánh giá.

Bảng 4: Bảng dữ liệu TMDB Movies

2. Bảng TMDB Credits

Cột (Column)	**Ý nghĩa**
Movie_id	ID phim trong cơ sở dữ liệu TheMovieDB.
Title	Thông tin credit khi merge. Tên tiêu đề của bộ phim đó
Cast	Danh sách diễn viên của phim (JSON string).
Crew	Danh sách nhân sự (đạo diễn, biên kịch…) của phim (JSON string).

Bảng 5: Bảng dữ liệu TMDB Credits

Tiến hành gộp dữ liệu giữa các bảng của 2 bộ dữ liệu Movielens và TMDB.

Đầu tiên, hệ thống gộp hai bảng dữ liệu nguồn của TMDB lại với nhau để có đầy đủ thông tin về phim và diễn viên/đạo diễn.

Dữ liệu đầu vào:

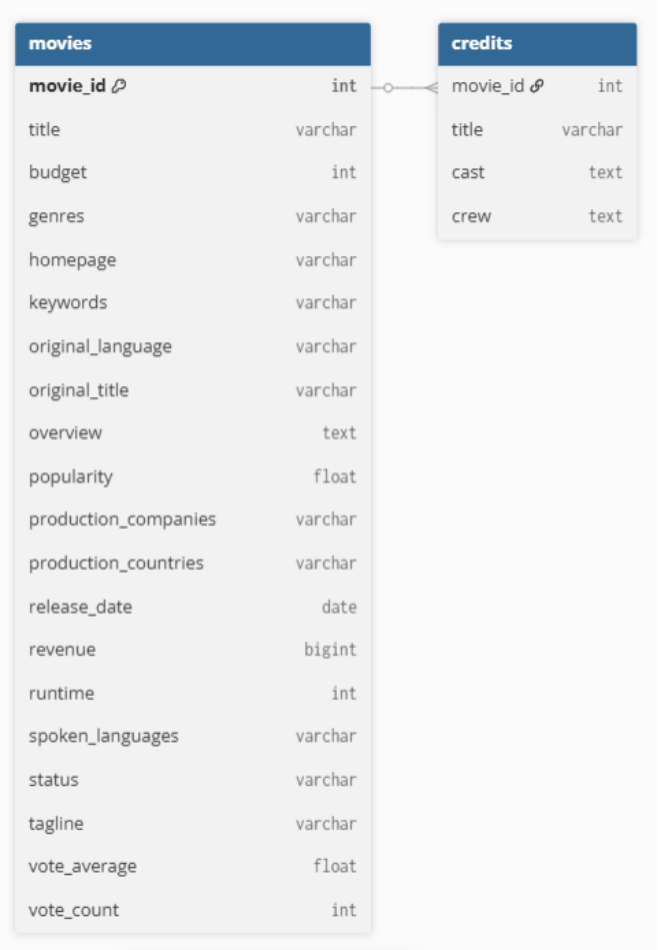
- tmdb_cred: Thông tin diễn viên (cast), đoàn làm phim (crew).
- tmdb_mov: Thông tin tài chính, doanh thu, ngân sách.

Thao tác chuẩn bị:

- Đổi tên cột title trong bảng Credits thành tittle_cr để tránh trùng lặp khi gộp.
- Đổi tên cột id trong bảng Movies thành movie_id để đồng nhất khóa nối.

Khóa nối (Key): movie_id.

Kết quả: Tạo ra bảng tmdb_full chứa tất cả thông tin của TMDB được minh họa tại Hình 3



Hình 3: Dữ liệu sau khi merge của TMDB

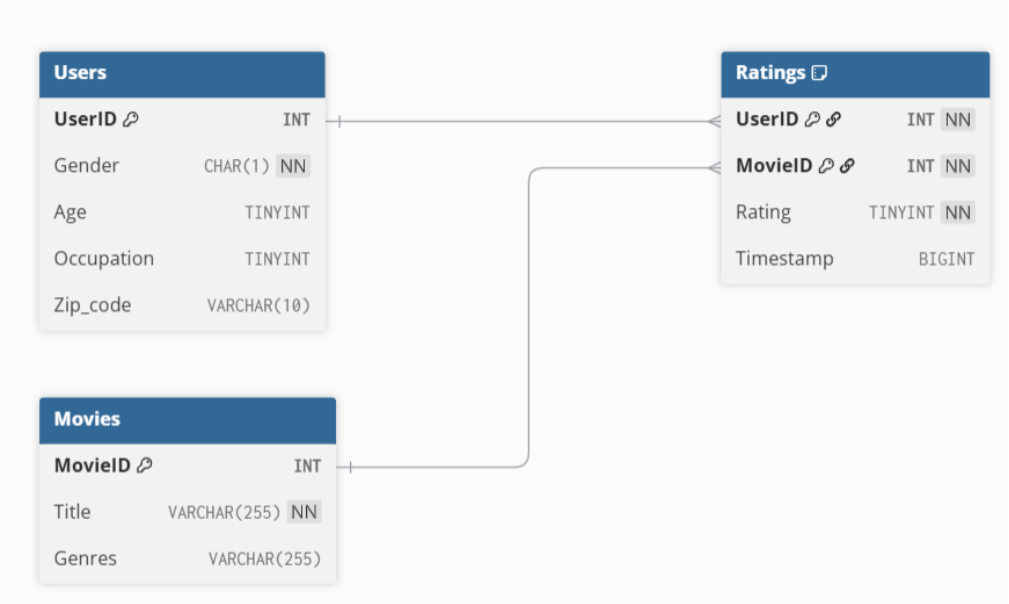
Tiếp theo ta cần nối các bảng của bộ dữ liệu của Movielens. Được thể hiện rõ nhất tại Hình 4.

Do MovieLens và TMDB là hai nguồn dữ liệu khác nhau, chúng không chia sẻ chung một ID (MovieLens dùng MovieID, TMDB dùng movie_id). Do đó, phải nối dựa trên Tên phim (Title).

Thao tác:

- Tạo cột title_join cho bảng movies (MovieLens): Loại bỏ năm phát hành, xóa khoảng trắng thừa, chuyển về chữ thường.
- Tạo cột title_join cho bảng tmdb_full (TMDB): Xử lý tương tự để đảm bảo định dạng văn bản giống hệt nhau.

Mục đích: Đảm bảo khi gộp, phim "Toy Story" bên này sẽ tìm thấy "toy story" bên kia.



Hình 4 Dữ liệu sau khi merge của Movielens

Tiếp tục gộp liên nguồn (MovieLens + TMDB)

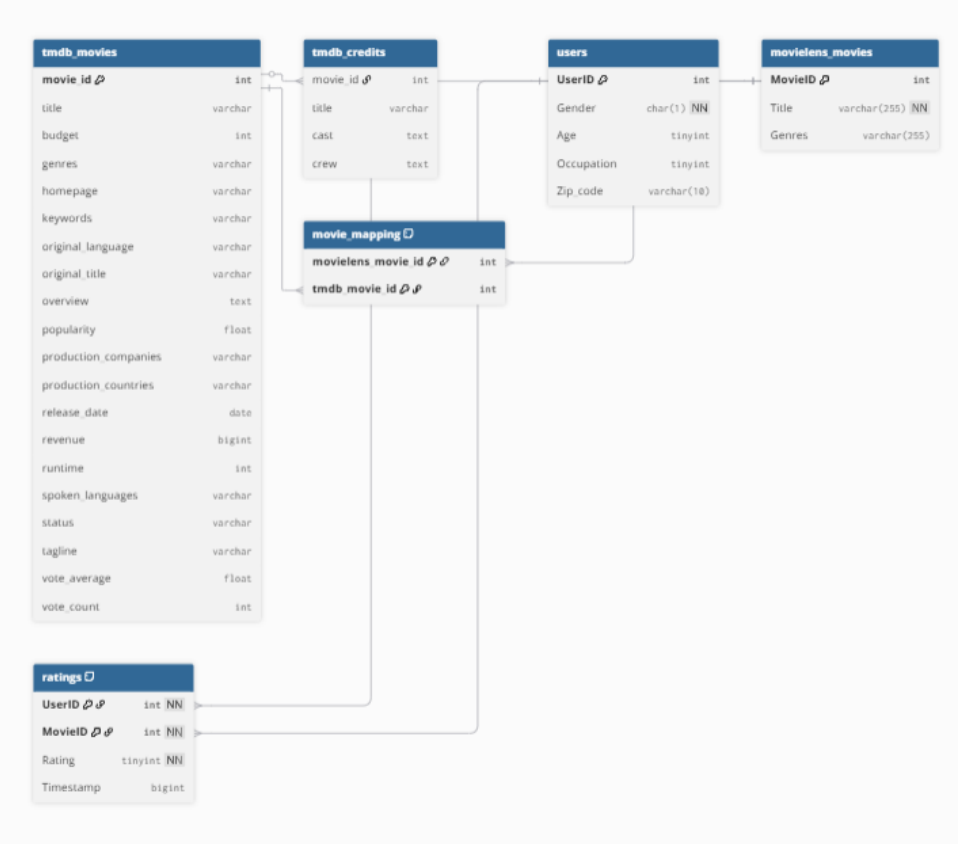
Dữ liệu đầu vào: movies (MovieLens) và tmdb_full (TMDB).

Khóa nối (Key): title_join (đã tạo ở Bước 2).

Phương thức: inner join.

Lưu ý: Chỉ giữ lại những bộ phim xuất hiện ở cả hai cơ sở dữ liệu. Những phim bị lệch tên hoặc không có trong TMDB sẽ bị loại bỏ.

Kết quả: Bảng movies_meta (đang ở dạng thô). Được minh họa tại Hình 5



Hình 5: Dữ liệu sau khi merge của Movielens và TMDB

Sau khi có bảng movies_meta, code thực hiện thêm thông tin thống kê và làm sạch dữ liệu.

Gộp thêm Rating trung bình:

- Nối bảng movies_meta với movie_targets (bảng chứa avg_rating đã tính trước đó).
- Khóa nối: MovieID.
- Lấy năm phát hành (release_year).

Lọc cột: Chỉ giữ lại các cột quan trọng nhất (budget, revenue, director, actors...) tạo thành bảng movies_final_meta.

Cuối cùng, gộp thông tin chi tiết phim vào bảng lịch sử đánh giá của từng người dùng để tạo thành bộ dữ liệu huấn luyện/phân tích cuối cùng.

Dữ liệu đầu vào:

- ratings: Bảng gốc chứa hàng triệu dòng đánh giá (UserID, MovieID, Rating).

- movies_final_meta: Bảng thông tin phim đã làm sạch ở Bước 4.

Khóa nối (Key): MovieID.

Phương thức: inner join.

Kết quả cuối cùng (df_final): Một bảng dữ liệu khổng lồ, trong đó mỗi dòng là một lượt đánh giá của người dùng, kèm theo chi tiết bộ phim đó (ngân sách bao nhiêu, ai đóng, đạo diễn là ai, doanh thu thế nào...). Có thể thấy rõ thông qua Hình 6.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 450575 entries, 0 to 450574
Data columns (total 20 columns):
 #   Column          Non-Null Count   Dtype
---  ------          --------------   -----
 0   UserID          450575 non-null  int64
 1   MovieID         450575 non-null  int64
 2   Rating          450575 non-null  int64
 3   Timestamp       450575 non-null  int64
 4   Title           450575 non-null  object
 5   Genres          450575 non-null  object
 6   release_year    450575 non-null  float64
 7   director        450535 non-null  object
 8   actor_1         450535 non-null  object
 9   actor_2         450535 non-null  object
 10  actor_3         450535 non-null  object
 11  budget          450575 non-null  int64
 12  revenue         450575 non-null  int64
 13  vote_average    450575 non-null  float64
 14  vote_count      450575 non-null  int64
 15  avg_rating      450575 non-null  float64
 16  runtime         450575 non-null  float64
 17  popularity      450575 non-null  float64
 18  director_power  450535 non-null  float64
 19  actor_power     450535 non-null  float64
dtypes: float64(7), int64(7), object(6)
memory usage: 68.8+ MB
```

Hình 6 Bảng dữ liệu tổng

III. Làm sạch dữ liệu

Tiến hành kiểm tra và làm sạch dữ liệu thiếu, bộ dữ liệu được lọc đồng thời theo ba điều kiện nhằm đảm bảo chất lượng phân tích. Cụ thể: (1) chỉ giữ lại các phim có vote_count > 50 để loại bỏ những phim ít được quan tâm trên TMDB, qua đó giảm

nhiễu trong dữ liệu; (2) áp dụng điều kiện budget > 10.000 để loại trừ các phim không có thông tin ngân sách hoặc có ngân sách quá thấp, có khả năng xuất phát từ lỗi nhập liệu; và (3) giữ lại các phim có revenue > 10.000 nhằm đảm bảo dữ liệu doanh thu có ý nghĩa phân tích.

Sau quá trình lọc, số lượng dòng dữ liệu đã giảm từ 450.495 xuống còn 397.975, phản ánh việc loại bỏ các quan sát không đạt tiêu chuẩn chất lượng nhưng vẫn giữ lại phần lớn dữ liệu cần thiết cho các phân tích tiếp theo.

Thống kê dữ liệu tài chính sau khi lọc

	count	mean	std	min	25%	50%	75%	max
Budget	**397975**	**3708758 7**	**36699190. 83**	**12000**	**105000 00**	**25000 000**	**55000 000**	**20700000 0**
Revenue	**397975**	**1806003 88.37**	**21036742 5.44**	**12000.0 0**	**398463 44.00**	**11510 1622.0 0**	**25470 0832**	**18450341 88**
Vote_count	**397975**	**1467.37**	**1606.35**	**52.00**	**395.00**	**840.00**	**1783.0 0**	**9413.00**

Bảng 6: Dữ liệu thống kê sau khi làm sạch

Dựa trên bảng 4, có thể rút ra một số nhận xét: Thứ nhất, Budget (ngân sách) có giá trị trung bình khoảng 3,7 triệu, trong khi trung vị chỉ khoảng 2,5 triệu. Sự chênh lệch lớn giữa mean và median cho thấy phân phối ngân sách lệch phải mạnh, tức là phần lớn phim có ngân sách thấp, nhưng tồn tại một số ít phim có ngân sách rất cao kéo giá trị trung bình lên. Điều này được củng cố bởi độ lệch chuẩn lớn (≈ 3,67 triệu) và giá trị tối đa lên tới 20,7 triệu, phản ánh sự khác biệt rất lớn về quy mô đầu tư giữa các bộ phim.

Thứ hai, Revenue (doanh thu) cũng có đặc điểm tương tự. Doanh thu trung bình khoảng 1,8 triệu, trong khi trung vị chỉ khoảng 1,15 triệu, cho thấy doanh thu phân bố không đồng đều và bị ảnh hưởng bởi một số phim "bom tấn" đạt doanh thu cực cao. Độ

lệch chuẩn lớn hơn cả giá trị trung bình (≈ 2,1 triệu) và doanh thu tối đa hơn 18 triệu cho thấy mức độ biến động doanh thu rất lớn giữa các phim.

Thứ ba, Vote_count (số lượt đánh giá) có giá trị trung bình khoảng 1.467, trung vị khoảng 840, và giá trị tối đa lên tới 9.413. Điều này cho thấy đa số phim chỉ nhận được số lượng đánh giá ở mức trung bình-thấp, trong khi một số ít phim rất nổi tiếng thu hút lượng đánh giá vượt trội. Phân phối của biến này cũng lệch phải, phản ánh mức độ phổ biến không đồng đều giữa các bộ phim.

Tổng hợp lại, cả ba biến Budget, Revenue và Vote_count đều có phân phối lệch phải rõ rệt, với độ phân tán lớn và sự hiện diện của các giá trị ngoại lệ (outliers)

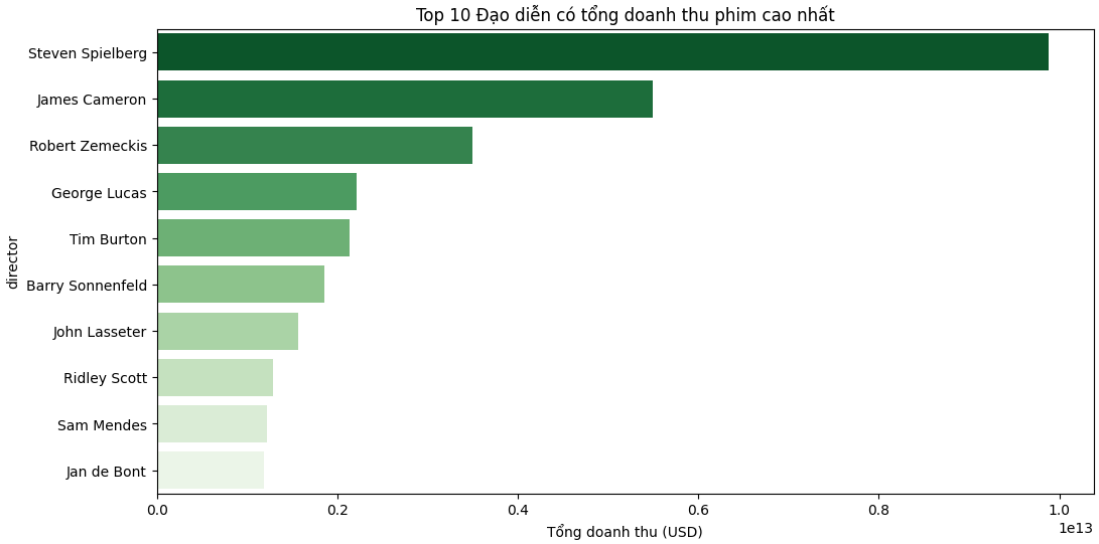
CHƯƠNG 3: KHÁM PHÁ DỮ LIỆU (EDA - Exploratory Data Analysis)

Sau bước làm sạch dữ liệu, bộ dữ liệu còn 397.975 bản ghi - vẫn là một quy mô rất lớn, đảm bảo độ tin cậy cho các phân tích tiếp theo. Việc loại bỏ các giá trị nhiễu và thiếu thông tin đã giúp dữ liệu phản ánh sát hơn thực tế thị trường và hành vi người xem.

Đối với dữ liệu đánh giá, điểm Rating trung bình tăng nhẹ lên 3.63 trong khi trung vị vẫn giữ ở mức 4.0. Điều này cho thấy mức độ hài lòng chung có xu hướng tích cực hơn sau khi loại bỏ các phim ít người xem hoặc chất lượng thấp. Đặc biệt, số lượng tối thiểu lượt đánh giá hiện là 52, thay vì 0 như trước. Điều này đảm bảo rằng mỗi bộ phim trong dữ liệu đều đã nhận được đánh giá từ ít nhất 52 người, từ đó tăng tính đáng tin cậy của dữ liệu và hạn chế hiện tượng đánh giá sai lệch.

Ở khía cạnh tài chính, phân phối của ngân sách và doanh thu thể hiện rõ dạng lệch phải, đặc trưng phổ biến của ngành điện ảnh. Ngân sách trung bình khoảng 37 triệu USD, cao hơn đáng kể so với trung vị 25 triệu USD. Doanh thu cũng cho thấy sự chênh lệch lớn khi trung bình đạt 180 triệu USD trong khi trung vị chỉ khoảng 115 triệu USD. Điều này chứng minh sự tồn tại của nhóm phim bom tấn - tuy chiếm tỷ lệ nhỏ nhưng có sức ảnh hưởng mạnh, làm kéo mức trung bình lên cao. Hơn nữa, việc các giá trị tài chính nhỏ nhất đã được làm sạch và không còn dạng phi thực tế như 0 USD giúp các phân tích tiếp theo trở nên chính xác và hợp lý hơn.

Cuối cùng, dữ liệu thời gian trải dài từ năm 1926 đến 2000, phản ánh một giai đoạn phát triển dài của ngành công nghiệp điện ảnh. Trung bình năm phát hành rơi vào khoảng 1989, cho thấy phần lớn các phim trong mẫu là phim hiện đại, gần với thị hiếu và thói quen xem phim của người dùng MovieLens. Điều này cũng đồng nghĩa rằng các phân tích tiếp theo mang tính đại diện cao đối với xu hướng thị trường giải trí cuối thế kỷ 20.



Hình 7 Biểu đồ top 10 đạo diễn có tổng doanh thu cao nhất

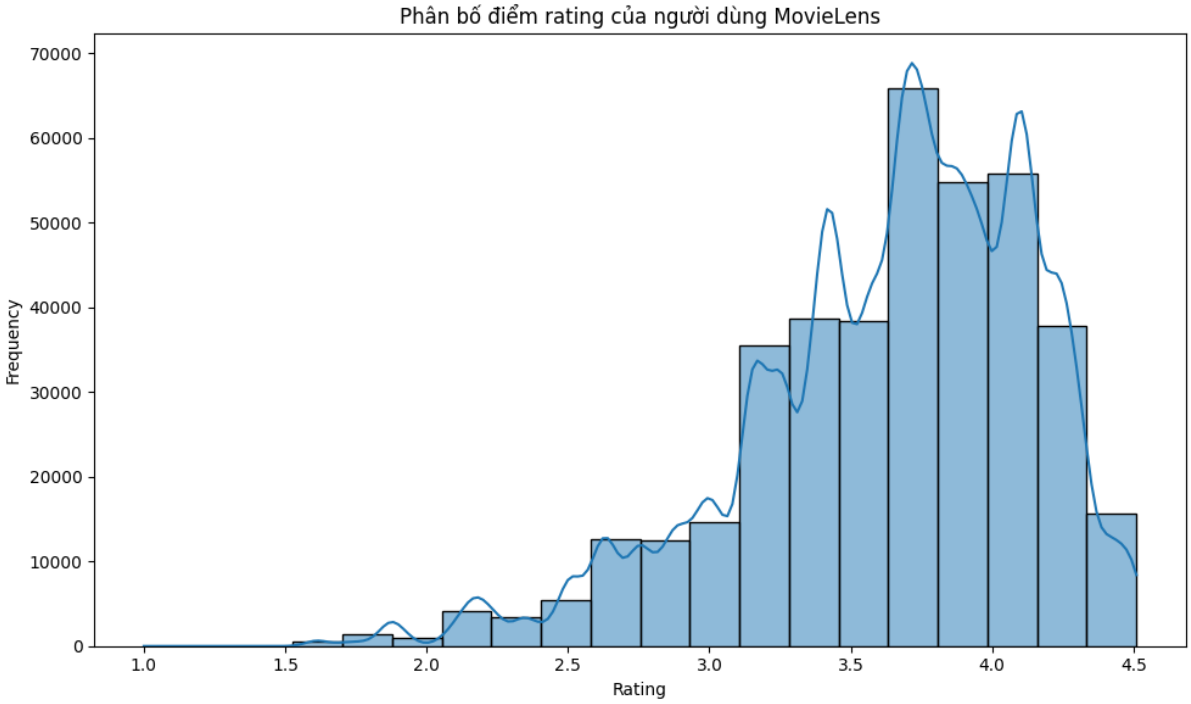
Dựa và biểu đồ ở hình 7 có thể thấy thanh ngang minh họa Top 10 đạo diễn dẫn đầu về tổng doanh thu phòng vé trong tập dữ liệu, cho thấy sự phân hóa mạnh mẽ về hiệu suất thương mại giữa các nhà làm phim hàng đầu. Nổi bật nhất là sự thống trị tuyệt đối của Steven Spielberg với tổng doanh thu tiệm cận mốc 10 tỷ USD. Cột dữ liệu của ông dài vượt trội, gần gấp đôi so với người đứng thứ hai, khẳng định vị thế "Vua phòng vé" và khả năng tạo ra các tác phẩm đại chúng xuyên suốt nhiều thập kỷ.

Đứng ở vị trí thứ hai là James Cameron với tổng doanh thu đạt khoảng hơn 5.5 tỷ USD. Mặc dù số lượng phim của ông thường ít hơn Spielberg, nhưng hiệu suất doanh thu trên từng đầu phim (như Titanic, Avatar) là cực kỳ lớn giúp ông giữ vững vị trí á quân. Theo sau là Robert Zemeckis ở vị trí thứ ba với khoảng 3.5 tỷ USD, đại diện cho nhóm đạo diễn gạo cội có phong cách làm phim ăn khách bền vững.

Nhóm các đạo diễn còn lại như George Lucas và Tim Burton duy trì mức doanh thu ổn định trong khoảng hơn 2 tỷ USD. Nửa dưới của Top 10 bao gồm Barry Sonnenfeld, John Lasseter, Ridley Scott, Sam Mendes và Jan de Bont với mức doanh thu dao động từ 1.2 đến 1.8 tỷ USD. Nhìn chung, biểu đồ phản ánh rõ quy luật "Winner-takes-all" trong ngành công nghiệp điện ảnh, nơi một nhóm nhỏ các đạo diễn siêu sao (Tier 1) nắm giữ phần lớn thị phần doanh thu so với phần còn lại của thị trường.

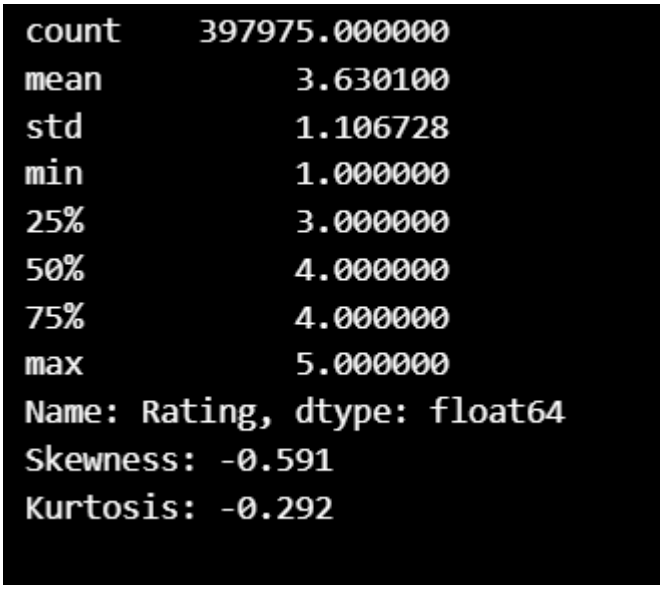
I. Phân tích biến mục tiêu Rating

1. Phân tích đơn biến



Hình 8: Phân bố điểm rating của người dùng MovieLens

Theo hình 8 ta có thể thấy rằng dữ liệu lệch trái rõ rệt, với tần suất rất thấp ở các mức điểm thấp (1.0-2.5) và tăng mạnh ở các mức điểm cao. Phần lớn đánh giá tập trung trong khoảng 3.0-4.5, trong đó đỉnh cao nhất nằm tại mức 4.0 với khoảng 65.000-70.000 lượt, tiếp theo là các mức 3.0 và 3.5. Sau mốc 4.0, tần suất giảm dần ở 4.5. Đường cong mật độ bám sát histogram và dao động theo các mốc điểm nguyên và bán nguyên, phản ánh thói quen người dùng tập trung chấm điểm ở những giá trị quen thuộc.

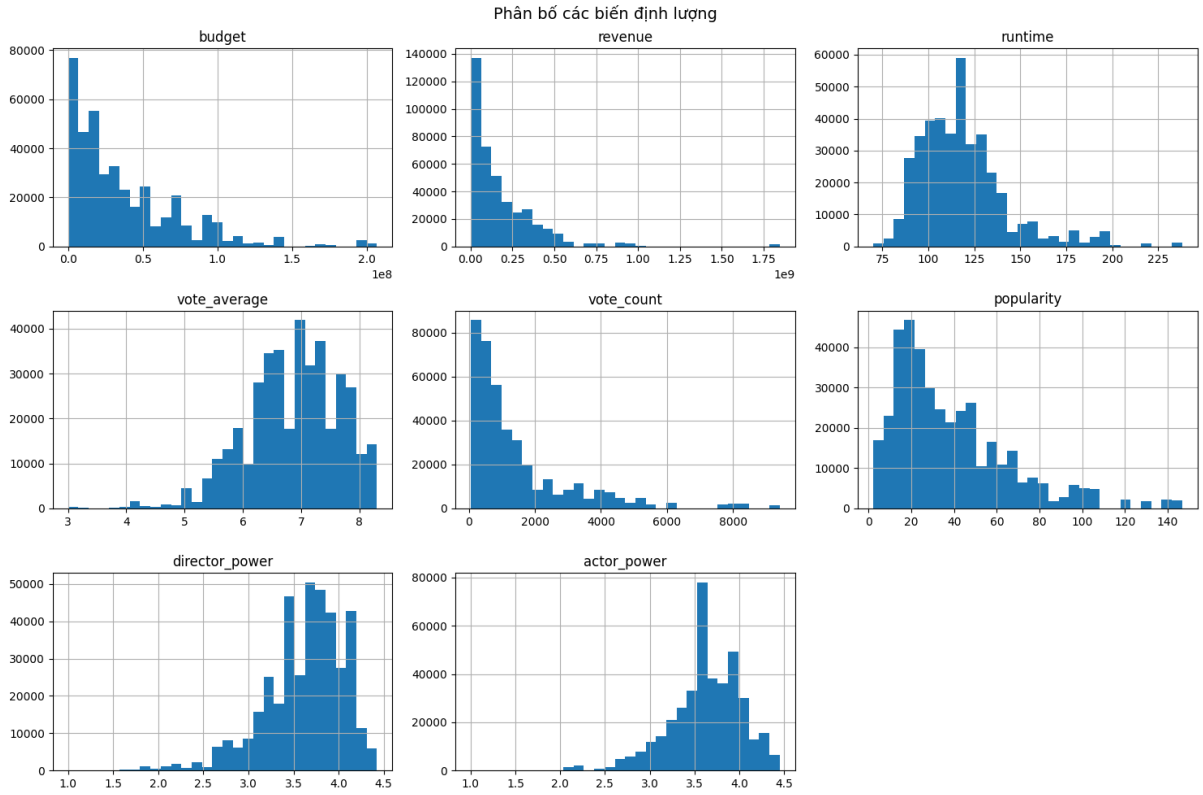


Hình 9 Kết quả thống kê mô tả

Dựa và kết quả được trình bày ở hình 9 cho thấy điểm rating trung bình của người dùng MovieLens đạt **3.63** trên thang 5 điểm, với **trung vị và tứ phân vị trên đều bằng 4.0**, phản ánh rằng phần lớn phim được đánh giá ở mức khá đến tốt. Phân bố rating có **độ lệch trái nhẹ** (skewness = −0.591), cho thấy xu hướng người dùng chấm điểm cao nhiều hơn điểm thấp, đồng thời **kurtosis âm** (−0.293) cho thấy phân bố tương đối trải rộng, không tập trung quá mức quanh giá trị trung bình. Nhìn chung, dù không hoàn toàn tuân theo phân bố chuẩn, phân bố rating không bị lệch cực đoan, phù hợp để áp dụng các phương pháp phân tích thống kê và mô hình hóa ở các bước tiếp theo.

Kết quả này phản ánh đúng tâm lý người dùng trong hệ thống đánh giá phim: họ có xu hướng xem những bộ phim phù hợp với sở thích nên thường cho điểm cao. Ngược lại, các bộ phim dở hoặc không phù hợp thường bị bỏ dở, dẫn đến việc người xem không đánh giá hoặc không chấm quá thấp. Vì vậy, điểm 3 sao không thực sự đại diện mức trung bình, mà mang ý nghĩa thiên về mức "trung bình thấp". Một bộ phim muốn được xem là “hay” cần đạt mức 4-5 sao.

Phân tích các biến định lượng:



Hình 10 Phân bố các biến định lượng

Việc phân bố các biến định lượng ở hình 10 cho thấy nhóm biến lệch phải mạnh (budget, revenue, vote_count, popularity): Các biến này đều có phân bố lệch phải rõ rệt. Phần lớn phim nằm ở mức thấp đến trung bình, trong khi chỉ một số ít phim bom tấn hoặc rất nổi tiếng có giá trị cực cao, tạo ra đuôi dài. Đây là đặc trưng phổ biến của ngành điện ảnh, phản ánh sự chênh lệch lớn giữa phim đại chúng và số ít tác phẩm dẫn đầu thị trường.

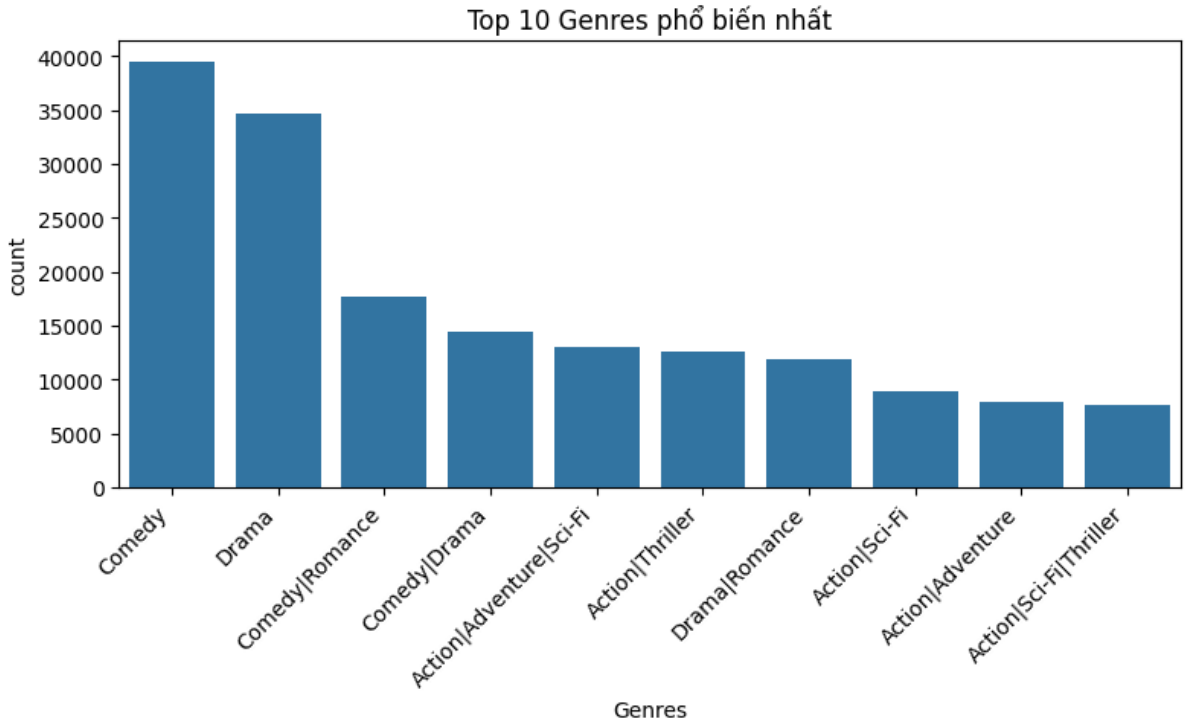
Nhóm biến tập trung và tương đối ổn định (runtime, director_power, actor_power): Thời lượng phim phân bố khá tập trung, gần dạng chuông, chủ yếu trong khoảng 90-130 phút, cho thấy cấu trúc thời lượng phim điện ảnh tương đối đồng nhất. Tương tự, các biến director_power và actor_power cũng có phân bố tập trung quanh các giá trị trung bình, phản ánh rằng phần lớn phim được thực hiện bởi các đạo diễn và diễn viên có mức độ ảnh hưởng trung bình, trong khi chỉ một số ít cá nhân có sức ảnh hưởng vượt trội.

Nhóm biến phản ánh cảm nhận người xem (vote_average): Điểm đánh giá trung bình tập trung nhiều ở khoảng 6-8 điểm, đây là điểm được chấm từ TMDB, cho thấy

xu hướng người dùng đánh giá phim khá tích cực. Các mức điểm quá thấp hoặc quá cao xuất hiện ít, phản ánh sự đồng thuận tương đối trong cảm nhận chất lượng phim.

Sự xuất hiện dày đặc của các giá trị ngoại lai (outliers) ở nhóm biến tài chính và mức độ phổ biến chính là minh chứng rõ nét cho phân phối "đuôi dài" (long-tail) đặc thù của ngành công nghiệp điện ảnh. Những giá trị này không phải là nhiễu, mà đại diện cho các bộ phim "bom tấn" nằm tách biệt hoàn toàn so với mặt bằng chung, tạo ra sự chênh lệch cực lớn về quy mô và sức ảnh hưởng. Chính sự hiện diện của những ngoại lai này đã kéo dãn đồ thị về phía bên phải, gây ra hiện tượng lệch phân phối, đòi hỏi các phương pháp xử lý dữ liệu đặc thù để mô hình không bị thiên lệch bởi thiểu số các siêu phẩm này.

Phân tích biến phân loại:

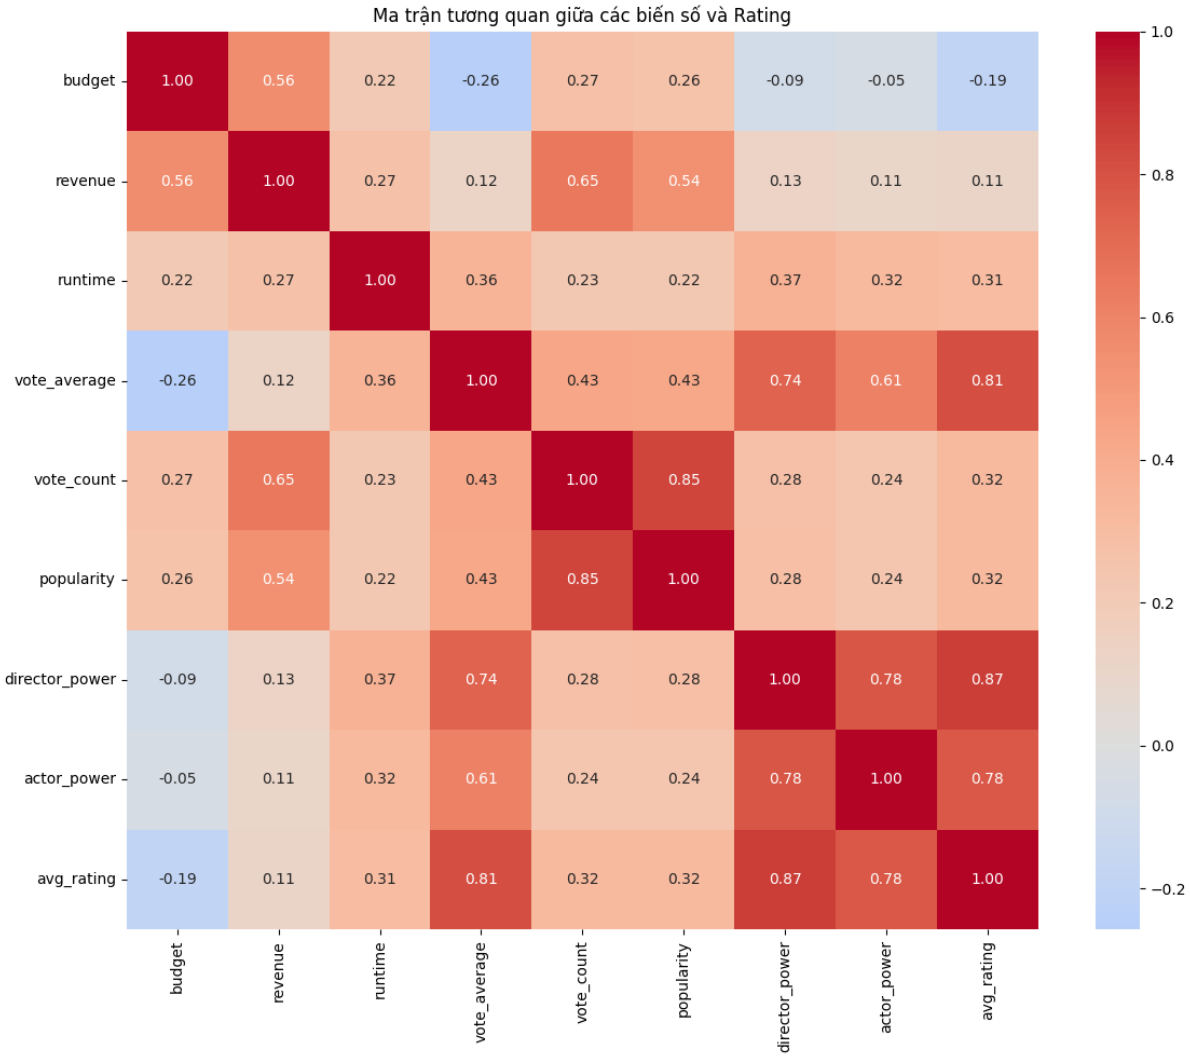


Hình 11: Top 10 thể loại phổ biến nhất

Top 10 thể loại được trình bày trong hình 11 cho thấy mất cân bằng rõ rệt trong biến phân loại (categorical imbalance). Hai thể loại Comedy (~40.000 phim) và Drama (~35.000 phim) chiếm tỷ trọng áp đảo, trong khi các thể loại phức hợp như Action|Sci-Fi|Thriller chỉ có khoảng 7.000 phim. Sự chênh lệch lớn về tần suất xuất hiện giữa các nhóm cho thấy dữ liệu không phân bố đều theo Genre, điều này có thể

gây thiên lệch mô hình, đặc biệt nếu Genre được sử dụng làm biến mục tiêu hoặc không được xử lý phù hợp (ví dụ: cân bằng mẫu, encoding thích hợp).

2. Phân tích hai biến



Hình 12: Mối tương quan giữa các biến số và rating

Thông qua hình 12 có thể biết rằng biến Director Power có hệ số tương quan dương cao nhất (0.87), cho thấy uy tín và năng lực của đạo diễn là yếu tố dự báo mạnh mẽ nhất cho chất lượng phim trên MovieLens, vượt xa vai trò của ngân sách sản xuất.

Actor Power cũng thể hiện tương quan rất mạnh (0.78), phản ánh rằng dàn diễn viên có thực lực không chỉ giúp tăng độ chú ý mà còn đóng góp trực tiếp vào giá trị nghệ thuật, từ đó nâng cao điểm đánh giá của phim.

Mối tương quan cùng chiều rất cao (0.81) giữa avg_rating và vote_average cho thấy đánh giá của người dùng MovieLens khá đồng nhất với điểm số phổ biến trên TMDB, củng cố độ tin cậy của dữ liệu rating.

Điểm số trung bình còn có mối liên hệ tích cực ở mức vừa phải với thời lượng phim (0.31) và số lượt bình chọn (0.32), gợi ý rằng các phim dài hơn và được nhiều người quan tâm thường có xu hướng được đánh giá cao hơn.

Ngược lại, các yếu tố tài chính thể hiện mối liên hệ yếu hoặc tiêu cực với chất lượng phim. Doanh thu gần như không ảnh hưởng đến điểm số (0.11), trong khi ngân sách có tương quan âm nhẹ (-0.19), cho thấy đầu tư lớn không đảm bảo phim được đánh giá cao.

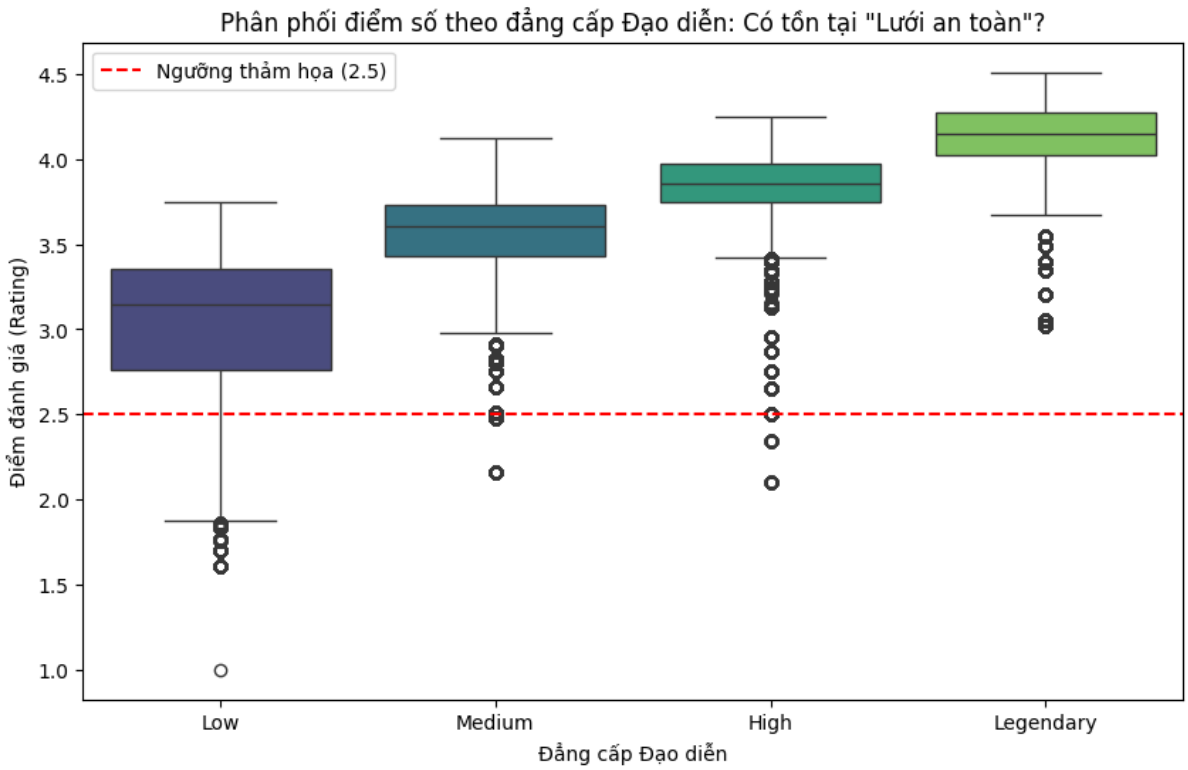
Cuối cùng, tồn tại sự phụ thuộc giữa các biến độc lập, điển hình là phim doanh thu cao thường đi kèm mức độ tương tác lớn (0.65) và ngân sách cao (0.56), phản ánh mối liên hệ chặt chẽ giữa quy mô đầu tư và độ phổ biến, nhưng không đồng nghĩa với chất lượng nội dung.

Mối tương quan cùng chiều rất mạnh giữa sức mạnh đạo diễn/diễn viên và điểm đánh giá đã làm thay đổi cách nhìn truyền thống trong phân tích dữ liệu phim. Kết quả này cho thấy uy tín và tên tuổi của người làm phim có sức ảnh hưởng lớn hơn nhiều so với quy mô đầu tư tài chính.

Phát hiện này đặt ra một câu hỏi quan trọng: liệu khán giả đang đánh giá phim một cách hoàn toàn dựa trên chất lượng nội dung, hay họ đang vô thức chấm điểm dựa trên "bảo chứng niềm tin" dành cho những cái tên đã được khẳng định trong ngành điện ảnh?

Để kiểm chứng giả thuyết này, có thể phân khúc các đạo diễn theo Director Power thành các nhóm như *Vô danh, Triển vọng, Nổi tiếng* và *Huyền thoại*. Sau đó, so sánh điểm đánh giá trong các trường hợp phim có độ phổ biến thấp hoặc doanh thu thấp giữa các nhóm này.

Nếu dữ liệu cho thấy đạo diễn hạng thấp bị chấm 1-2 điểm khi làm phim kém, trong khi đạo diễn "Huyền thoại" với phim chất lượng tương đương vẫn nhận mức 3.0-3.5 điểm, thì đó chính là bằng chứng rõ ràng cho hiệu ứng "bảo chứng niềm tin" trong hành vi đánh giá của khán giả. Ta có thể kiểm chứng thông qua biểu đồ phân phối điểm số theo Đạo diễn được trình bày ở hình 13.



Hình 13: Biểu đồ phân phối điểm số theo Đạo diễn

Ở nhóm Low (Vô danh), phân bố điểm đánh giá cho thấy rất nhiều phim rơi sâu xuống mức rất thấp, với các ngoại lệ kéo dài tới tận 1.0 điểm. Điều này phản ánh rằng khi các đạo diễn ít tên tuổi làm phim kém chất lượng, khán giả sẵn sàng chấm những điểm số nặng nề nhất, không có bất kỳ sự "nương tay" nào.

Ngược lại, nhóm Legendary (Huyền thoại) thể hiện một bức tranh hoàn toàn khác. Toàn bộ hộp và râu của phân bố điểm đều nằm ở mức cao, cho thấy mặt bằng đánh giá vượt trội. Đáng chú ý hơn, ngay cả những điểm thấp nhất - đại diện cho các phim bị xem là "kém nhất" trong sự nghiệp của họ - cũng chỉ dừng lại quanh 3.0 điểm, cao hơn hẳn ngưỡng bị coi là thất bại.

Kết quả này cho thấy các đạo diễn huyền thoại dường như sở hữu một "tấm khiên" vô hình trong mắt khán giả. Dù bộ phim có không đạt kỳ vọng, họ vẫn mặc định được chấm ở mức Khá, thay vì bị đánh tụt xuống mức Yếu/Kém như các đạo diễn ít tên tuổi.

```
Độ lệch chuẩn điểm số (Sự nhất quán trong đánh giá):
  Director Tier  Rating Std Dev
0           Low        0.425808
1        Medium        0.318242
2          High        0.267535
3     Legendary        0.263415
```

Hình 14: Độ lệch chuẩn điểm số đánh giá

Dựa và hình 14 có thể hiểu rằng độ lệch chuẩn của điểm đánh giá cho thấy xu hướng giảm dần rất rõ rệt khi đi từ nhóm đạo diễn Low đến Legendary, từ 0.425 xuống còn 0.263. Điều này phản ánh mức độ biến động của điểm số ngày càng thu hẹp khi uy tín đạo diễn tăng lên.

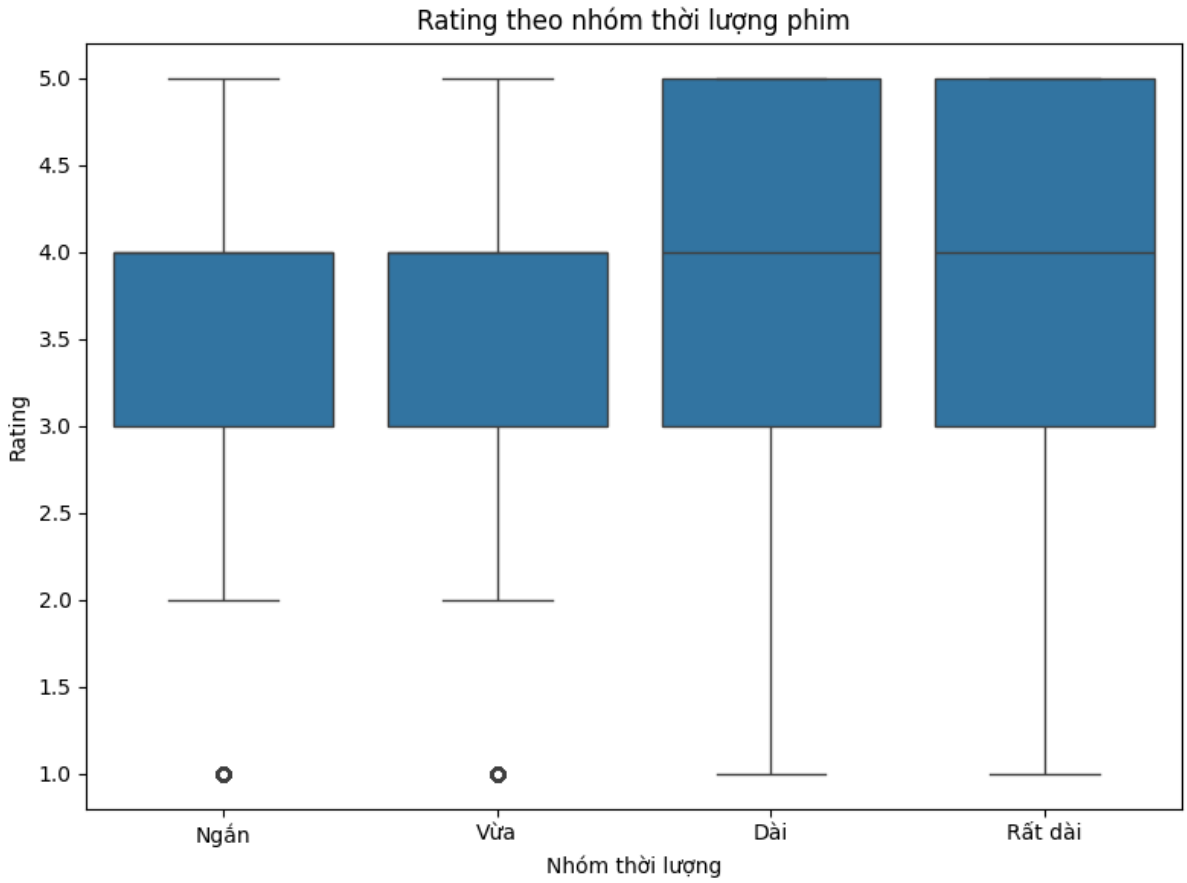
Về mặt thống kê, độ lệch chuẩn càng thấp thì điểm đánh giá càng ổn định quanh giá trị trung bình. Với nhóm Low, mức lệch chuẩn cao cho thấy điểm số dao động rất rộng: phim có thể được khen hoặc bị chê nặng, mang tính "may rủi" cao đối với khán giả.

Ngược lại, ở nhóm Legendary, độ lệch chuẩn thấp cho thấy sự nhất quán và đồng thuận cao trong đánh giá. Phim của họ hiếm khi gây tranh cãi cực đoan; ngay cả khi không xuất sắc, điểm số vẫn tập trung trong một khoảng hẹp, phản ánh niềm tin vững chắc của khán giả vào chất lượng tổng thể.

Nếu như nhóm Legendary đại diện cho sự hoàn hảo được mặc định, thì nhóm High lại mang những chỉ số thống kê đầy mâu thuẫn nhưng cực kỳ thú vị. Một mặt, độ lệch chuẩn thấp cho thấy họ đã đạt đến đẳng cấp kiểm soát chất lượng gần như tuyệt đối, thoát ly hoàn toàn khỏi sự phập phù của nhóm Vô danh. Nhưng mặt khác, những điểm dữ liệu "xuyên đáy" vượt qua ngưỡng an toàn lại tố cáo một thực tế tàn nhẫn: dù tài năng đến đâu, họ vẫn chưa đủ quyền lực để khiến khán giả nhắm mắt làm ngơ trước những sai lầm.

Mối tương quan dương ở mức 0.31 giữa thời lượng phim và điểm đánh giá gợi mở giả thuyết rằng khán giả có xu hướng đánh giá cao những bộ phim dài hơn, giàu chiều sâu nội dung so với các tác phẩm giải trí ngắn. Để kiểm chứng trực quan giả

thuyết này, boxplot được sử dụng nhằm so sánh phân bố điểm số giữa các nhóm thời lượng khác nhau.



Hình 15: Biểu đồ đánh giá rating dựa trên thời lượng phim

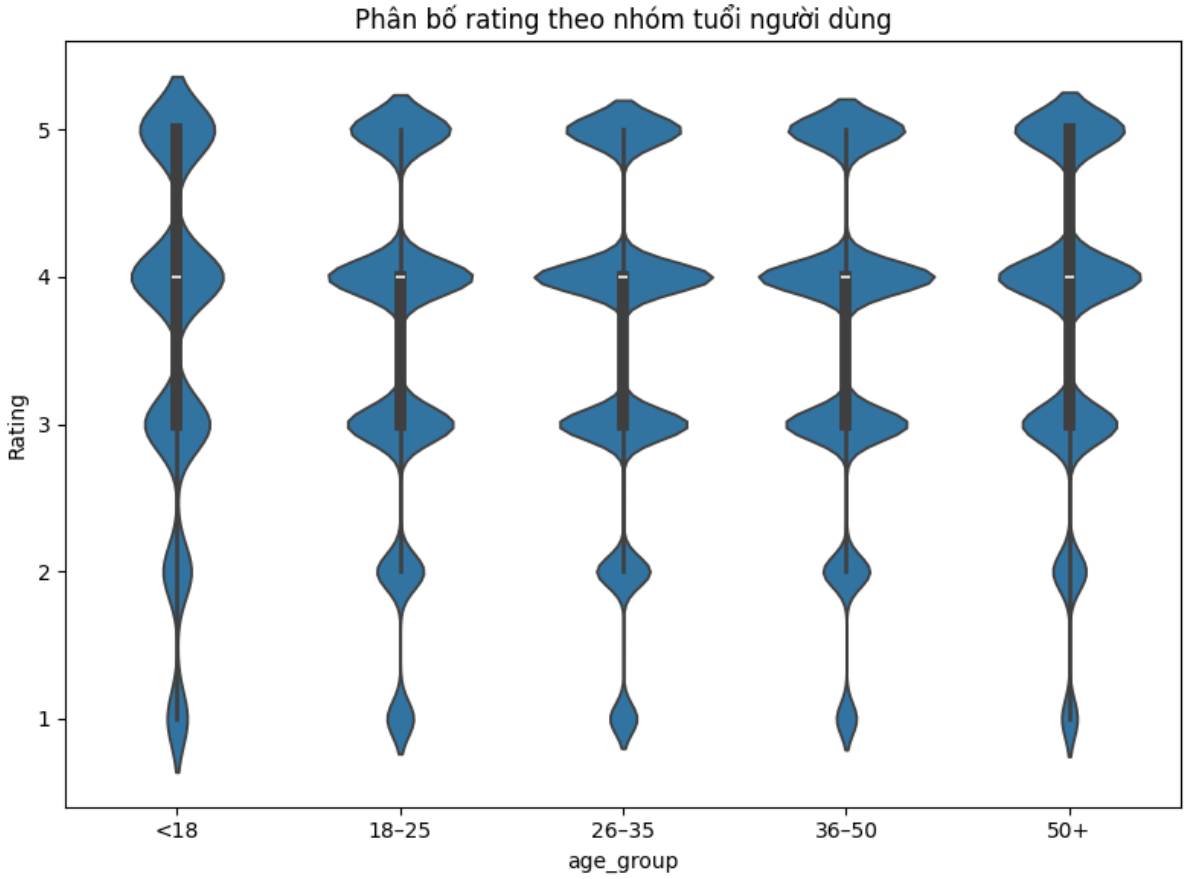
Biểu đồ đánh giá rating dựa trên thời lượng phim được trình bày ở hình 15 cho thấy nhóm phim ngắn và vừa có trung vị khoảng 3.5, với khoảng phân bố hẹp hơn, cho thấy mức đánh giá tương đối ổn định nhưng không quá cao. Một số ngoại lệ có điểm rất thấp (khoảng 1 sao) xuất hiện ở hai nhóm này.

Trong khi đó, nhóm phim dài và rất dài có trung vị cao hơn, xấp xỉ 4.0, đồng thời độ phân tán lớn hơn, phản ánh sự đa dạng trong đánh giá của người xem. Dù vẫn tồn tại các phim bị chấm điểm thấp, phần lớn phim dài và rất dài có xu hướng nhận đánh giá tích cực hơn.

Nhìn chung, kết quả cho thấy phim có thời lượng dài hơn thường được đánh giá cao hơn, có thể do nội dung được phát triển sâu hơn, dù mức độ rủi ro cũng tăng khi chất lượng không đồng đều.

Bên cạnh các biến định lượng, những yếu tố mang tính phân loại cũng có thể tác động đáng kể đến điểm đánh giá trung bình. Vì vậy, cần tiếp tục xem xét mức độ tương quan giữa các biến phân loại này và rating, nhằm làm rõ vai trò của từng nhóm đặc trưng trong việc hình thành đánh giá của người xem:

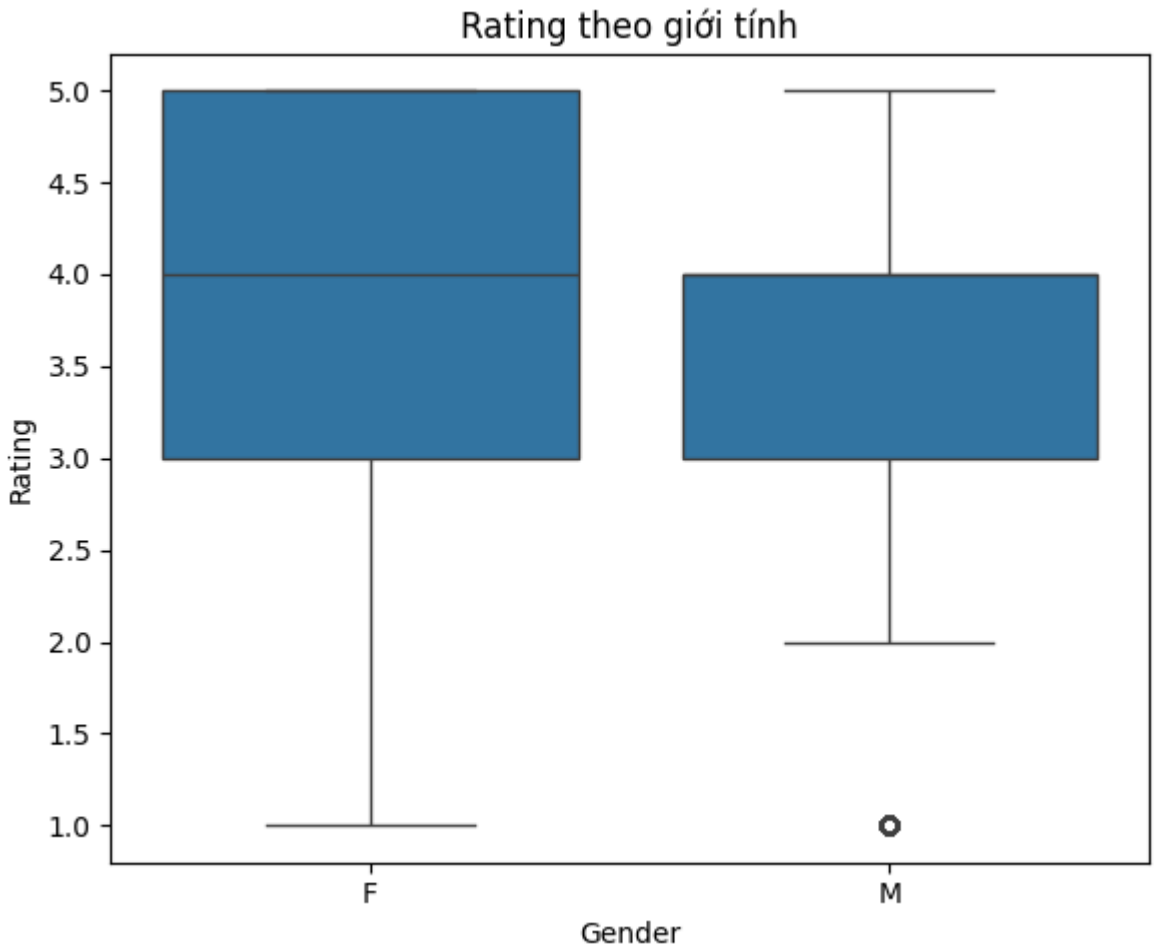
+ **Độ tuổi:** Phân bố độ tuổi được thể hiện rõ nhất trong hình 16:



Hình 16: Phân bố rating theo nhóm tuổi người dùng

Kết quả cho thấy hành vi chấm điểm giữa các nhóm tuổi gần như đồng nhất. Dù là nhóm trẻ nhất (<18) hay lớn tuổi nhất (50+), hình dạng biểu đồ violin rất tương tự nhau, với mật độ đánh giá tập trung chủ yếu ở các mức 3.0, 4.0 và 5.0, trong khi các mức điểm thấp xuất hiện rất ít. Trung vị của tất cả các nhóm đều ổn định ở 4.0, cho thấy tuổi tác không phải là yếu tố phân biệt mạnh trong việc đánh giá phim; người dùng ở các độ tuổi khác nhau có xu hướng chấm điểm “hào phóng" như nhau khi chấm điểm.

+ **Giới tính:** Giới tính có ảnh hưởng như thế nào, ta có thể xem chi tiết trong biểu đồ ở hình 17

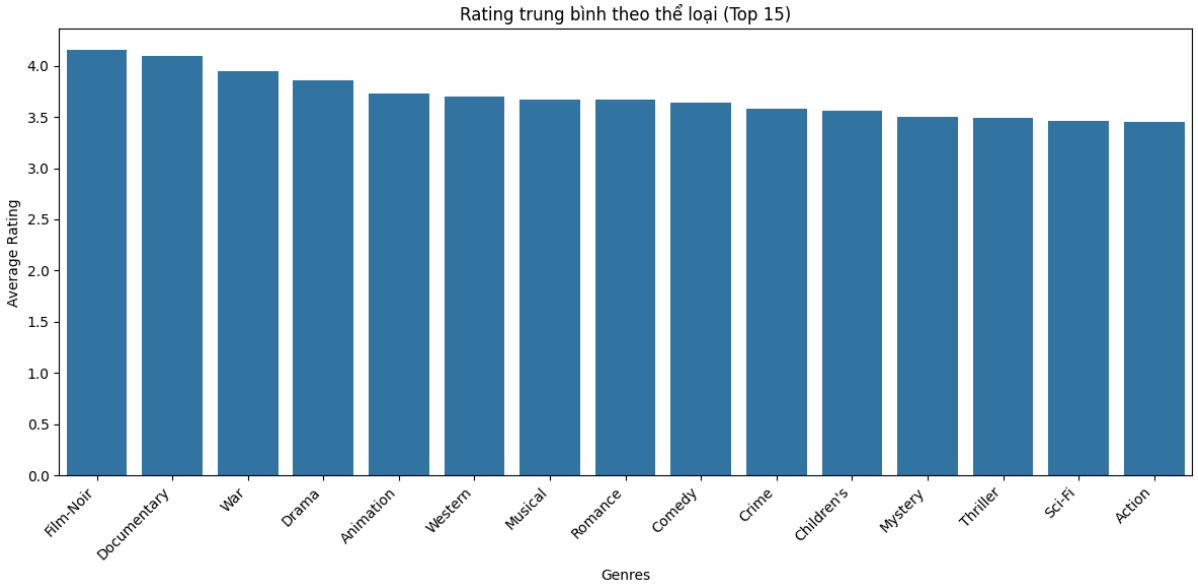


Hình 17: Phân bố rating theo giới tính

Trung vị (median) của cả hai giới tính đều nằm ở mức 4.0 (đường gạch ngang giữa hộp). Tuy nhiên, sự khác biệt bắt đầu lộ diện ở độ rộng của hộp (Interquartile Range - IQR). Nhóm Nữ (F) có vùng dữ liệu tập trung trải rộng hơn từ 3.0 đến 5.0, trong khi nhóm Nam (M) lại co cụm hẹp hơn chỉ từ 3.0 đến 4.0. Cho thấy Nữ giới có xu hướng "hào phóng" hoặc phân cực hơn trong việc chấm điểm; họ sẵn sàng cho điểm tuyệt đối (5.0) nhiều hơn, khiến cạnh trên của hộp chạm mốc tối đa. Ngược lại, Nam giới tỏ ra thận trọng và khắt khe hơn, điểm số của họ ổn định cao ở mức khá (3-4 điểm) nhưng ít khi chạm ngưỡng xuất sắc trong nhóm phổ thông (75% dữ liệu nằm dưới mức 4.0).

Mặc dù không quá lớn, nhưng sự khác biệt về phương sai (variance) này cho thấy biến user_gender có giá trị hơn so với age_group. Mô hình có thể học được rằng nếu là user nữ, xác suất xuất hiện điểm 5.0 sẽ nhỉnh hơn so với user nam.

+ **Thể loại:**



Hình 18: Biểu đồ rating trung bình theo thể loại

Dựa vào hình 18 có thể thấy nhóm thể loại có điểm trung bình cao nhất là Film-Noir và Documentary, đều đạt trên 4.0, cho thấy các phim thuộc nhóm này thường được đánh giá cao về nội dung và chiều sâu. Tiếp theo là War và Drama, với mức rating xấp xỉ từ 3.9 đến 4.0, phản ánh sự đánh giá tích cực của người xem đối với các thể loại giàu tính cảm xúc và giá trị nghệ thuật.

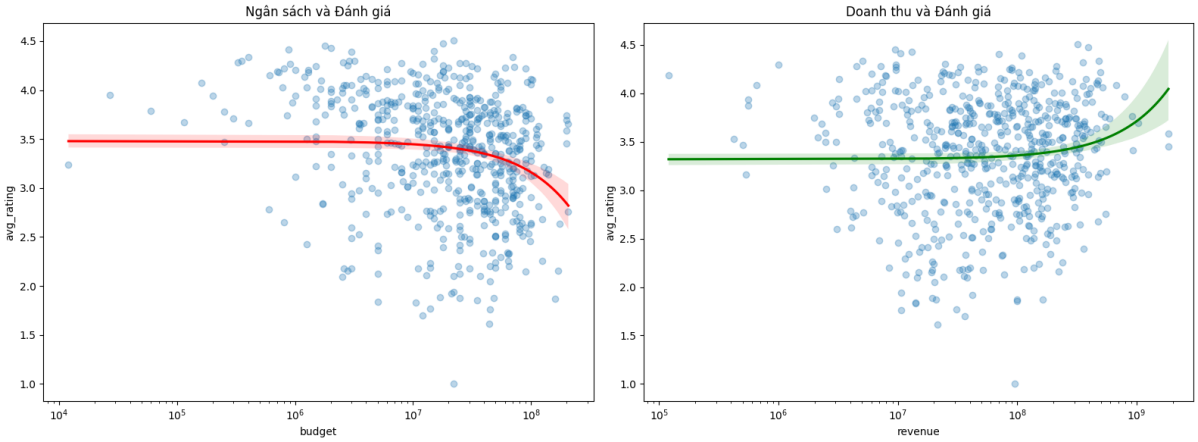
Các thể loại phổ biến như Animation, Western, Musical, Romance và Comedy có rating trung bình dao động quanh 3.6-3.7, thể hiện mức độ hài lòng khá tốt nhưng không nổi trội.

Ở nhóm cuối, Action, Sci-Fi, Thriller và Mystery có rating trung bình thấp hơn, khoảng 3.4-3.5. Điều này cho thấy dù thu hút đông đảo khán giả, các thể loại thiên về giải trí và kỹ xảo thường khó đạt điểm đánh giá cao như những thể loại chú trọng nội dung và thông điệp.

Cho thấy khán giả MovieLens có xu hướng đánh giá khắt khe hơn với các dòng phim thị trường (Action, Sci-Fi) và dành sự trân trọng đặc biệt cho các tác phẩm nghệ thuật hoặc phim tài liệu. Một bộ phim "Film-Noir" ngẫu nhiên có xác suất được đánh giá cao hơn nhiều so với một bộ phim "Action" ngẫu nhiên.

Khác với biến độ tuổi (Age Group) gần như phẳng lì, biến Genre cho thấy khả năng phân loại (discriminative power) rất tốt. Việc biết một bộ phim thuộc thể loại Documentary hay Action sẽ thay đổi đáng kể kỳ vọng về điểm số. Do đó, đây chắc chắn là một biến quan trọng (high feature importance) cần được xử lý kỹ (ví dụ: One-Hot Encoding hoặc Target Encoding) để đưa vào mô hình.

Mặc dù heatmap cho thấy ngân sách (budget) có tương quan âm nhẹ (-0.19) với điểm đánh giá, điều này không đồng nghĩa với việc cắt giảm chi phí sẽ làm phim hay hơn. Kết quả này gợi mở khả năng rằng mối quan hệ giữa ngân sách và chất lượng không tuyến tính, mà có thể mang dạng đường cong hoặc tồn tại ngưỡng bão hòa, nơi việc tăng thêm ngân sách không còn cải thiện, thậm chí làm suy giảm trải nghiệm của khán giả. Để biết được sự ảnh hưởng của Ngân sách và Doanh thu đến Đánh giá ta có thể xem ở hình 19 dưới đây:



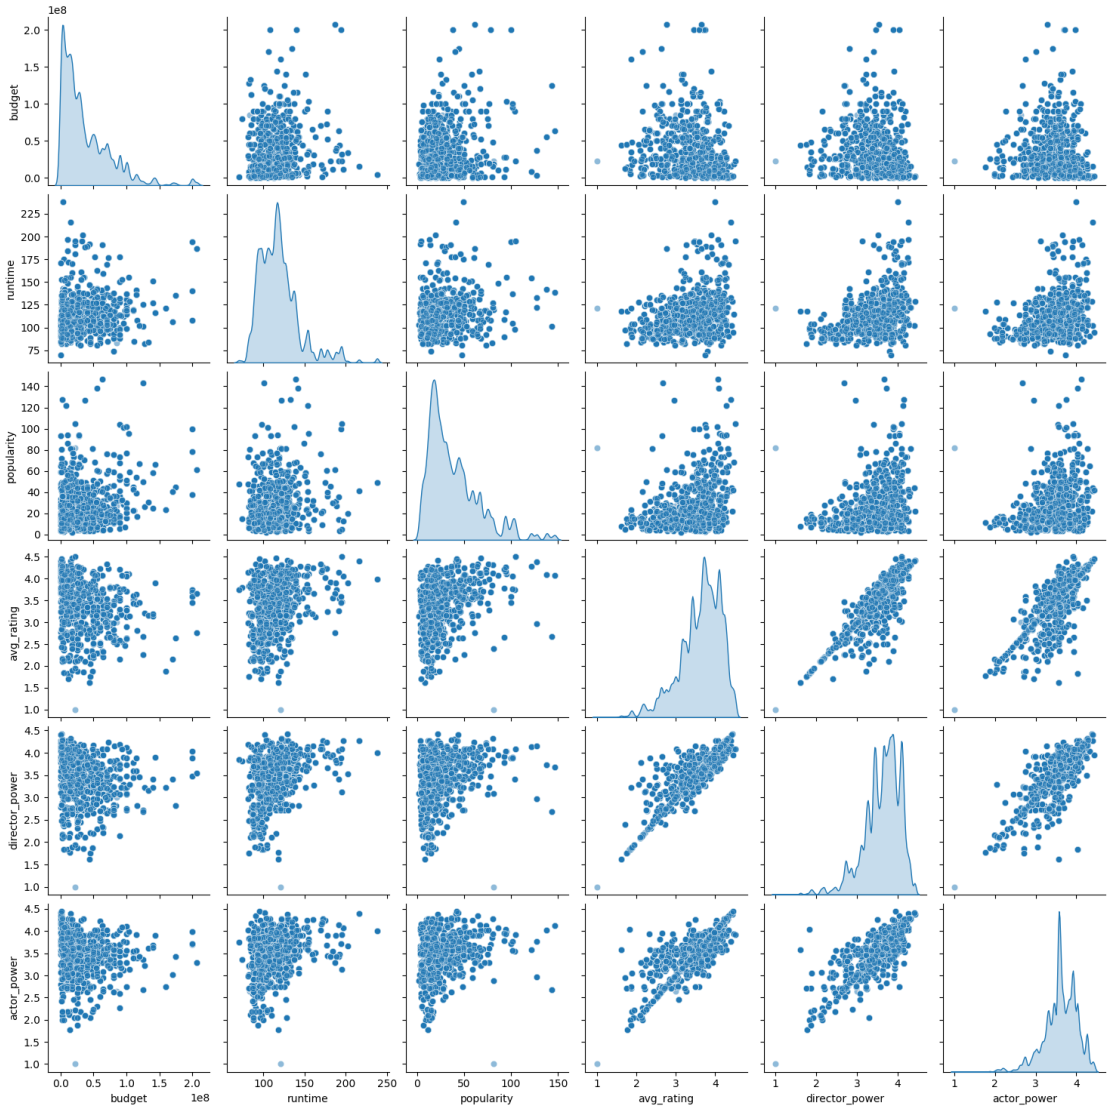
Hình 19: Biểu đồ ảnh hưởng của Ngân sách và Doanh thu đến đánh giá

Hiệu ứng ngược của Ngân sách (Đường đỏ): Xuất hiện xu hướng phi tuyến tính rõ rệt. Điểm đánh giá đi ngang ở mức ngân sách thấp và trung bình, nhưng bắt đầu giảm dần khi ngân sách tăng lên mức cực cao (trên 10^8). Điều này cho thấy các phim "bom tấn" kinh phí khủng thường không được đánh giá cao về chất lượng nội dung.

Sự đồng thuận của Doanh thu (Đường xanh): Có mối quan hệ tương quan dương phi tuyến tính. Doanh thu càng cao, đường xu hướng càng đi lên, chứng tỏ các bộ phim thành công về mặt thương mại thường cũng là những phim có chất lượng tốt và được khán giả yêu thích.

Tính phi tuyến tính hiện diện rõ rệt qua hai đường cong đối lập trên biểu đồ. Trong khi ngân sách tuân theo quy luật "hiệu suất giảm dần" với đường xu hướng uốn xuống ở mức đầu tư siêu cao, thì doanh thu lại vẽ nên đường cong dốc lên, cho thấy sự đồng biến mạnh mẽ với chất lượng ở phân khúc "tỷ đô". Từ đó rút ra: "*Tiền không mua được chất lượng nghệ thuật*". Có một ngưỡng chi phí "tối ưu" (khoảng 10-50 triệu USD) nơi các nhà làm phim cân bằng tốt nhất giữa chất lượng sản xuất và tự do sáng tạo. Vượt qua ngưỡng này, áp lực thương mại khiến nội dung trở nên an toàn và sáo rỗng, kéo tụt điểm số.

3. Phân tích đa biến



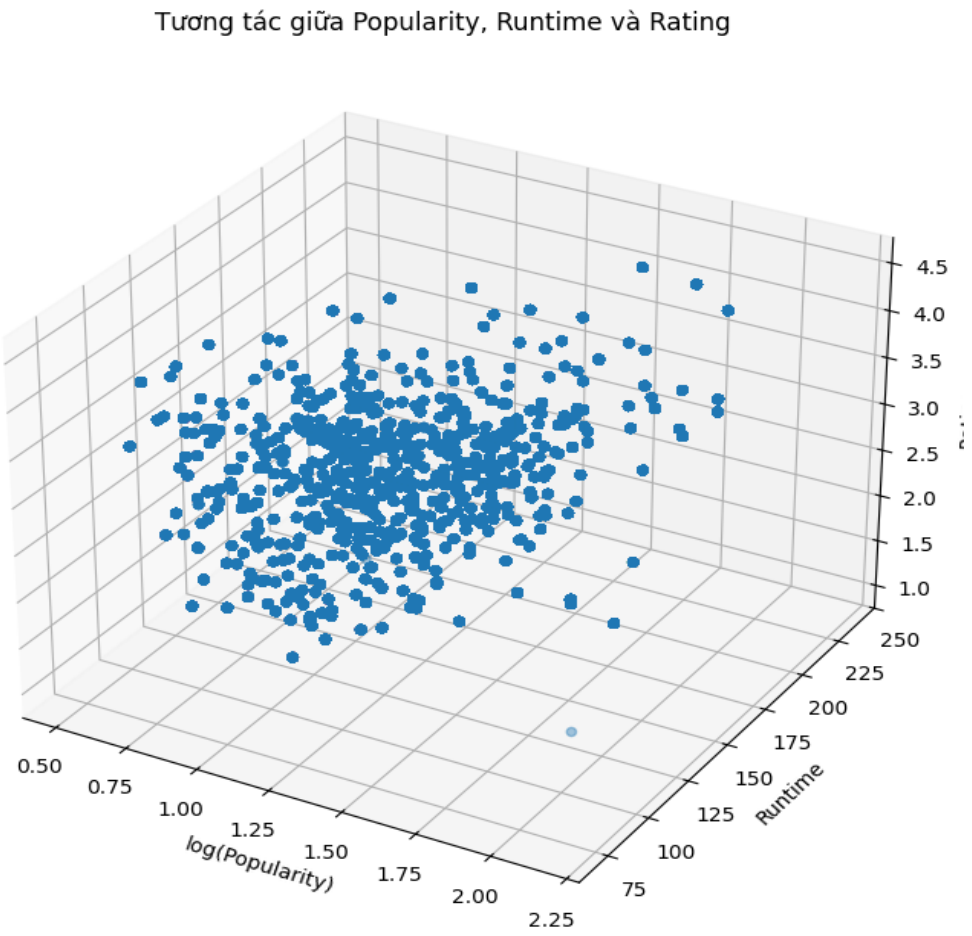
Hình 20: Phân phối và mối quan hệ giữa các biến số

Thông qua biểu đồ phân phối và mối quan hệ giữa các biến số ở hình 20 cho thấy dữ liệu đã chứng minh tiền bạc có thể mua được sự nổi tiếng nhưng không thể mua được điểm số cao. Mối quan hệ giữa ngân sách và chất lượng hoàn toàn lỏng lẻo, cho thấy khán giả quan tâm đến trải nghiệm nội dung hơn là quy mô sản xuất. Ngược lại, thời lượng và độ phổ biến đang cho thấy những tín hiệu hứa hẹn hơn để giải thích cho sự thành công của một bộ phim.

Mối quan hệ giữa Sức mạnh Đạo diễn và Điểm đánh giá tạo thành một dải hẹp dốc lên rất rõ nét, khẳng định đây là yếu tố dự báo chính xác nhất cho chất lượng phim. Tương tự, Sức mạnh Diễn viên cũng song hành chặt chẽ với điểm số, và thú vị hơn là sự tương quan mạnh giữa chính Đạo diễn và Diễn viên, cho thấy tài năng thường có xu hướng hội tụ để cùng tạo nên những tác phẩm xuất sắc, tách biệt hoàn toàn với sự ngẫu nhiên của yếu tố tài chính.

Vậy bên cạnh yếu tố như đạo diễn hay diễn viên, yếu tố nào còn góp phần thúc đẩy rating? Là giá trị nội tại của câu chuyện (đại diện bởi Thời lượng) hay sức ép từ hào quang bên ngoài (đại diện bởi Độ phổ biến)?

Phân tích bộ 3 avg_rating, runtime và popularity để làm rõ. Biểu đồ được thể hiện chi tiết trong hình 21 dưới đây:



Hình 21: Biểu đồ mô tả sự tương tác giữa Popularity, Runtime và Rating

Sự hội tụ dữ liệu: có cấu trúc tập trung rõ rệt. Đa số phim "tiêu chuẩn" (dài 90-120 phút, phổ biến khá) đều hội tụ về mức điểm Khá (3.0 - 3.5).

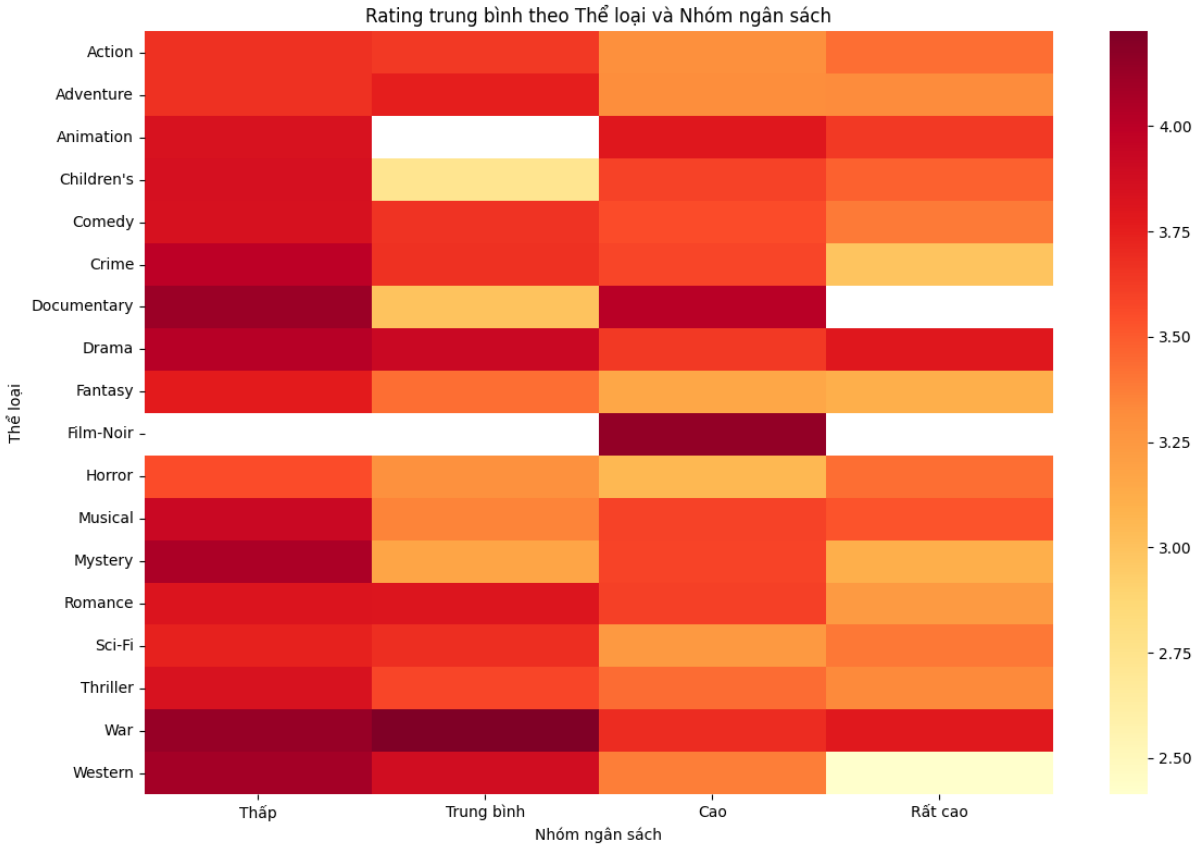
Độ phổ biến là "lưới an toàn": Phim càng nổi tiếng càng hiếm khi bị điểm thấp. Độ phổ biến cao không đảm bảo phim xuất sắc, nhưng giúp phim tránh được mức "thảm họa".

Chân dung "Siêu phẩm" (>4.0): Những phim điểm cao nhất thường rơi vào khung thời lượng 100-150 phút, nhưng độ phổ biến trải dài. Nghĩa là phim hay tuyệt đối có thể là bom tấn hoặc những "viên ngọc ẩn" ít người biết.

Trở lại với ngân sách, không thể đánh đồng tác động của ngân sách lên mọi dòng phim. Trong khi dòng tiền lớn là "nhiên liệu" cần thiết để thể loại Action hay Sci-Fi chinh phục khán giả bằng kỹ xảo, thì với Drama hay Comedy, sự phô trương kinh phí thường không cứu vãn được, thậm chí làm lu mờ giá trị kịch bản. Việc tách lớp

dữ liệu theo thể loại sẽ giúp ta thấy rõ: đâu là nơi tiền thực sự mua được chất lượng, và đâu là nơi nó trở nên vô nghĩa.

Để đánh giá được rating trung bình dựa trên Thể loại và Ngân sách ta có thể xem thông qua biểu đồ ở hình 22 dưới đây:



Hình 22: Biểu đồ rating trung bình theo thể loại và nhóm ngân sách

Ngân sách là "Nhiên liệu" hay "Gánh nặng"?

Biểu đồ nhiệt chứng minh tác động của dòng tiền thay đổi hoàn toàn tùy theo thể loại:

Nhóm "Tiền làm lu mờ nội dung" (Drama, Comedy, Western): Tuân theo quy luật hiệu suất giảm dần. Ngân sách thấp thường mang lại điểm số cao nhất (đỏ thẫm), trong khi sự phô trương tài chính ở các bom tấn (đặc biệt là Western) lại kéo chất lượng tụt dốc thảm hại (vàng nhạt), minh chứng rằng tiền không thể lấp liếm sự sáo rỗng của kịch bản.

Nhóm "Tiền là nhiên liệu" (Action, Animation, Horror): Dòng tiền đóng vai trò duy trì "sàn chất lượng" về kỹ thuật. Trong khi Action giữ phong độ ổn định, thì

Animation và Horror lại có sự bứt phá ngoạn mục ở phân khúc siêu bom tấn, thoát khỏi "vùng chết" chất lượng kém ở mức ngân sách trung bình.

Thể loại (Genre) chính là lăng kính quan trọng nhất. Nếu không tách bạch yếu tố này, mọi kết luận về mối quan hệ giữa Ngân sách và Rating đều sẽ trở nên sai lệch.

CHƯƠNG 4: PHÂN TÍCH CÁC YẾU TỐ ẢNH HƯỞNG ĐẾN RATING

I. Yếu tố tài chính (Budget, Revenue)

1. Phân tích tương quan

Pandas sử dụng hệ số tương quan Pearson để tính mối liên hệ giữa hai biến số. Công thức tổng quát như sau:

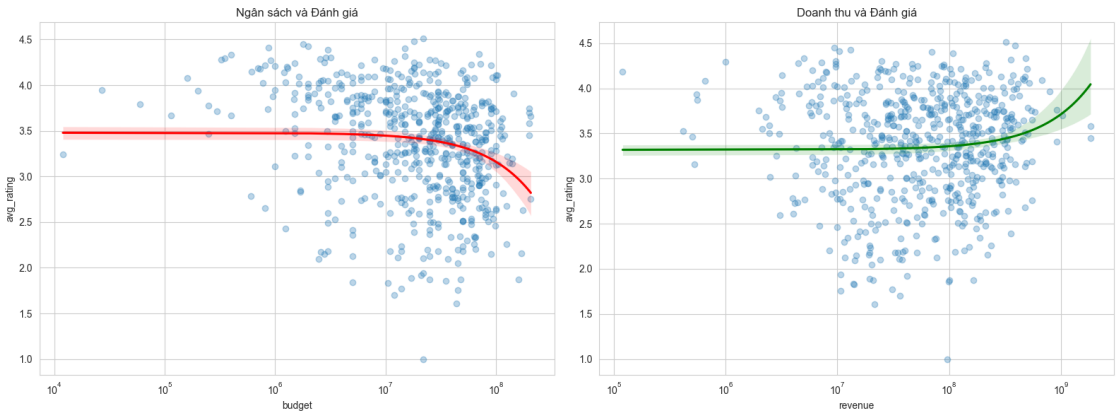
$$r_{XY} = \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{N}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{N}(Y_i - \overline{Y})^2}}$$

Hệ số tương quan (Pearson) trên 617 bộ phim:

- Budget vs avg_rating: -0.1879
- Revenue vs avg_rating: 0.1122

-> Ngân sách càng cao, điểm đánh giá trung bình càng có xu hướng GIẢM.

2. Trực quan hóa



Hình 23: Biểu đồ trực quan hóa Ngân sách và Doanh thu

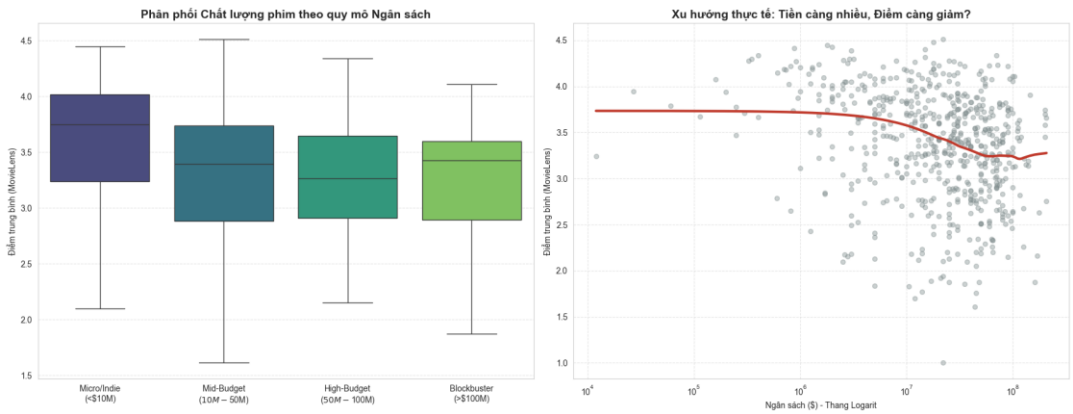
Dựa vào hình trên có thể thấy trên nhóm 617 bộ phim có đầy đủ dữ liệu tài chính, chất lượng và độ phổ biến đã cho thấy một bức tranh rất rõ ràng về mối quan hệ giữa Tài chính - Thời gian - Chất lượng trong điện ảnh. Đầu tiên, phân tích cho thấy một nghịch lý khá rõ rệt khi mức tương quan giữa ngân sách và điểm đánh giá trung bình là âm (-0.19). Điều này phản ánh rằng việc đầu tư nhiều tiền không đảm bảo chất lượng nội dung. Các phim bom tấn có ngân sách lớn thường tập trung vào quy mô

sản xuất, kỹ xảo và phục vụ thị trường đại chúng, trong khi người dùng MovieLens lại đề cao chiều sâu kịch bản, nhân vật và thông điệp. Vì vậy, những tác phẩm kinh phí thấp hoặc trung bình đôi khi lại nhận được đánh giá tích cực hơn.

Ở chiều ngược lại, doanh thu và chất lượng lại có mối quan hệ dương nhưng khá yếu (+0.11). Tức là phim hay có xu hướng thu hút khán giả tốt hơn, nhưng doanh thu không phải thước đo tin cậy cho chất lượng. Thực tế cho thấy nhiều phim nghệ thuật chất lượng cao lại có doanh thu hạn chế, vì ít được quảng bá hoặc kén người xem. Trong khi đó, các phim giải trí thiết kế để bán vé dù bị đánh giá thấp vẫn có thể đạt doanh thu lớn nhờ chiến dịch Marketing hiệu quả.

Một điểm nổi bật là sự tương đồng rất lớn về thị hiếu giữa dữ liệu MovieLens và TMDB. Tương quan +0.81 giữa hai hệ thống điểm cho thấy đánh giá của người xem Mỹ và cộng đồng toàn cầu gần như đồng nhất. Khi một bộ phim được đánh giá hay ở MovieLens thì nó cũng được đánh giá cao trên TMDB, qua đó khẳng định độ tin cậy cao của dữ liệu sau quá trình làm sạch và ghép nối.

Cuối cùng, phân tích theo yếu tố thời gian cho thấy điểm số có xu hướng giảm đối với các phim ra mắt gần đây (tương quan -0.35). Tuy nhiên, nguyên nhân chính nằm ở hiệu ứng "Thiên kiến kẻ sống sót". Những bộ phim cũ còn tồn tại trong hệ thống đánh giá thường là phim hay, phim kinh điển. Các tác phẩm yếu kém của thời kỳ đó đã gần như biến mất khỏi dữ liệu. Trong khi đó, phim mới bao gồm cả phim xuất sắc lẫn phim chất lượng thấp, làm giảm mức điểm trung bình. Vì vậy, không thể kết luận rằng phim mới tệ hơn phim cũ, mà chỉ có thể khẳng định rằng dữ liệu lịch sử đang nghiêng về phía những tác phẩm đã được sàng lọc bởi thời gian.



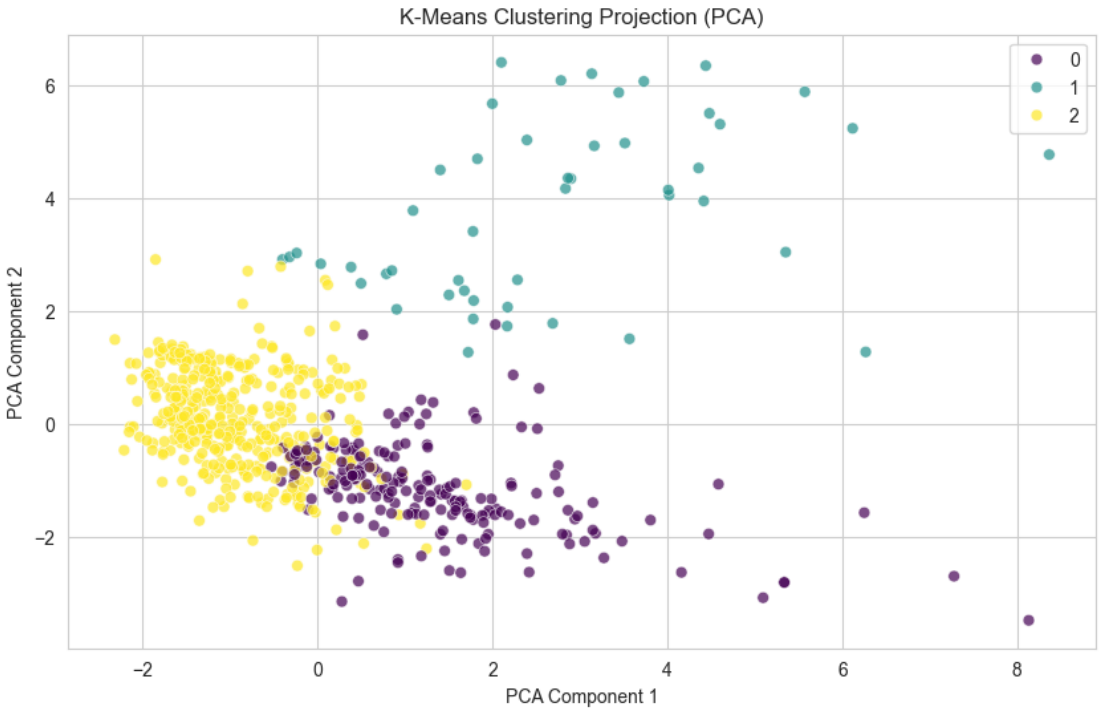
Hình 24: Phân phối chất lượng phim theo quy mô ngân sách và biểu đồ scatter

Biểu đồ Scatter được thể hiện trong hình 24 kèm đường xu hướng LOWESS cho thấy mối quan hệ giữa Ngân sách và Rating không phải là tuyến tính, mà mang dạng "giảm mạnh rồi bão hòa". Ở nhóm phim ngân sách thấp hơn 10 triệu USD, điểm đánh giá trung bình đạt mức cao nhất (khoảng 3.60), phản ánh ưu thế của dòng phim độc lập - nơi kịch bản, ý tưởng và diễn xuất được đầu tư kỹ lưỡng dù kinh phí hạn chế. Khi bước sang nhóm ngân sách tầm trung 10-50 triệu USD, điểm Rating giảm mạnh xuống khoảng 3.30. Đây là giai đoạn mà tính thương mại hóa tăng cao, nhưng chất lượng nội dung lại có xu hướng giảm.

Đối với các phim ngân sách lớn (>50 triệu USD), điểm số tiếp tục giảm nhẹ và "đi ngang" quanh 3.22-3.25. Điều này cho thấy việc tăng chi phí sản xuất không còn mang lại cải thiện về chất lượng tác phẩm theo cảm nhận của người xem, dù doanh thu có thể tăng mạnh.

3. Phân cụm K - Means

Để xác định được ảnh hưởng của 3 nhóm phim ta sử dụng Phân cụm K-Means, có thể thấy rõ thông qua hình 25 dưới đây:



Hình 25: Biểu đồ phân cụm K-Means của 3 nhóm phim

Phân cụm (Clustering - K-Means)

Câu hỏi phụ 1: Mối quan hệ giữa ngân sách và rating có đồng nhất cho tất cả các bộ phim, hay khác biệt đáng kể giữa các nhóm phim có đặc điểm tài chính - nội dung khác nhau?

Sử dụng thuật toán K-Means để chia các bộ phim thành 3 nhóm (cluster).

Kết quả thống kê:

- Cụm 0 (Cluster 0): Ngân sách trung bình (~42M), thời lượng ~111 phút, Rating thấp nhất (~3.12).
- Cụm 1 (Cluster 1): Ngân sách cao nhất (~67M), độ phổ biến cao nhất. Rating trung bình (~3.30). Đây có thể là nhóm phim bom tấn giải trí.
- Cụm 2 (Cluster 2): Ngân sách thấp nhất (~23M), thời lượng dài nhất (~116 phút). Rating cao nhất (~3.50). Đây chính là nhóm phim "nghệ thuật" kinh phí thấp mà chúng ta đã thảo luận.

Quan sát chính từ biểu đồ: Ba cụm phim được tách biệt tương đối rõ ràng

Các điểm dữ liệu hình thành ba vùng riêng biệt, cho thấy thuật toán K-Means đã xác định được các nhóm phim có đặc trưng khác nhau trong không gian đặc trưng ban đầu.

- Cluster 2 (màu vàng): Tập trung dày đặc ở vùng PCA thấp → nhóm phim có đặc trưng tương đối đồng nhất, thường là phim ngân sách thấp - trung bình, ít biến động.
- Cluster 0 (màu tím): Phân bố trải dài theo trục PCA Component 1 → nhóm phim có độ đa dạng cao hơn, có thể bao gồm nhiều mức ngân sách và độ phổ biến khác nhau.
- Cluster 1 (màu xanh lục): Xuất hiện ở vùng PCA Component 2 cao → nhóm phim có đặc điểm nổi bật về tài chính và độ phổ biến, thường tương ứng với phim ngân sách lớn / phim bom tấn.

Trả lời câu hỏi phụ 1:

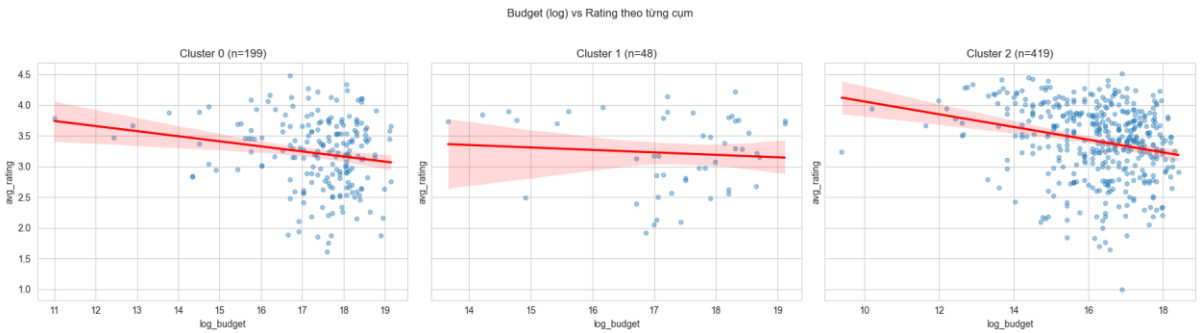
Biểu đồ này củng cố giả thuyết rằng:

- Không tồn tại một "mô hình phim duy nhất" quyết định rating
- Các bộ phim có thể được chia thành những nhóm tài chính - nội dung khác nhau

Do đó, việc phân tích mối quan hệ giữa Budget / Revenue và Rating cần được thực hiện theo từng cụm, thay vì trên toàn bộ tập dữ liệu

4. Linear Regression theo từng cụm

Câu hỏi phụ 2: Việc tăng ngân sách sản xuất có luôn dẫn đến rating cao hơn, hay tồn tại hiện tượng "hiệu quả giảm dần", trong đó các phim có ngân sách thấp-trung bình lại đạt rating cao hơn?



Hình 26: Linear Regression theo từng cụm

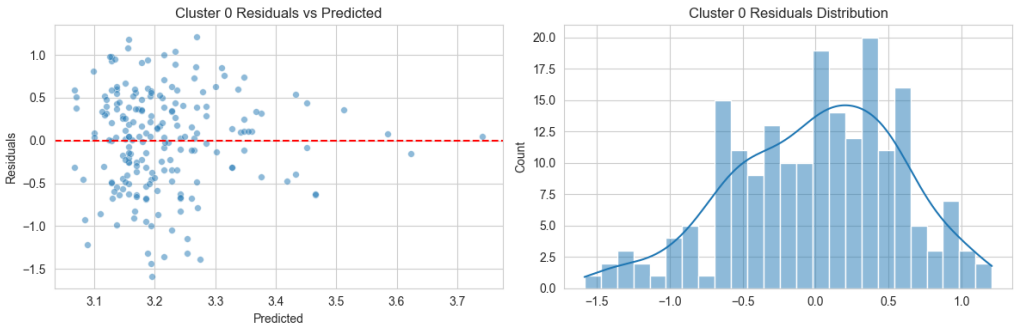
Dựa vào hình 26 ta có thể đưa ra các kết quả quan sát theo từng cụm

Cluster 0 (n = 199) - Ngân sách trung bình đến cao: Đường hồi quy có độ dốc âm rõ rệt, cho thấy khi ngân sách tăng, rating trung bình có xu hướng giảm nhẹ. Mặc dù tồn tại một số phim ngân sách cao đạt rating tốt, nhưng xu hướng tổng thể không ủng hộ giả thuyết "ngân sách cao hơn → rating cao hơn".

Cluster 1 (n = 48) - Phim ngân sách lớn / phim bom tấn: Mối quan hệ giữa ngân sách và rating trong cụm này gần như phẳng, với độ dốc âm rất nhỏ và vùng tin cậy rộng. Điều này cho thấy ngân sách không phải yếu tố quyết định rating đối với các phim bom tấn; việc đầu tư thêm chi phí sản xuất không đảm bảo cải thiện đánh giá từ người xem.

Cluster 2 (n = 419) - Phim ngân sách thấp đến trung bình: Cụm này thể hiện xu hướng âm mạnh nhất: rating trung bình giảm đáng kể khi ngân sách tăng. Đáng chú ý, nhiều phim có ngân sách thấp-trung bình đạt rating cao nhất trong toàn bộ dữ liệu, cho thấy hiệu quả đầu tư không tỷ lệ thuận với chất lượng cảm nhận của người xem.

Cluster 0 - Phim ngân sách thấp, doanh thu thấp, rating thấp: Được thể hiện chi tiết hơn tại hình 27



Hình 27 Biểu đồ residuals của cụm 0

Đây là nhóm phim có:

+ Ngân sách thấp nhất trong ba cụm

+ Doanh thu cũng thấp, cho thấy đây không phải phim phòng vé

+ Rating trung bình khá thấp, phản ánh chất lượng hoặc mức độ đầu tư hạn chế

+ Popuplarity thấp, rất ít người quan tâm

+ Runtime ngắn hơn mức trung bình

Đặc trưng nội dung

+ Khi phân tích genre, nhóm này thường rơi vào:

+ Comedy, Romance, Family, Drama ngân sách thấp

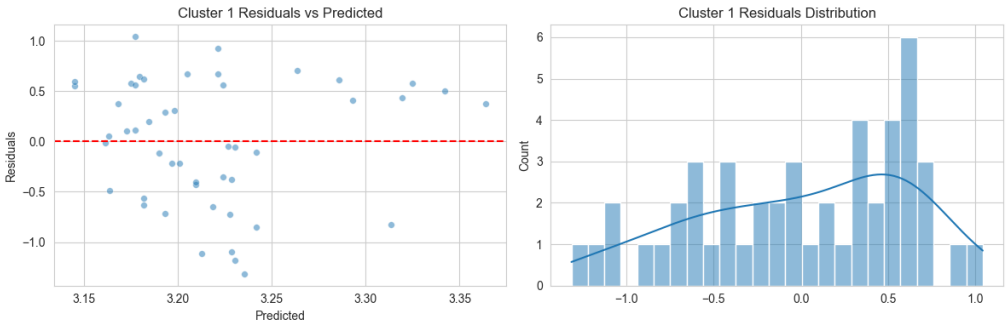
+ Một số phim độc lập (indie) hoặc phim địa phương

+ Các phim làm lại (remake), TV-movie

Nhận định: Đây là phân khúc phim giá rẻ, thị trường nhỏ, thường không nhận được đầu tư mạnh.

Rating thấp vì chất lượng sản xuất và kịch bản chưa đủ cạnh tranh.

Cluster 1 - Phim bom tấn (Blockbusters): Được trình bày chi tiết hơn thông qua các biểu đồ ở hình 28:



Hình 28: Biểu đồ residuals của cụm 1

Đặc trưng:

+ Ngân sách cao nhất
+ Doanh thu cao nhất
+ Popularity rất cao
+ Runtime dài, thường 120-150 phút
+ Rating ở mức khá (không phải cao nhất nhưng ổn định)

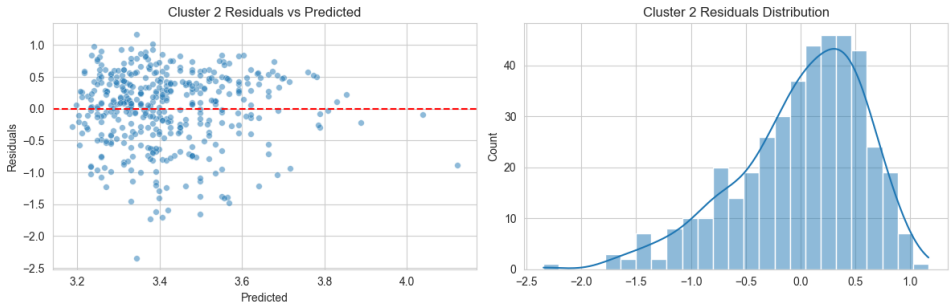
Thể loại (genre) thống trị

+ Action (hành động)
+ Adventure (phiêu lưu)
+ Sci-Fi (viễn tưởng)
+ Fantasy (giả tưởng)
+ Một số Animation ngân sách lớn

Nhận định đây là cụm rõ ràng nhất, đại diện cho:

+ Phim bom tấn Hollywood: Các phim dạng: Marvel, DC, Star Wars, Disney, Jurassic World, Transformers…
+ Những phim này có rating không phải luôn cao, nhưng ổn định vì lượng xem lớn, đầu tư mạnh, VFX tốt, nhiều chiến dịch marketing.

Cluster 2 - Phim thị trường mid-budget, rating trung bình-khá: Có thể thấy rõ sự khác biệt thông qua hình 29 dưới đây:



Hình 29: Biểu đồ residuals của cụm 2

Đặc trưng:

+ Ngân sách trung bình
+ Doanh thu trung bình, đôi khi cao
+ Popularity ổn nhưng không bùng nổ
+ Rating cao nhất trong cả ba cụm

Genre thường gặp

+ Drama(kịch) chất lượng, được đánh giá cao
+ Thriller(Giật gân), Mystery(bí ẩn), Crime(tội phạm), Biography(tiểu sử)
+ Phim nghệ thuật nhận đánh giá tốt từ giới phê bình

Nhận định đây là nhóm phim:

+ Không phải bom tấn nhưng làm rất tốt về nội dung
+ Được đánh giá cao nhờ kịch bản và diễn xuất
+ Đôi khi là phim thắng Oscar hoặc giải quốc tế

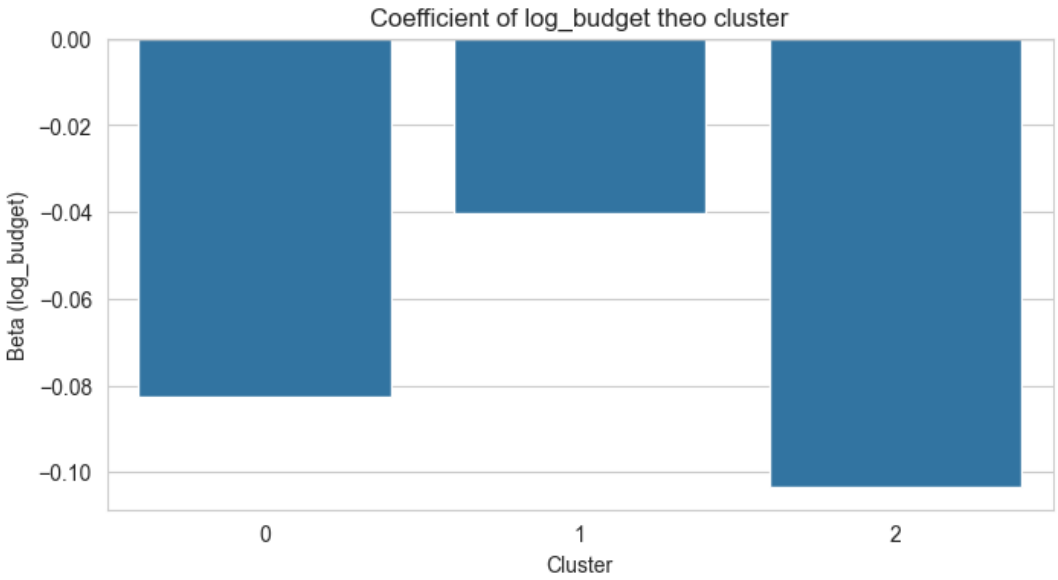
Kiểm định độ phù hợp mô hình qua Residuals

Biểu đồ residuals của từng cụm cho thấy:

- Phần dư phân bố quanh 0, không có xu hướng lệch hệ thống.
- Histogram residuals gần dạng phân phối chuẩn.

Điều này cho thấy kết luận về mối quan hệ âm giữa ngân sách và rating không phải là nhiễu ngẫu nhiên, mà phản ánh một xu hướng ổn định trong dữ liệu.

So sánh hệ số (coefficients) giữa các cụm, được trình bày ở hình 30:



Hình 30: So sánh hệ số coefficient của 3 cụm

Mỗi cluster sẽ có bảng model.summary() (từ statsmodels) gồm: hệ số (coef), độ lệch chuẩn, t-stat, p-value, R^2, adj. R^2.

Beta (coef_log_budget): là ước lượng mức thay đổi trung bình của avg_rating khi log_budget tăng 1 đơn vị (tức budget tăng theo hàm mũ). Nếu beta dương và p-value < 0.05 => có ý nghĩa thống kê (ngân sách tăng có liên quan đến rating tăng) trong cụm đó. Nếu p-value lớn => không đủ bằng chứng.

R^2: cho biết bao nhiêu phần trăm phương sai rating được giải thích bởi biến độc lập trong model (ví dụ chỉ log_budget thì thường thấp).

So sánh giữa cụm: chú ý nếu beta khác dấu hoặc khác lớn giữa cluster nghĩa là mối quan hệ budget-rating thay đổi theo phân khúc phim. Ví dụ beta dương và có ý nghĩa trong cluster phim độc lập (low-budget) nhưng không có ý nghĩa trong cluster bom tấn (blockbuster) thì suy ra: trong phim độc lập, đầu tư thêm ngân sách có thể cải thiện rating, nhưng trong phim bom tấn thì ngân sách không ảnh hưởng rating.

5. Phân tích hệ số, rút ra kết luận và trả lời câu hỏi

Biểu đồ hệ số được trình bày ở hình 30 cho thấy beta của log(budget) đều âm ở cả ba cụm, trong đó:

- Cụm 2 có hệ số âm lớn nhất → tác động tiêu cực của ngân sách cao đến rating rõ ràng nhất.
- Cụm 0 có hệ số âm ở mức trung bình.
- Cụm 1 có hệ số âm nhỏ nhất, cho thấy ngân sách cao gần như không còn ảnh hưởng đáng kể đến rating.

Về mặt định lượng, điều này khẳng định rằng sau một ngưỡng nhất định, việc tăng ngân sách mang lại hiệu quả biên rất thấp, thậm chí âm, đối với rating người dùng.

Trả lời câu hỏi phụ 2:

Việc tăng ngân sách sản xuất không luôn dẫn đến rating cao hơn. Ngược lại, dữ liệu cho thấy tồn tại rõ ràng hiện tượng "hiệu quả giảm dần" (diminishing returns). Các phim có ngân sách thấp đến trung bình thường đạt rating cao hơn so với nhiều phim ngân sách lớn, đặc biệt trong nhóm phim đại chúng.

Những "insight" đắt giá nhất mà dữ liệu đã kể cho chúng ta:

Ngân sách lớn ≠ chất lượng cảm nhận cao: Người dùng MovieLens đánh giá cao nội dung, câu chuyện và chiều sâu hơn là quy mô đầu tư tài chính.

Phim kinh phí vừa phải có lợi thế về rating: Đây thường là các phim tập trung vào kịch bản và nghệ thuật, phù hợp với thị hiếu đánh giá của người xem.

Ngân sách cao chủ yếu phục vụ doanh thu và độ phủ, chứ không phải để tối ưu điểm rating.

Kết quả phân tích cho thấy ngân sách sản xuất (budget) và doanh thu phòng vé (revenue) không có mối quan hệ tích cực rõ ràng với rating trung bình của phim do người dùng MovieLens đánh giá. Ngược lại, mối quan hệ này có xu hướng yếu và mang dấu âm nhẹ, đặc biệt khi xem xét ở cấp độ từng nhóm phim có đặc trưng tương đồng.

Cụ thể, phân tích tương quan Pearson trên dữ liệu cấp độ phim cho thấy cả budget và revenue đều có hệ số tương quan thấp với avg_rating, cho thấy yếu tố tài chính chỉ giải thích được một phần rất nhỏ sự biến thiên trong đánh giá người dùng. Điều này bác bỏ giả định trực giác rằng phim đầu tư nhiều tiền hoặc thu về doanh thu lớn sẽ luôn được đánh giá cao hơn.

Khi đi sâu hơn bằng phương pháp phân cụm K-Means, các phim được chia thành các nhóm có cấu trúc tài chính và đặc điểm nội dung khác nhau. Trong cả ba cụm, hồi quy tuyến tính giữa log(budget) và rating đều cho hệ số âm, cho thấy sau một ngưỡng nhất định, việc tăng ngân sách không giúp cải thiện rating, thậm chí còn làm giảm nhẹ điểm đánh giá trung bình. Hiện tượng này phản ánh rõ "hiệu quả giảm dần" của ngân sách đối với chất lượng cảm nhận của người xem.

Doanh thu phòng vé cũng thể hiện một xu hướng tương tự. Phim doanh thu cao thường là phim có độ phủ truyền thông lớn hoặc hướng đến thị trường đại chúng, nhưng điều đó không đồng nghĩa với việc được đánh giá cao hơn về mặt chất lượng. Rating trên MovieLens phản ánh đánh giá hậu nghiệm của người xem, trong khi doanh thu chủ yếu phản ánh mức độ tiếp cận và thành công thương mại.

II. Yếu tố nội dung (Thể loại, Độ dài phim)

1. Thể loại

Trong số các yếu tố có thể ảnh hưởng đến mức độ hài lòng của khán giả, thể loại phim (Genres) và thời lượng phim (Runtime) là hai yếu tố thường được quan tâm. Phần này tiến hành đánh giá xem liệu hai yếu tố này có tác động đáng kể đến điểm đánh giá trung bình (vote_average) của người xem hay không.

Mục tiêu của phân tích này là đánh giá xem các thể loại phim khác nhau có nhận được mức đánh giá trung bình (rating) khác nhau một cách đáng kể hay không. Đây là một câu hỏi quan trọng, bởi mỗi thể loại có thể thu hút nhóm khán giả riêng, dẫn đến mức độ hài lòng khác nhau.

Vì một bộ phim trong dữ liệu có thể thuộc nhiều thể loại cùng lúc (ví dụ: *Action | Adventure | Drama*), nên trước khi tiến hành phân tích, cần thực hiện thao tác tách (explode) cột *Genres*. Cách làm này giúp mỗi bộ phim-thể loại xuất hiện dưới dạng một dòng dữ liệu độc lập, từ đó ta có thể tính toán chính xác hơn mức rating trung bình cho từng thể loại.

	UserID	MovieID	Rating	Timestamp	Title	Genres	release_year	runtime	director	actor_1	actor_2	actor_3
0	1	1193	5	978300760	One Flew Over the Cuckoo's Nest (1975)	Drama	1975	133.0	Miloš Forman	Jack Nicholson	Louise Fletcher	Danny DeVito
1	1	914	3	978301968	My Fair Lady (1964)	Musical	1964	170.0	George Cukor	Audrey Hepburn	Rex Harrison	Stanley Holloway
1	1	914	3	978301968	My Fair Lady (1964)	Romance	1964	170.0	George Cukor	Audrey Hepburn	Rex Harrison	Stanley Holloway
2	1	3408	4	978300275	Erin Brockovich (2000)	Drama	2000	131.0	Steven Soderbergh	Julia Roberts	Albert Finney	Aaron Eckhart
3	1	1287	5	978302039	Ben-Hur (1959)	Action	1959	125.0	Timur Bekmambetov	Jack Huston	Toby Kebbell	Rodrigo Santoro
3	1	1287	5	978302039	Ben-Hur (1959)	Adventure	1959	125.0	Timur Bekmambetov	Jack Huston	Toby Kebbell	Rodrigo Santoro
3	1	1287	5	978302039	Ben-Hur (1959)	Drama	1959	125.0	Timur Bekmambetov	Jack Huston	Toby Kebbell	Rodrigo Santoro
4	1	594	4	978302268	Snow White and the Seven Dwarfs	Animation	1937	83.0	David Hand	Adriana Caselotti	Lucille La Verne	Harry Stockwell

Hình 31: Bộ dữ liệu sau khi tách các thể loại

Sau khi "bung" dữ liệu theo thể loại được trình bày rõ ở hình 31, ta tiến hành tính điểm rating trung bình cho từng nhóm thể loại, từ đó xác định thể loại nào được đánh giá cao hơn hoặc thấp hơn trong toàn bộ tập dữ liệu.

Sau khi tách dữ liệu để mỗi thể loại tương ứng với một dòng độc lập, bước tiếp theo là tiến hành tổng hợp thông tin và trực quan hóa kết quả. Đầu tiên, để đảm bảo tính tin cậy về mặt thống kê, chỉ những thể loại có ít nhất 10 bộ phim mới được giữ lại để phân tích. Điều này giúp loại bỏ những thể loại quá hiếm, vốn có thể gây sai lệch trong việc tính toán điểm trung bình.

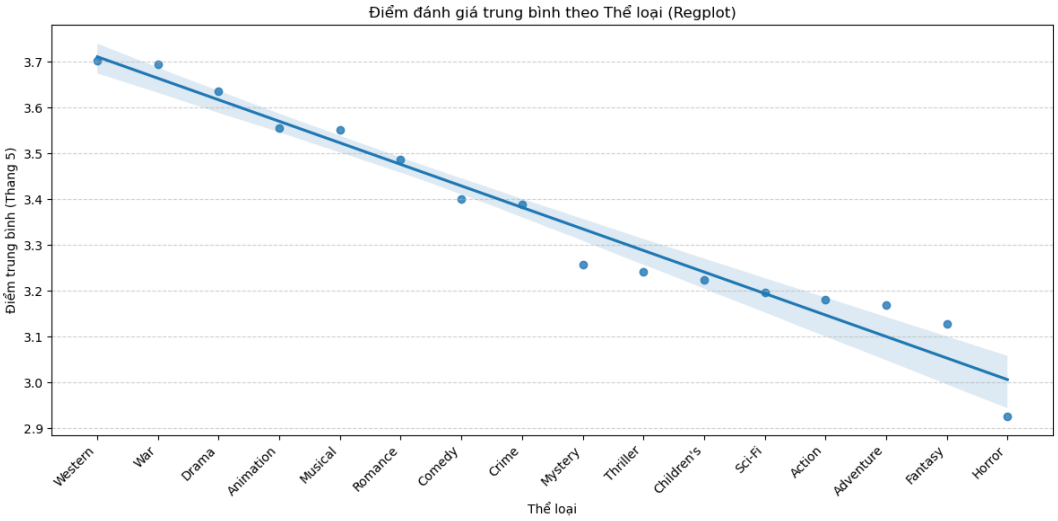
Tập dữ liệu sau khi lọc được sắp xếp theo điểm rating trung bình giảm dần, cho phép ta dễ dàng quan sát thể loại nào được đánh giá cao hơn.

Tiếp đó, các thể loại được ánh xạ sang một chỉ số dạng số thứ tự (Genre_Num). Việc chuyển đổi này giúp thuận tiện cho việc trực quan hóa bằng biểu đồ regplot, vốn yêu cầu trục x là dữ liệu số. Biểu đồ regplot cho phép hiển thị đồng thời các điểm dữ liệu và xu hướng tuyến tính, từ đó mang lại cái nhìn trực quan hơn về mức rating trung bình giữa các thể loại.

Trong biểu đồ, trục x biểu diễn từng thể loại, còn trục y thể hiện điểm rating trung bình (thang 5). Đường hồi quy được vẽ nhằm giúp nhận diện xu hướng chung

giữa các điểm dữ liệu. Ngoài ra, việc xoay nhãn thể loại giúp biểu đồ dễ đọc hơn, đặc biệt khi danh sách thể loại tương đối dài.

Cuối cùng, bảng kết quả thống kê bao gồm tên thể loại, rating trung bình, và số lượng phim được hiển thị. Từ bảng này, ta có thể nhận định rõ thể loại nào đang nhận được mức độ hài lòng cao nhất, cũng như những thể loại có mức đánh giá thấp hơn mặt bằng chung.



Hình 32: Biểu đồ đánh giá trung bình theo Thể loại

```
--- Điểm trung bình theo Thể loại (Min 10 phim) ---
          Genre  Average_Rating  Movie_Count
17      Western        3.702746           16
16          War        3.694930           35
7         Drama        3.636912          183
2     Animation        3.555775           26
11      Musical        3.550957           25
13      Romance        3.486773           87
4        Comedy        3.400093          186
5         Crime        3.389018           44
12      Mystery        3.256719           17
15     Thriller        3.242090          131
3    Children's        3.224632           46
14       Sci-Fi        3.195637           95
0        Action        3.181096          178
1     Adventure        3.169072           90
8       Fantasy        3.126819           22
10       Horror        2.925248           63
```

Hình 33: Điểm trung bình theo thể loại

Kết quả phân tích thông qua hình 32 và 33 cho thấy có sự khác biệt đáng kể giữa các thể loại phim về mức điểm đánh giá trung bình. Nhóm thể loại được đánh giá cao nhất gồm Western (3.70 điểm, 16 phim), War (3.69 điểm, 35 phim) và Drama (3.64 điểm, 183 phim). Đây đều là những thể loại có xu hướng khai thác chiều sâu cảm xúc, nội dung kịch tính hoặc giá trị nghệ thuật, nên nhận được mức độ hài lòng cao hơn từ khán giả.

Ngược lại, các thể loại có điểm trung bình thấp hơn bao gồm Horror (2.93 điểm, 63 phim), Fantasy (3.13 điểm, 22 phim), cùng các thể loại Action, Adventure và Sci-Fi với điểm trung bình dao động trong khoảng 3.17-3.19. Những thể loại này thường mang tính giải trí mạnh, chất lượng phim không đồng đều, hoặc dễ bị phân hóa trong đánh giá của người xem, dẫn đến điểm trung bình thấp hơn mặt bằng chung.

Về số lượng sản xuất, Drama (183 phim) và Comedy (186 phim) là hai thể loại phổ biến nhất trong dữ liệu. Điều này phản ánh xu hướng ưu tiên của các nhà làm phim, dù điểm đánh giá của chúng không nằm trong nhóm cao nhất.

Tổng thể, mức rating trung bình giữa các thể loại dao động từ khoảng 2.9 đến 3.7, cho thấy sự khác biệt khá rõ rệt.

Trong dữ liệu, mỗi thể loại có số lượng phim khác nhau, dẫn đến mức độ ổn định của điểm trung bình cũng khác nhau. Những thể loại có nhiều phim thường cho ra điểm trung bình đáng tin cậy hơn, trong khi các thể loại chỉ có ít phim rất dễ bị ảnh hưởng bởi các giá trị ngoại lệ. Vì vậy, khi tính điểm trung bình đại diện cho một bộ phim dựa trên danh sách thể loại mà nó thuộc về, việc sử dụng trọng số theo số lượng phim là cần thiết để phản ánh mức độ ổn định của từng thể loại.

Cách tiếp cận này sử dụng số lượng phim của mỗi thể loại (Movie_Count) làm trọng số. Điểm trung bình có trọng số (Weighted Average) của một bộ phim được tính bằng cách kết hợp điểm trung bình của từng thể loại mà phim đó thuộc về, với mức độ đóng góp của mỗi thể loại tỷ lệ với số lượng phim của thể loại đó.

Cụ thể, giả sử một bộ phim thuộc *k* thể loại. Với mỗi thể loại, ta có giá trị điểm trung bình và số lượng phim tương ứng. Điểm trung bình có trọng số của bộ phim được tính bằng tổng của tích giữa điểm trung bình của từng thể loại và trọng số số lượng phim, sau đó chia cho tổng các trọng số. Cách tính này giúp các thể loại phổ biến và ổn định hơn có ảnh hưởng lớn hơn, đồng thời giảm bớt tác động của những thể loại hiếm dễ gây sai lệch.

- Trọng số = số lượng phim trong thể loại (Movie_Count)
- Điểm trung bình Weighted Average (Movie_Score) được tính như sau:

$$\text{Movie_Score} = \frac{\sum_{i=1}^{n} \text{Average_Rating}(\text{Genre}_i) \times \text{Movie_Count}_i}{\sum_{i=1}^{n} \text{Movie_Count}_i}$$

Trong đó:

- (n): số lượng thể loại của phim
- $(\text{Average_Rating}(\text{Genres}_i))$: điểm trung bình của thể loại thứ (i)
- (Movie_Count_i): số lượng phim trong thể loại thứ (i)

Việc sử dụng trung bình có trọng số mang lại nhiều lợi ích khi phân tích mối quan hệ giữa thể loại và điểm đánh giá của phim. Trước hết, các thể loại sở hữu số lượng phim lớn sẽ có ảnh hưởng mạnh hơn đến điểm trung bình của một bộ phim.

Điều này giúp giảm thiểu tác động từ những thể loại chỉ có rất ít phim - vốn dễ bị chi phối bởi các giá trị quá cao hoặc quá thấp và có thể gây sai lệch khi tính toán.

Bên cạnh đó, phương pháp này giúp ước lượng mức rating kỳ vọng của một bộ phim dựa trên danh sách thể loại của nó một cách ổn định và chính xác hơn. Những thể loại phổ biến, có dữ liệu lớn, sẽ đóng vai trò định hướng chính trong việc phản ánh xu hướng đánh giá thực tế của khán giả.

Ngoài ý nghĩa mô tả, weighted average còn có giá trị ứng dụng cao trong mô hình hóa. Chỉ số này có thể được đưa vào như một đặc trưng quan trọng trong các mô hình dự đoán rating hoặc hệ thống gợi ý phim, giúp cải thiện khả năng dự đoán bằng cách bổ sung thông tin về mức độ tín nhiệm của từng thể loại.

Sau khi có điểm trung bình và số lượng phim của từng thể loại, dữ liệu phim-thể loại được gộp với bảng thống kê để mỗi dòng mang theo thông tin *Average_Rating* và *Movie_Count*.

Tiếp theo, với mỗi thể loại của một phim, ta tính giá trị trọng số bằng công thức:

$$\text{Weighted} = \text{Average_Rating} \times \text{Movie_Count}$$

Các giá trị này được cộng lại cho từng *MovieID*, rồi chia cho tổng *Movie_Count* của các thể loại mà phim thuộc về. Kết quả thu được chính là Weighted_Score - điểm trung bình có trọng số của bộ phim.

Cuối cùng, Weighted_Score được gộp trở lại bảng dữ liệu chính để sử dụng trong các bước phân tích hoặc mô hình dự đoán tiếp theo. Dữ liệu sau khi được tính toán Weight_Score được thể hiện chi tiết trong hình 34 dưới đây:

	MovieID	Title	Genres	Weighted_Score
0	1193	One Flew Over the Cuckoo's Nest (1975)	Drama	3.636912
1	914	My Fair Lady (1964)	Musical|Romance	3.501100
2	3408	Erin Brockovich (2000)	Drama	3.636912
3	1287	Ben-Hur (1959)	Action|Adventure|Drama	3.363651
4	594	Snow White and the Seven Dwarfs (1937)	Animation|Children's|Musical	3.397496
...	...	...	...	...
397970	2021	Dune (1984)	Fantasy|Sci-Fi	3.182697
397971	2028	Saving Private Ryan (1998)	Action|Drama|War	3.437153
397972	1089	Reservoir Dogs (1992)	Crime|Thriller	3.279032
397973	1090	Platoon (1986)	Drama|War	3.646227
397974	1097	E.T. the Extra-Terrestrial (1982)	Children's|Drama|Fantasy|Sci-Fi	3.428508

[397975 rows x 4 columns]

Hình 34: Bộ dữ liệu sau khi tính Weighted_Score

Mục tiêu của mô hình là dự đoán điểm đánh giá trung bình (*avg_rating*) của từng bộ phim dựa trên các yếu tố ảnh hưởng, trong đó *Weighted_Score* đóng vai trò là biến dự báo chính. Vì *avg_rating* là một giá trị liên tục trong thang điểm 0-5, đây là bài toán hồi quy.

Để xây dựng mô hình, Random Forest Regressor được lựa chọn nhờ khả năng xử lý quan hệ phi tuyến giữa các biến và mục tiêu, đặc biệt trong bối cảnh mối quan hệ giữa *Weighted_Score* và *avg_rating* không hoàn toàn tuyến tính. Thuật toán Random Forest cũng giúp giảm hiện tượng overfitting nhờ việc kết hợp nhiều cây quyết định thông qua kỹ thuật bagging, mang lại kết quả ổn định hơn so với mô hình cây đơn lẻ.

Bên cạnh đó, Random Forest không yêu cầu chuẩn hóa dữ liệu đầu vào, rất phù hợp với bộ dữ liệu gồm nhiều biến có đơn vị khác nhau như runtime, budget hay

Weighted_Score. Thuật toán cũng cung cấp chỉ số quan trọng của từng biến, cho phép đánh giá mức độ ảnh hưởng của các đặc trưng trong mô hình. Kết quả cho thấy Weighted_Score là biến quan trọng nhất, với giá trị quan trọng hóa lên đến 1.0.

Với quy mô dữ liệu lớn khoảng 900.000 dòng, Random Forest cho phép huấn luyện hiệu quả và ổn định, đặc biệt khi sử dụng đa luồng (*n_jobs = -1*). Mô hình được thiết lập với các tham số: *n_estimators = 200*, *max_depth = 10*, *random_state = 42*, và tập dữ liệu được chia theo tỷ lệ train-test là 80:20.

Dữ liệu sau khi được train, chi tiết thông qua hình 35 dưới đây:

```
MAE = 0.506
MSE = 0.399
RMSE = 0.632
          Feature  Importance
0  Weighted_Score         1.0
```

Hình 35: Dữ liệu sau khi được train

Dựa trên công thức tính RMSE (đo lường sai số trung bình căn bậc hai giữa giá trị thực tế và giá trị dự đoán):

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Trong đó:

- (n): số lượng quan sát (số phim)
- (y_i): giá trị thực tế của quan sát thứ (i) (ví dụ avg_rating)
- ($\hat{y}_i$):giá trị dự đoán của quan sát thứ (i)
- ($y_i - \hat{y}_i$): sai số (error) của quan sát thứ (i)

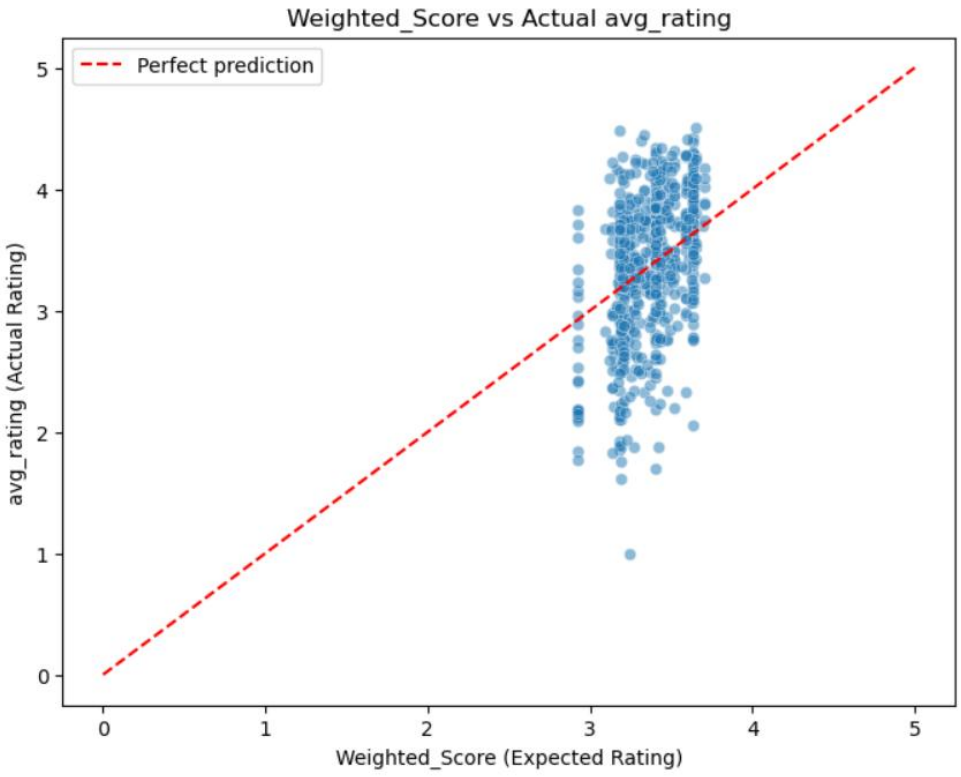
Ý nghĩa:

- RMSE có cùng đơn vị với giá trị target, nên dễ hiểu trực quan.
- RMSE càng nhỏ -> model dự đoán càng chính xác

Kết quả đánh giá mô hình cho thấy mức độ sai số tương đối thấp. Chỉ số MAE đạt 0.506, nghĩa là trung bình mỗi dự đoán lệch khoảng 0.5 điểm so với giá trị thực trên thang 0-5. Bên cạnh đó, MSE = 0.399 và RMSE = 0.632 cho thấy sai số bình phương trung bình không lớn, phản ánh mô hình dự đoán khá sát với thực tế.

Kết quả phân tích mức độ quan trọng của biến cho thấy *Weighted_Score* là đặc trưng duy nhất đóng vai trò quyết định trong mô hình, với giá trị quan trọng hóa đạt mức tối đa (1.0). Điều này cho thấy mô hình Random Forest gần như chỉ dựa vào thông tin về thể loại - đã được tổng hợp bằng trọng số - để đưa ra dự đoán. Các biến khác như *runtime*, *budget*, *revenue*, *vote_count* hay *release_year* cho thấy mức đóng góp không đáng kể trong thiết lập hiện tại, nhưng vẫn có thể được thêm vào để cải thiện độ chính xác nếu cần.

Weighted_Score hoạt động hiệu quả bởi nó đã phản ánh kỳ vọng rating dựa trên các thể loại mà bộ phim thuộc về, giúp dự đoán gần sát giá trị thực mà không cần nhiều biến bổ sung. Random Forest cũng nhanh chóng nhận ra điều này và phân bổ toàn bộ mức độ quan trọng vào biến này. Điều này có thể thấy rõ dựa vào biểu đồ phân bố Weighted_Score và Rating ở hình 36 dưới đây:



Hình 36: Biểu đồ phân bố Weighted_Score và rating

2. Thời lượng phim

Để đánh giá xem độ dài phim có tác động đến mức độ hài lòng của khán giả hay không, ta tiến hành phân tích mối quan hệ giữa *runtime* và *rating trung bình* bằng cách sử dụng hệ số tương quan Pearson. Chỉ số này cho biết mức độ liên hệ tuyến tính giữa hai biến, giúp xác định xem các phim dài hơn có xu hướng được đánh giá cao hơn, hay ngược lại, liệu độ dài phim có ít ảnh hưởng đến cảm nhận của người xem.

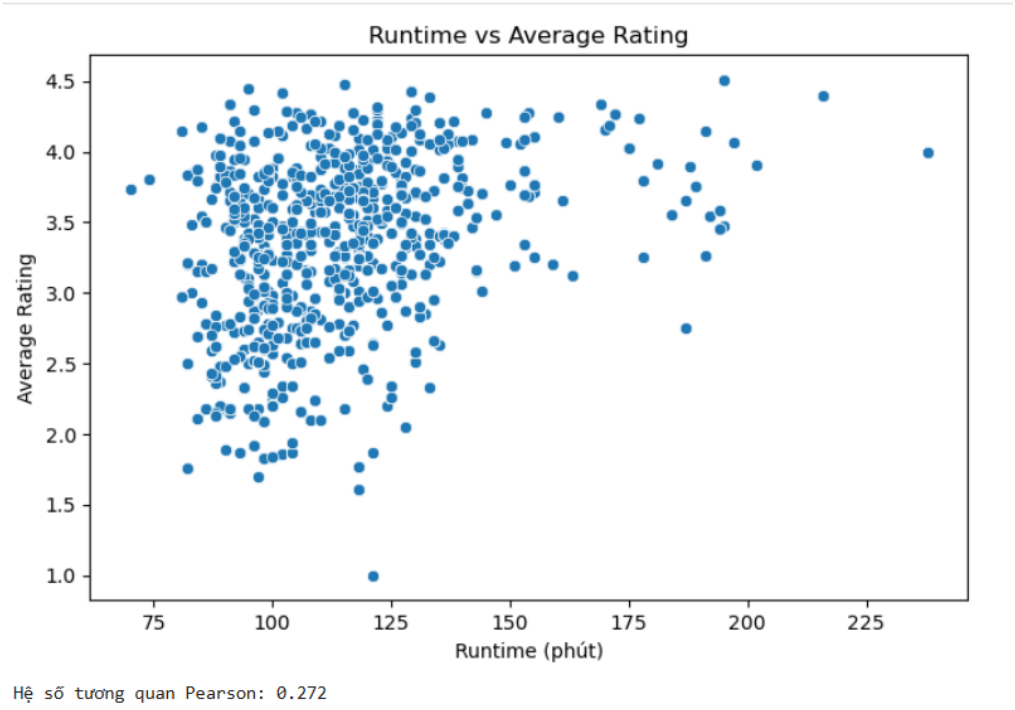
- Công thức:

$$r_{XY} = \frac{\sum_{i=1}^{n}(X_i - \overline{\mathrm{X}})(\mathrm{Y}_i - \overline{\mathrm{Y}})}{\sqrt{\sum_{\mathrm{i}=1}^{\mathrm{N}}(X_i - \overline{\mathrm{X}})^2}\sqrt{\sum_{\mathrm{i}=1}^{\mathrm{N}}(\mathrm{Y}_i - \overline{\mathrm{Y}})^2}}$$

Trong đó:

- (X_i) là giá trị runtime của phim thứ i
- (Y_i) là ratring trung bình của phim thứ i
- $(\overline{\mathrm{X}})$ và $(\overline{\mathrm{Y}})$Là giá trị trung bình của runtime và rating
- Giá r nằm trong khoảng [-1, 1]:
    - r > 0 -> runtime tăng, rating có xu hướng tăng (mối quan hệ thuận)
    - r < 0 -> runtime tăng, rating có xu hướng tăng (mối quan hệ nghịch)
    - r ≈ 0 -> không có xu hướng rõ ràng

Để quan sát trực quan mối quan hệ giữa độ dài phim và rating trung bình, biểu đồ phân tán (scatter plot) được sử dụng nhằm thể hiện cách hai biến này thay đổi theo nhau. Biểu đồ giúp nhận diện xu hướng tổng quát: liệu các phim có thời lượng dài hơn thường được đánh giá cao hơn hay không, hay mối quan hệ giữa hai biến là rất yếu hoặc không tồn tại. Đây là bước trực quan hóa quan trọng trước khi phân tích định lượng bằng hệ số tương quan Pearson.



Hình 37: Biểu đồ tương quan giữa runtime và rating

Kết quả phân tích ở hình 37 cho thấy hệ số tương quan Pearson giữa *runtime* và *avg_rating* đạt r = 0.272. Vì giá trị r dương, các phim có thời lượng dài hơn nhìn chung có xu hướng nhận được đánh giá cao hơn. Tuy nhiên, mức tương quan này vẫn khá thấp (r < 0.3), cho thấy độ dài phim chỉ giải thích được một phần nhỏ sự biến động trong điểm rating.

Quan sát từ biểu đồ scatter cũng phản ánh điều này: vẫn tồn tại nhiều phim ngắn đạt điểm cao, đồng thời không ít phim có thời lượng dài nhưng lại bị đánh giá thấp. Điều này cho thấy rating còn chịu ảnh hưởng bởi nhiều yếu tố khác như thể loại, chất lượng kịch bản, đạo diễn, diễn xuất hay mức đầu tư sản xuất.

Để đánh giá mức độ ảnh hưởng của độ dài phim (runtime) đến rating trung bình, ta sử dụng mô hình *Linear Regression* với runtime là biến độc lập và rating là biến phụ thuộc.

Để đánh giá mức độ ảnh hưởng của thời lượng phim đến mức độ hài lòng của khán giả, nghiên cứu trước hết xem xét mối quan hệ tuyến tính giữa *runtime* và *rating trung bình*. Kết quả phân tích tương quan Pearson cho thấy hệ số r đạt 0.272, tức hai biến có mối quan hệ thuận nhưng khá yếu. Điều này hàm ý rằng các bộ phim

có thời lượng dài hơn thường có xu hướng nhận được mức đánh giá cao hơn, tuy nhiên mức độ liên hệ không đủ mạnh để xem runtime là yếu tố quyết định.

Tiếp theo, mô hình hồi quy tuyến tính được sử dụng nhằm định lượng cụ thể tác động của thời lượng phim. Hệ số hồi quy thu được là 0.006, nghĩa là khi thời lượng phim tăng thêm 1 phút, điểm rating trung bình tăng khoảng 0.006 điểm trên thang đo 0-5. Nói cách khác, nếu hai bộ phim chênh lệch nhau 100 phút thời lượng, thì bộ phim dài hơn dự kiến có thể đạt mức rating cao hơn khoảng 0.6 điểm, nếu chỉ xét riêng ảnh hưởng của runtime. Tuy vậy, con số này vẫn được xem là nhỏ khi đặt trong bối cảnh toàn bộ thang điểm và sự đa dạng lớn về mức đánh giá của khán giả.

Tổng hợp kết quả từ cả tương quan và hồi quy cho thấy mặc dù độ dài phim có tác động tích cực đến rating, mức độ ảnh hưởng này không mạnh. Runtime chỉ giải thích một phần nhỏ sự thay đổi của đánh giá và không đủ để dự đoán mức độ hài lòng của khán giả một cách độc lập. Điều đó cho thấy các yếu tố khác như thể loại, nội dung kịch bản, diễn xuất, chất lượng sản xuất hay mức độ phổ biến của phim có vai trò quan trọng hơn nhiều trong việc hình thành nhận định của người xem.

Bên cạnh việc đánh giá mối quan hệ liên tục giữa thời lượng và rating, nghiên cứu tiếp tục phân tích theo nhóm độ dài phim nhằm quan sát sự thay đổi trung bình một cách rõ ràng hơn. Dữ liệu được chia thành bốn nhóm: *Ngắn*, *Vừa*, *Dài* và *Rất dài*. Kết quả cho thấy sự khác biệt tương đối rõ rệt giữa các nhóm khi xét về điểm đánh giá trung bình của khán giả.

Dữ liệu phân nhóm theo độ dài phim (`length_group`) và rating trung bình:

Nhóm độ dài	Rating trung bình
Ngắn	3.54
Vừa	3.50
Dài	3.72
Rất dài	3.94

Các phim thuộc nhóm *Ngắn* và *Vừa* có mức rating trung bình khoảng 3.50-3.54, thể hiện mức độ hài lòng ở mức trung bình. Trong khi đó, nhóm *Dài* và đặc biệt là *Rất dài* đạt mức rating cao hơn đáng kể, lần lượt khoảng 3.72 và 3.94. Sự chênh lệch này cho thấy một xu hướng nhất quán: các bộ phim có thời lượng dài hơn thường được khán giả đánh giá tích cực hơn.

Khoảng cách từ khoảng 3.50 của nhóm phim *Ngắn/Vừa* đến 3.94 của nhóm *Rất dài* tương ứng mức tăng khoảng 0.44 điểm trên thang 0-5. Khi kết hợp với kết quả hồi quy trước đó (hệ số 0.006 điểm cho mỗi phút phim), có thể thấy tác động của từng phút thời lượng là khá nhỏ, nhưng khi gộp lại theo nhóm độ dài, sự khác biệt tổng thể trở nên rõ rệt hơn. Điều này phản ánh rằng các phim có thời lượng dài thường có xu hướng đầu tư hơn về nội dung, tuyến truyện hoặc chiều sâu cảm xúc, từ đó nhận được đánh giá cao hơn từ người xem.

Tuy nhiên, tương tự các phân tích trước, runtime vẫn không phải là yếu tố quyết định duy nhất. Sự khác biệt giữa các nhóm độ dài cho thấy một xu hướng hợp lý, nhưng các yếu tố khác như thể loại, chất lượng kịch bản, mức độ đầu tư sản xuất, diễn viên và đạo diễn vẫn đóng vai trò quan trọng hơn trong việc định hình mức độ hài lòng của khán giả.

III. Yếu tố nhân sự & thời gian (Cast/Crew, Year)

Vai trò của Đạo diễn/diễn viên có tên tuổi lớn có tương quan mạnh mẽ với rating người dùng cao hơn không? Năm sản xuất (phim cũ/mới) có ảnh hưởng đến rating trung bình không?

+ Liệu một diễn viên ngôi sao có thể "gánh" được một đạo diễn tồi? Hay một đạo diễn tài năng có thể biến diễn viên vô danh thành sao?

+ Phim này có phải là một món hời (Bứt phá) hay là một cú lừa (Sa sút)?

- Input: director_power, actor_power, release_year.

- Output: cột Rating thực tế.

Dữ liệu: Sử dụng kỹ thuật Target Encoding để chuyển đổi dữ liệu định danh (tên người) thành dữ liệu định lượng (điểm số lịch sử), đại diện cho "Sức hút thương hiệu" (Star Power).

Mô hình: Sử dụng XGBoost Regressor, một mô hình phi tuyến tính mạnh mẽ để nắm bắt các mối quan hệ phức tạp giữa nhân sự, thời gian và chất lượng phim.

Phân tích: Áp dụng phương pháp SHAP (Shapley Additive exPlanations) để bóc tách mức độ đóng góp của từng yếu tố, giúp trả lời câu hỏi liệu "Tên tuổi lớn" có thực sự là nguyên nhân trực tiếp dẫn đến "Rating cao" hay không.



Hình 38: Quy trình thực hiện đánh giá dựa trên yếu tố đạo diễn, diễn viên

1. Số hóa sức mạnh nhân sự

Công thức:

$$P_D = \frac{\sum_{i=1}^{n} r_i}{n}$$

Trong đó:

- P_D: Chỉ số sức mạnh (Power) của Đạo diễn/ Diễn viên D (Giá trị sau khi mã hóa)
- r_i: Điểm Rating thực tế của bộ phim thứ i mà người đó tham gia
- n: Tổng số lượng phim mà người đó đã tham gia trong tập dữ liệu huấn luyện

2. Huấn luyện XGBoost Regressor

XGBoost Regressor là một mô hình phi tuyến tính mạnh mẽ để nắm bắt các mối quan hệ phức tạp giữa nhân sự, thời gian và chất lượng phim.

a. Công thức Dự đoán (Additive Prediction): Dựa đoán cuối cùng là tổng hợp kết quả của K cây quyết định (Decision Trees).

$$\hat{y}_i = \sum_{k=1}^{K} f_k(x_i), \qquad f_k \in F$$

Trong đó:

- $\hat{y}_i$: Điểm Rating dự đoán cho bộ phim i
- K: Tổng số lượng cây quyết định (trong code là n_estimators)
- $f_k(x_i)$: Điểm số dự đoán của cây thứ k dựa trên đặc trưng đầu vào x_i (Budget, Director Power, Year…)
- F: Không gian chứa tất cả các cây quyết định có thể

b. Hàm mục tiêu (Objective Function): XGBoost tối ưu hóa hàm này để giảm sai số và tránh Overfitting.

$$L(\emptyset) = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k)$$

Trong đó:

- $l(y_i, \hat{y}_i)$: Hàm mất mát (Loss function), thường là Sai số bình phương (MSE) để đo sự chênh lệch giữa Rating thực tế và dự đoán
- $\Omega(f_k)$: Số hạng điều chuẩn (Regularization term). Nó phạt các cây quá phức tạp để mô hình không bị học vẹt (Overfitting)

3. Phân tích SHAP

SHAP (SHapley Additive exPlanations) là một kỹ thuật xuất phát từ Lý thuyết Trò chơi (Game Theory), dùng để giải thích các mô hình "hộp đen" phức tạp như XGBoost.

SHAP có nhiệm vụ chia nhỏ kết quả dự đoán (Rating) thành các phần đóng góp công bằng của từng yếu tố (Đạo diễn, Diễn viên, Tiền...), giúp chúng ta hiểu được mô hình đang "nghĩ" gì.

Giá trị SHAP($\emptyset_i$) của một đặc trưng j (ví dụ: director_power) được tính bằng:

$$\emptyset_j(val) = \sum_{S \in \{x_i,\dots,x_p\} \setminus \{x_i\}} \frac{|S|!\,(p - |S| - 1)!}{p!} (val(S \cup \{x_i\}) - val(S))$$

4. Vẽ biểu đồ (SHAP Dependence Plots)

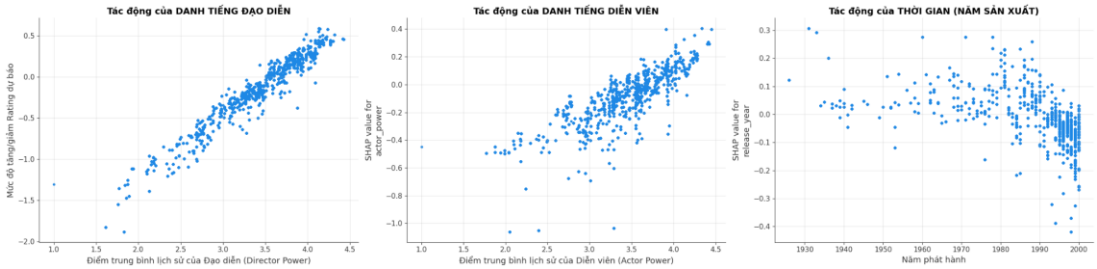
Trục Hoành (X-axis): Giá trị thực tế của dữ liệu (Ví dụ: Điểm lịch sử của Đạo diễn là 3.0 hay 4.0).

Trục Tung (Y-axis - SHAP value): Mức độ tác động lên điểm Rating dự đoán.

- Giá trị > 0: Yếu tố này giúp Cộng điểm cho phim (Kéo Rating lên).

- Giá trị < 0: Yếu tố này làm Trừ điểm phim (Kéo Rating xuống).
- Giá trị = 0: Không ảnh hưởng.

Có thể kiểm tra thông qua 3 biểu đồ được trình bày ở hình 38:



Hình 39: Biểu đồ Phụ thuộc SHAP (SHAP Dependence Plot)

Biểu đồ 1: Ảnh hưởng của Danh tiếng Đạo diễn (Director Power)

Biểu đồ bên trái cho thấy một xu hướng tăng rất rõ ràng, gần như tuyến tính. Khi năng lực hoặc danh tiếng của đạo diễn tăng, điểm số dự đoán của bộ phim (thông qua SHAP value) cũng tăng mạnh theo. Đường xu hướng dốc và chặt chẽ cho thấy mối quan hệ rất bền vững: nếu đạo diễn có mức Power thấp khoảng 2.0, bộ phim có xu hướng bị trừ đến khoảng −1.5 điểm. Ngược lại, khi đạo diễn có chuyên môn cao (Power xấp xỉ 4.0), bộ phim nhận thêm khoảng +0.5 điểm. Điều này chứng minh rằng đạo diễn đóng vai trò then chốt trong chất lượng cuối cùng của một bộ phim. Một đạo diễn yếu kém gần như chắc chắn sẽ kéo điểm phim xuống đáng kể.

Biểu đồ 2: Ảnh hưởng của Danh tiếng Diễn viên (Actor Power)

Biểu đồ ở giữa cũng cho thấy một xu hướng tăng, tuy nhiên độ dốc thấp hơn và dữ liệu phân tán rộng hơn so với đạo diễn. Nghĩa là diễn viên có danh tiếng cao vẫn mang lại giá trị tích cực cho điểm phim, nhưng hiệu ứng này không mạnh và không ổn định như đạo diễn. Biên độ tác động của diễn viên chỉ dao động khoảng từ -0.6 đến +0.4. Sự phân tán dọc tại cùng một mức Power phản ánh thực tế: dù có những diễn viên được đánh giá cao, nhưng không phải phim nào họ tham gia cũng tốt. Vai trò của diễn viên mang tính hỗ trợ nhưng không phải yếu tố quyết định tuyệt đối.

Biểu đồ 3: Ảnh hưởng của Thời gian (Release Year)

Biểu đồ bên phải thể hiện một xu hướng giảm tương đối rõ ràng: phim càng sản xuất về các năm gần đây thì tác động tới điểm cuối càng có xu hướng âm. Các tác phẩm trước những năm 1980 thường có SHAP value > 0, nghĩa là được cộng điểm

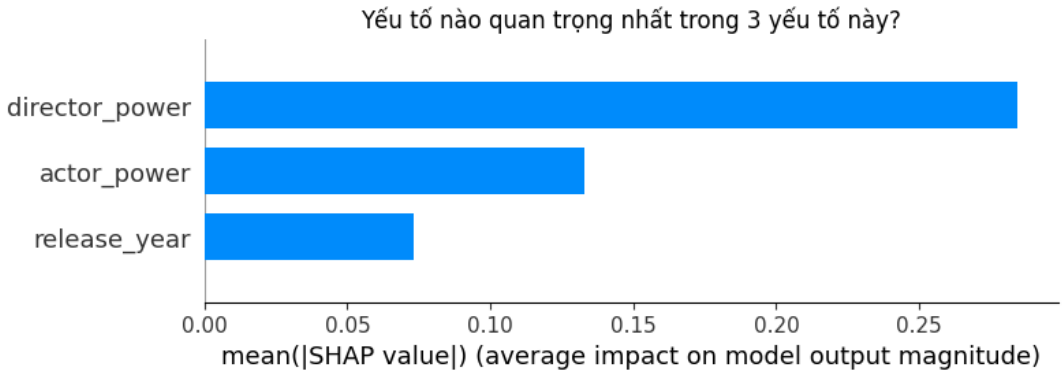
- đây có thể xem là hiệu ứng ưu ái đối với phim cổ điển. Ngược lại, các phim từ giai đoạn 1990-2000 lại dần bị trừ điểm. Điều này cho thấy tâm lý khắt khe với phim hiện đại: một bộ phim mới có thể bị hụt từ -0.1 đến -0.2 điểm so với phim ra mắt ở giai đoạn cũ, ngay cả khi chất lượng tương đương.

Kết luận:

- Đạo diễn là yếu tố ảnh hưởng mạnh nhất.
- Diễn viên tác động tích cực nhưng không ổn định.
- Năm sản xuất thể hiện xu hướng thiên vị cho phim cổ điển.

5. Tầm quan trọng

Để xác định được các yếu tố quan trọng nhất trong 3 yếu tố: Director Power, Actor Power và Release Year. Ta có thể thấy rõ thông qua hình 39:



Hình 40: Biểu đồ So sánh mức độ ảnh hưởng của Director Power, Actor Power và Release Year

5.1. Sự thống trị tuyệt đối của Đạo diễn

Các giá trị SHAP cho thấy director_power có mức độ ảnh hưởng vượt trội so với các biến còn lại, đạt khoảng 0.28 — gấp hơn 2,5 lần so với diễn viên và khoảng 5 lần so với năm sản xuất. Kết quả này phản ánh rất đúng bản chất điện ảnh: đạo diễn chính là người định hình chất lượng cuối cùng của bộ phim. Một kịch bản tốt đi kèm đạo diễn yếu có thể trở thành thất bại, trong khi một đạo diễn tài năng vẫn có thể biến các nguồn lực bình thường thành một sản phẩm chất lượng. Vì vậy, trong mô hình dự đoán điểm số, chỉ cần biết ai là đạo diễn đã giúp nâng độ chính xác đáng kể.

5.2. Vai trò thứ cấp của Diễn viên

Biến actor_power đứng thứ hai với giá trị khoảng 0.12, cho thấy diễn viên nổi tiếng vẫn góp phần nâng điểm phim nhưng không phải yếu tố mang tính quyết định. Nhiều trường hợp phim sở hữu dàn sao lớn nhưng vẫn nhận đánh giá kém khi thiếu sự dẫn dắt tốt từ đạo diễn. Điều này hàm ý rằng diễn viên là yếu tố quan trọng nhưng chỉ mang tính bổ trợ. Khi đạo diễn mạnh, giá trị của diễn viên mới được phát huy trọn vẹn.

5.3. Ảnh hưởng nhỏ hơn từ Thời gian sản xuất

Release_year thể hiện mức độ ảnh hưởng thấp nhất, khoảng 0.05. Mặc dù ở biểu đồ xu hướng trước đó, năm sản xuất có chiều hướng làm giảm điểm phim (đặc biệt ở giai đoạn phim mới), nhưng tác động trung bình chỉ khoảng -0.1 đến -0.2 điểm. So với mức biến động có thể lên tới -1.5 hoặc +0.5 từ đạo diễn, yếu tố thời gian chỉ đóng vai trò điều chỉnh nhỏ. Có thể xem yếu tố năm sản xuất giống như gia vị bổ sung - làm thay đổi nhẹ cảm nhận, nhưng không quyết định chất lượng tổng thể.

Biểu đồ SHAP cho thấy chất lượng phim phụ thuộc chủ yếu vào năng lực đội ngũ sản xuất, đặc biệt là Đạo diễn. Yếu tố thời gian và danh tiếng diễn viên chỉ đóng vai trò bổ trợ.

6. Các phân tích liên quan

6.1. Phân tích "Ma trận Cộng hưởng": Đạo diễn giỏi + Diễn viên giỏi = ?

Phân tích ma trận cộng hưởng cho thấy đạo diễn là yếu tố nền tảng, mang tính quyết định. Vậy, thay vì xem xét riêng lẻ, hãy xem xét sự kết hợp. Liệu một diễn viên ngôi sao có thể "gánh" được một đạo diễn tồi? Hay một đạo diễn tài năng có thể biến diễn viên vô danh thành sao?

a. Phân nhóm theo Phân vị (Quantile Binning)

Thay vì giữ các con số lẻ tẻ (ví dụ: Director Power = 3.45, 4.12...), phương pháp này ép dữ liệu vào 4 giỏ (buckets): Thấp - Trung bình - Cao - Huyền thoại.

Dùng qcut mà thay vì cut:

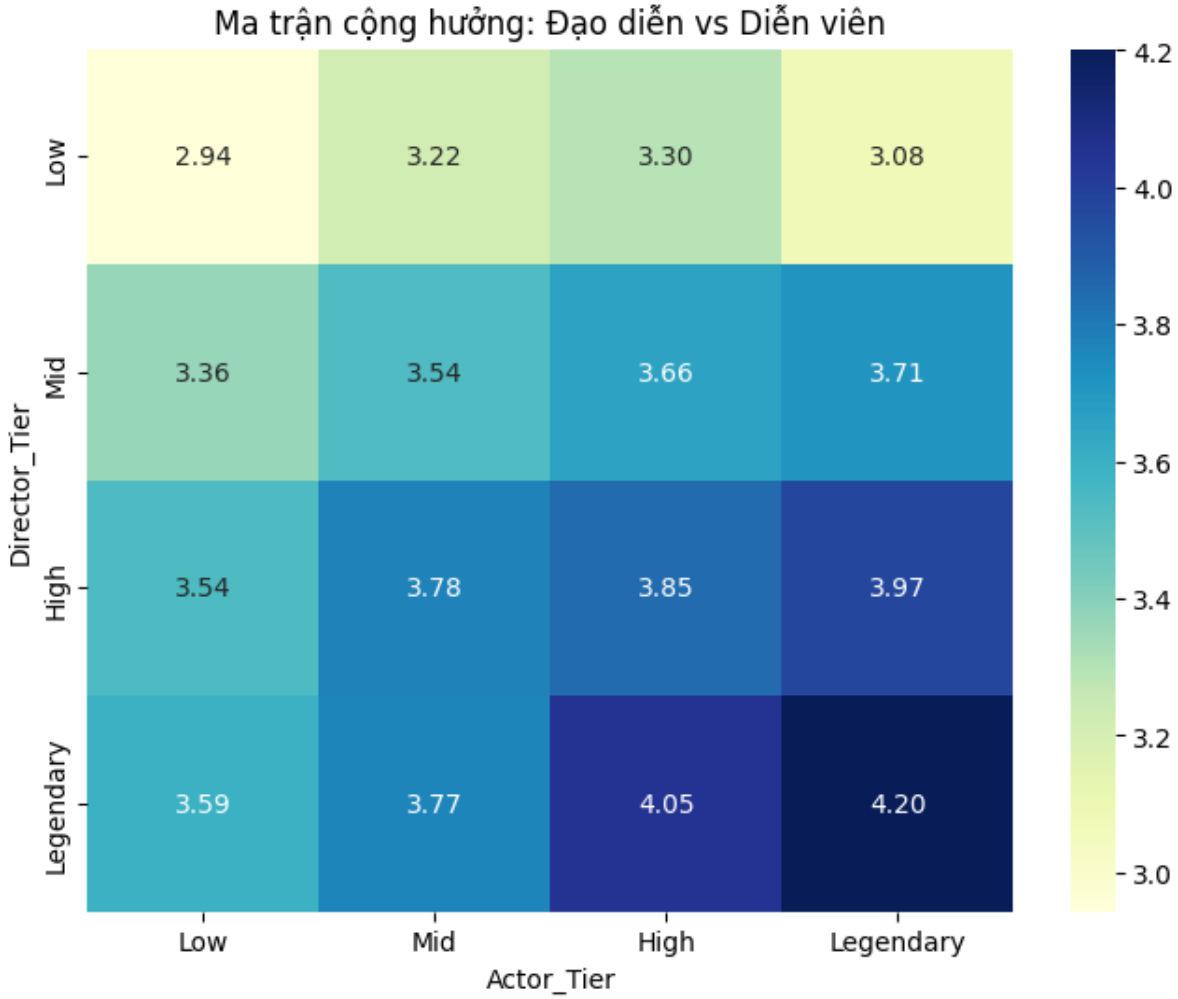
+ qcut chia dựa trên số lượng (Quantile). Nó đảm bảo nhóm "Low", "Mid", "High", “Legendary” có số lượng phim bằng nhau.

+ Điều này giúp tránh việc một nhóm nào đó quá ít dữ liệu (ví dụ nhóm "High" chỉ có 2 phim) làm sai lệch kết quả trung bình.

b. Kỹ thuật Bảng chéo (Cross-Tabulation / Pivot Table)

Nguyên lý: Đây là kỹ thuật tạo Ma trận (Matrix). Nó tạo ra một lưới 4x4 (16 ô).

Mục đích: Để xem xét sự giao thoa giữa hai yếu tố. Ví dụ: Tại ô giao nhau giữa Đạo diễn Thấp và Diễn viên Cao, điểm trung bình là bao nhiêu?



Hình 41: Ma trận cộng hưởng: Đạo diễn và diễn viên

Biểu đồ Ma trận cộng hưởng: Đạo diễn và diễn viên được trình bày ở hình 40 cho thấy đạo diễn nắm vai trò chủ đạo, là người kiến tạo. Một đạo diễn thuộc nhóm High-tier đảm bảo cho bộ phim mức điểm sàn (floor) là 3.62 ngay cả khi không có ngôi sao. Ngược lại, một diễn viên High-tier dù nỗ lực

đến đâu cũng chỉ có thể kéo bộ phim của đạo diễn Low-tier lên mức 3.41 (vẫn dưới trung bình).

Kết quả cho thấy vai trò quyết định thuộc về đạo diễn. Một đạo diễn nhóm High vẫn đạt điểm 3.54 khi làm việc với diễn viên Low, cao hơn rõ rệt so với trường hợp đạo diễn Low kết hợp với diễn viên High (3.30). Ở mức cực đoan hơn, đạo diễn Legendary có thể kéo dàn diễn viên Low lên mức 3.59, trong khi diễn viên Legendary lại không thể cứu vãn phim do đạo diễn Low, với điểm chỉ 3.08. Điều này khẳng định đạo diễn là người định hình trần và sàn chất lượng của bộ phim.

Khi đạo diễn thuộc nhóm Low, diễn viên giỏi chỉ cải thiện điểm số ở mức hạn chế, từ 2.94 lên tối đa 3.30. Đáng chú ý, sự kết hợp giữa đạo diễn Low và diễn viên Legendary thậm chí còn cho điểm thấp hơn (3.08), cho thấy ngôi sao không phải "thuốc tiên". Kỳ vọng quá cao hoặc sự lệch pha sáng tạo có thể khiến phim bị đánh giá khắt khe hơn; diễn viên chỉ thực sự phát huy tối đa khi có đạo diễn từ mức High trở lên.

Sự cộng hưởng mạnh nhất xuất hiện khi Đạo diễn Legendary kết hợp với Diễn viên Legendary, đạt điểm 4.20 - mức cao nhất. So với trường hợp thấp nhất (Low/Low = 2.94), chất lượng được nâng lên 1.26 điểm, một khoảng cách rất lớn trên thang 5 sao. Các mức 4.05 và 4.20 cho thấy để chạm ngưỡng "siêu phẩm" (>4.0), đạo diễn huyền thoại là điều kiện bắt buộc, còn diễn viên tài năng là yếu tố giúp tối ưu hóa chất lượng.

6.2. Phân tích "Ngoại lệ" (Outlier Analysis)

Chúng ta sẽ đi vào tìm hiểu 2 nhóm chính để trả lời cho câu hỏi: "Bộ phim nào có chất lượng sai lệch nhiều nhất so với thương hiệu của người tạo ra nó?"

A. Nhóm "Sa sút"

Đây là những trường hợp đạo diễn nổi tiếng, tay nghề cao nhưng bộ phim lại bị chấm điểm thấp. Điều này có thể xảy ra khi họ làm phim không đúng sở trường, bị can thiệp bởi nhà sản xuất, hoặc đơn giản là phong độ đi xuống. Nhóm này cho thấy: đạo diễn giỏi cũng có lúc làm ra phim dở.

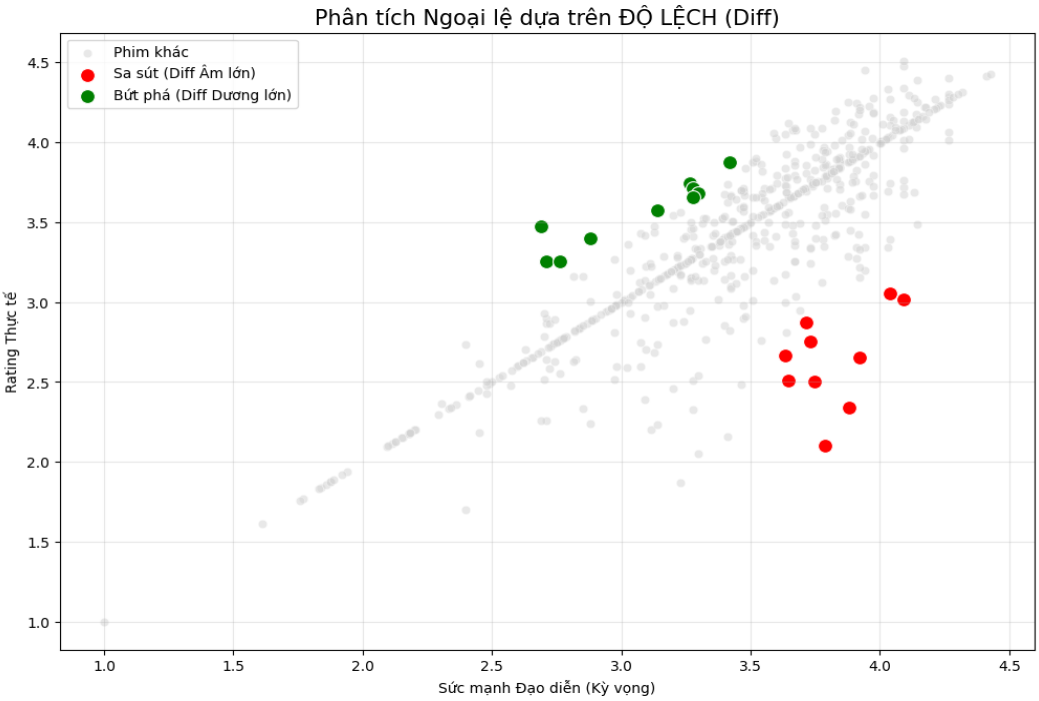
B. Nhóm "Bứt phá"

Nhóm này gồm những đạo diễn ít tiếng tăm hoặc mới vào nghề, những tác phẩm lại được đánh giá rất cao. Đây thường là những phim có kịch bản xuất sắc, ý tưởng độc đáo hoặc là cú "bật lên" hiếm có của một người mới. Điều này khẳng định: không cần nổi tiếng, chỉ cần nội dung hay vẫn có thể tạo nên siêu phẩm. Dưới đây là hình 41 mô tả kết quả top 10 bộ phim cho từng loại

```
=== TOP 10 SA SÚT (Gây thất vọng nhất) ===
                    Title         director  avg_rating  director_power      Diff
          Fair Game (1995)       Doug Liman    2.104167        3.786935 -1.682769
       Mary Reilly (1996)    Stephen Frears    2.340909        3.880931 -1.540022
           Psycho (1998) Alfred Hitchcock    2.651515        3.921470 -1.269955
Beverly Hills Cop III (1994)      John Landis    2.505682        3.747289 -1.241608
  Last Action Hero (1993)    John McTiernan    2.508000        3.647550 -1.139550
            Hook (1991) Steven Spielberg    3.018006        4.091758 -1.073752
        G.I. Jane (1997)     Ridley Scott    3.052065        4.037769 -0.985704
 Death Becomes Her (1992)   Robert Zemeckis    2.752212        3.728823 -0.976610
          Sphere (1998)    Barry Levinson    2.663586        3.634777 -0.971191
   Renaissance Man (1994)    Penny Marshall    2.870968        3.715354 -0.844386

=== TOP 10 BỨT PHÁ (Gây bất ngờ nhất) ===
              Title          director  avg_rating  director_power     Diff
 Get Carter (1971)     Stephen T. Kay    3.472727        2.690323 0.782405
 Flatliners (1990)    Joel Schumacher    3.254237        2.708747 0.545491
      Alive (1993)     Frank Marshall    3.401639        2.878590 0.523049
Blue Streak (1999)       Les Mayfield    3.257812        2.762791 0.495022
Hang 'em High (1967)          Ted Post    3.746888        3.264026 0.482862
 Tombstone (1993) George P. Cosmatos    3.873418        3.419322 0.454096
     Scream (1996)         Wes Craven    3.575621        3.138017 0.437604
  Halloween (1978)     John Carpenter    3.713439        3.277652 0.435786
Total Recall (1990)      Paul Verhoeven    3.682365        3.297276 0.385089
Out of Africa (1985)     Sydney Pollack    3.653355        3.275114 0.378240
```

Hình 42: Kết quả Top 10 bộ phim cho từng loại



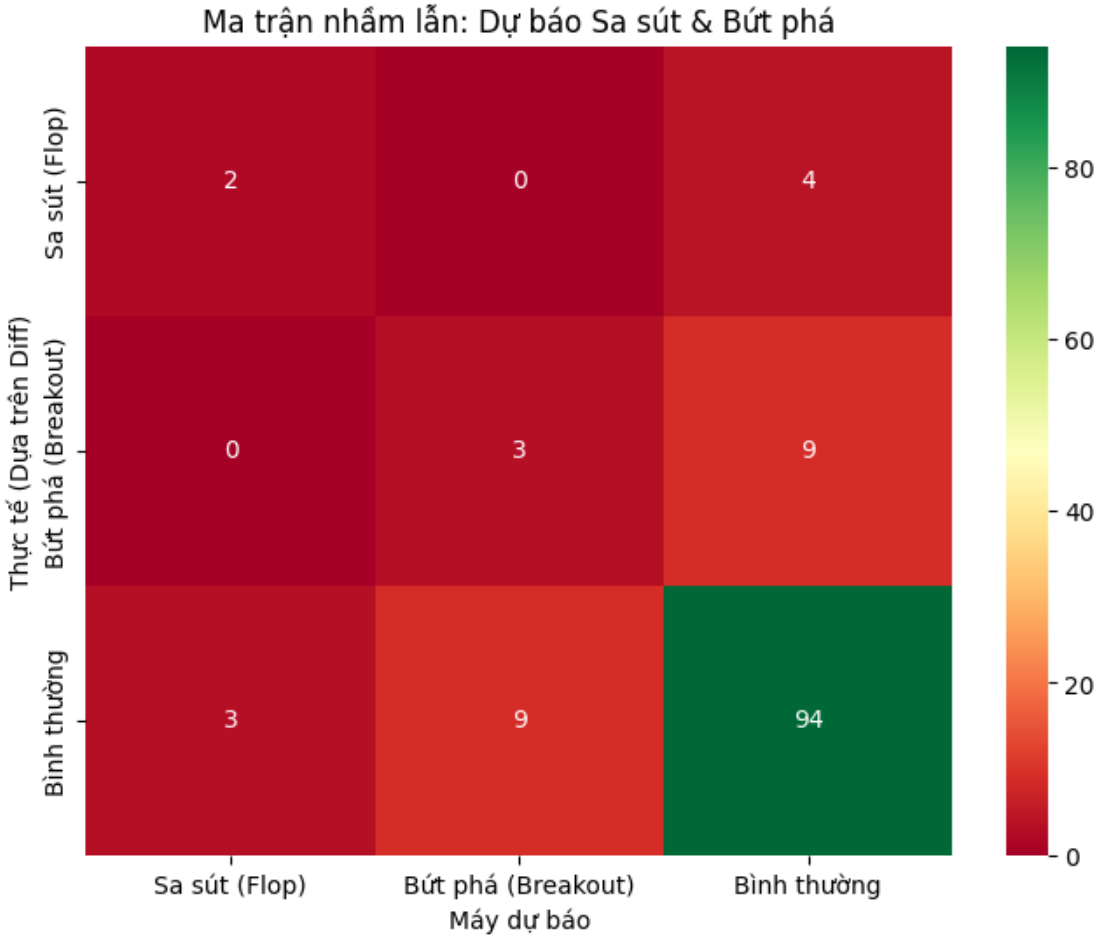
Hình 43: Biểu đồ Phân tán phân tích Ngoại lệ

Thông qua biểu đồ phân tán phân tích ngoại lệ được trình bày ở hình 42 có thể thấy dữ liệu về nhóm phim gây thất vọng cho thấy một mô hình rõ rệt: đây đều là các tác phẩm do những đạo diễn có uy tín cao chỉ đạo, nhưng điểm số thực tế lại rơi xuống mức rất thấp. Một phát hiện quan trọng trong nhóm này là trường hợp Psycho (1998), nơi dữ liệu đã ghép nhầm đạo diễn Alfred Hitchcock của bản gốc với bản làm lại năm 1998 của Gus Van Sant. Vì Hitchcock có power gần 4.0, kỳ vọng bị đẩy lên quá cao, trong khi bản remake bị chê dữ dội, dẫn đến sự lệch lớn và bị phân loại là "phim gây thất vọng". Các ví dụ khác như Hook (Steven Spielberg) hay G.I. Jane (Ridley Scott) cho thấy ngay cả những đạo diễn huyền thoại cũng có thể tạo ra các tác phẩm không đạt kỳ vọng khi thay đổi phong cách hoặc gặp vấn đề trong quá trình sản xuất.

Ở chiều ngược lại, nhóm phim gây bất ngờ tập trung vào các đạo diễn có mức độ uy tín thấp đến trung bình, nhưng tác phẩm của họ lại đạt điểm số cao vượt trội. Bên cạnh đó, nhóm các phim "bất ngờ thật sự" hiện lên rõ nét, đặc biệt trong dòng phim kinh dị như Halloween hay Scream. Đây là những tác phẩm mà các đạo diễn còn ít tên tuổi đã tạo ra dấu ấn mạnh bằng kịch bản độc đáo hoặc phong cách mới mẻ, cho thấy thể loại này có khả năng tạo ra những cú bứt phá ngay cả khi đội ngũ sản xuất chưa có danh tiếng lớn.

Từ hai nhóm đối lập này, có thể đưa ra vài kết luận quan trọng cho báo cáo. Đầu tiên, chỉ số Diff hoạt động chính xác trong việc phát hiện sự lệch giữa kỳ vọng và thực tế, phản ánh đúng tâm lý khán giả: thất vọng không đến từ phim dở mà đến từ phim dở so với danh tiếng đạo diễn. Cuối cùng, kết quả cho thấy chiến lược đầu tư vào các đạo diễn trẻ trong dòng phim kinh dị hoặc hành động có thể mang lại hiệu quả cao, bởi những thể loại này có tỷ lệ xuất hiện "breakout" vượt trội so với các nhóm phim khác.

Từ việc đối chiếu hai nhóm ngoại lệ đối lập, có thể đặt ra câu hỏi quan trọng cho nghiên cứu: *Liệu có thể dự đoán một bộ phim sẽ rơi vào nhóm "sa sút" hay "bứt phá" dựa trên các tiêu chí sẵn có hay không? Ta có thể thấy rõ thông qua Ma trận nhầm lẫn và kết quả dự báo được trình bày trong hình 43 và hình 44:*



Hình 44: Ma trận nhầm lẫn: Dự báo sa sút và bứt phá

```
========================================
KẾT QUẢ DỰ BÁO:
========================================
                    precision    recall  f1-score   support

     Sa sút (Flop)       0.40      0.33      0.36         6
Bứt phá (Breakout)       0.25      0.25      0.25        12
       Bình thường       0.88      0.89      0.88       106

          accuracy                           0.80       124
         macro avg       0.51      0.49      0.50       124
      weighted avg       0.79      0.80      0.80       124
```

Hình 45: Kết quả dự báo phân loại

Kết quả phân loại ba nhóm phim dựa trên hình 44 bao gồm Sa sút - Bứt phá - Bình thường cho thấy một bức tranh vừa tích cực vừa còn nhiều hạn

chế. Mặc dù độ chính xác tổng thể đạt khoảng 80% (99/124 mẫu đúng), nhưng thành tích này chủ yếu đến từ khả năng nhận diện rất tốt nhóm chiếm đa số là Bình thường (94/106 trường hợp). Khi đi sâu vào hai nhóm thiểu số có ý nghĩa chiến lược cao, hiệu năng mô hình giảm rõ rệt.

Đối với nhóm Sa sút (Flop), mô hình đóng vai trò cảnh báo ở mức chấp nhận được. Precision đạt 40%, nghĩa là trong 5 lần cảnh báo, có 2 trường hợp đúng, đủ để tạo tín hiệu rủi ro ban đầu cho nhà đầu tư. Tuy nhiên, Recall thấp cho thấy mô hình bỏ sót nhiều trường hợp sa sút: chỉ phát hiện được 2/6 phim, còn 4 phim bị nhầm sang nhóm Bình thường.

Với nhóm Bứt phá (Breakout), đây là bài toán khó nhất. Cả Precision và Recall đều chỉ đạt 25%, cho thấy mô hình vừa dự báo sai nhiều trường hợp bứt phá, vừa bỏ lỡ phần lớn các phim thực sự thành công bất ngờ. Sự nhầm lẫn mạnh hai chiều giữa Bứt phá và Bình thường (9 trường hợp mỗi phía) phản ánh ranh giới giữa hai nhóm này vẫn rất mờ nhạt với các đặc trưng hiện tại.

Nguyên nhân cốt lõi nằm ở mất cân bằng dữ liệu nghiêm trọng. Nhóm Bình thường áp đảo với 106 mẫu, trong khi Sa sút chỉ có 6 và Bứt phá có 12 mẫu. Sự chênh lệch này khiến mô hình thiên lệch về nhóm đa số và chưa đủ dữ kiện để học được các quy luật tinh vi nhằm phân biệt chính xác các nhóm thiểu số quan trọng.

Tóm lại, mô hình đã chứng minh được tính khả thi ở mức Proof-of-Concept: khả năng tách nhóm dựa trên logic Diff đã có hiệu lực, đặc biệt ở nhóm Sa sút. Tuy nhiên, hạn chế lớn đến từ sự khan hiếm dữ liệu ngoại lệ.

CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ

I. Tóm tắt các kết quả nghiên cứu chính

Nghiên cứu này đã hoàn thành mục tiêu ban đầu là xác định và đo lường các yếu tố ảnh hưởng đến mức độ hài lòng của khán giả đối với phim điện ảnh thông qua việc khai thác, tích hợp và phân tích dữ liệu từ hai nguồn lớn là MovieLens và TMDB. Bằng cách áp dụng các phương pháp thống kê mô tả, kiểm định tương quan, phân cụm K-Means và các mô hình học máy tiên tiến như Random Forest và XGBoost kết hợp giải thích SHAP, đề tài đã rút ra được những kết luận quan trọng về mối quan hệ giữa các yếu tố tài chính, nội dung, nhân sự và sự đánh giá của người xem.

Thứ nhất, nghiên cứu đã chỉ ra "nghịch lý tài chính" trong điện ảnh, nơi ngân sách sản xuất không tỷ lệ thuận với chất lượng cảm nhận. Kết quả phân tích hồi quy và phân cụm K-Means khẳng định sự tồn tại của quy luật hiệu suất giảm dần; cụ thể, việc tăng ngân sách vượt quá ngưỡng bão hòa không những không cải thiện điểm đánh giá mà còn có xu hướng tác động tiêu cực nhẹ đối với các dòng phim đại chúng. Doanh thu phòng vé, mặc dù phản ánh sự thành công về mặt thương mại và độ phủ sóng, cũng chỉ có mối tương quan yếu với điểm rating, chứng minh rằng sự phổ biến (popularity) không đồng nhất với chất lượng nghệ thuật trong mắt khán giả MovieLens.

Thứ hai, yếu tố nhân sự, đặc biệt là vai trò của đạo diễn, được xác định là biến số dự báo mạnh mẽ nhất cho sự hài lòng của khán giả. Phân tích mô hình XGBoost và giá trị SHAP đã lượng hóa được sự thống trị của "Director Power" so với "Actor Power". Đạo diễn đóng vai trò là người thiết lập trần và sàn chất lượng cho tác phẩm; một đạo diễn tài năng có khả năng nâng tầm một kịch bản hoặc dàn diễn viên trung bình, trong khi một ngôi sao điện ảnh dù xuất sắc đến đâu cũng khó có thể cứu vãn một dự án có sự chỉ đạo yếu kém. Sự cộng hưởng giữa đạo diễn và diễn viên là có thật, nhưng đạo diễn luôn là yếu tố nền tảng tiên quyết.

Thứ ba, về khía cạnh nội dung, thể loại và thời lượng phim có ảnh hưởng đáng kể đến xu hướng chấm điểm. Khán giả có xu hướng đánh giá cao các thể loại thiên về chiều sâu nội dung như Drama, War hay Documentary so với các thể loại giải trí thuần túy như Horror hay Action. Đồng thời, nghiên cứu cũng tìm thấy mối liên hệ tích cực giữa thời lượng phim và điểm đánh giá, gợi ý rằng những tác phẩm có thời lượng dài thường

được đầu tư kỹ lưỡng hơn về kịch bản và phát triển nhân vật, từ đó tạo ra trải nghiệm trọn vẹn hơn cho người xem.

II. Hàm ý quản trị

Từ các kết quả phân tích định lượng, nghiên cứu đề xuất một số hàm ý quản trị dành cho các nhà sản xuất phim và nhà đầu tư nhằm tối ưu hóa cả chất lượng nghệ thuật lẫn hiệu quả dự án.

Một là, cần thay đổi tư duy đầu tư từ "chạy đua vũ trang" về ngân sách sang đầu tư vào chiều sâu nhân sự chủ chốt. Thay vì dồn nguồn lực tài chính khổng lồ cho kỹ xảo hay quy mô sản xuất để mong đạt điểm cao, nhà sản xuất nên ưu tiên ngân sách để mời được những đạo diễn có tư duy nghệ thuật và phong cách phù hợp. Dữ liệu đã chứng minh "thương hiệu cá nhân" của đạo diễn chính là tem bảo chứng uy tín nhất cho chất lượng phim, giúp giảm thiểu rủi ro bị khán giả đánh giá thấp.

Hai là, chiến lược tuyển chọn diễn viên (Casting) cần được cân nhắc kỹ lưỡng trong mối tương quan với đạo diễn. Việc chi tiền tấn để mời ngôi sao hạng A tham gia vào một dự án có đạo diễn non tay là một khoản đầu tư rủi ro và kém hiệu quả. Thay vào đó, nguồn lực nên được tập trung vào việc xây dựng một kịch bản chắc chắn và một đội ngũ làm phim (crew) có năng lực thực sự, bởi diễn viên chỉ có thể tỏa sáng rực rỡ nhất trên bệ phóng của một đạo diễn giỏi.

Ba là, đối với các dự án phim thuộc thể loại giải trí (Action, Horror), nhà sản xuất cần chú trọng hơn đến kịch bản và chiều sâu nội dung để tránh rơi vào bẫy "doanh thu cao, chất lượng thấp". Việc một bộ phim có doanh thu tốt nhưng rating thấp có thể ảnh hưởng đến uy tín thương hiệu lâu dài. Ngược lại, việc phát triển các dòng phim có thời lượng phù hợp để kể trọn vẹn câu chuyện sẽ giúp tăng khả năng nhận được phản hồi tích cực từ khán giả.

III. Hạn chế của đề tài và Hướng phát triển

Mặc dù đã đạt được những kết quả khả quan, nghiên cứu vẫn tồn tại một số hạn chế nhất định. Về mặt dữ liệu, sự mất cân bằng giữa các nhóm thể loại và sự khan hiếm dữ liệu của các nhóm phim "ngoại lệ" (như phim bứt phá hoặc phim thảm họa) đã ảnh

hưởng đến độ chính xác của mô hình phân loại, khiến khả năng dự báo các trường hợp đặc biệt chưa đạt hiệu suất tối ưu. Bên cạnh đó, hiện tượng "thiên kiến kẻ sống sót" đối với các phim cũ cũng có thể tạo ra những nhận định chưa hoàn toàn khách quan về xu hướng chất lượng theo thời gian.

Về phạm vi phân tích, nghiên cứu mới chỉ tập trung vào các dữ liệu có cấu trúc (bảng biểu, con số) mà chưa khai thác sâu các dữ liệu phi cấu trúc như tóm tắt nội dung phim (plot summary), bình luận văn bản (reviews) hay phân tích hình ảnh poster. Đây là những yếu tố chứa đựng nhiều thông tin cảm xúc quan trọng ảnh hưởng đến quyết định của người xem.

Để khắc phục các hạn chế trên và mở rộng hướng nghiên cứu trong tương lai, các đề tài tiếp theo có thể tích hợp thêm kỹ thuật Xử lý Ngôn ngữ Tự nhiên (NLP) để phân tích cảm xúc từ nội dung review của khán giả, hoặc sử dụng Deep Learning để phân tích trailer và poster. Ngoài ra, việc mở rộng mô hình để giải quyết bài toán mất cân bằng dữ liệu sẽ giúp cải thiện đáng kể khả năng dự báo các hiện tượng điện ảnh bất ngờ, mang lại giá trị thực tiễn cao hơn cho ngành công nghiệp điện ảnh.

TÀI LIỆU THAM KHẢO

[1] Google Developers. (n.d.). *Clustering algorithms*. Google. https://developers.google.com/machine-learning/clustering/clustering-algorithms

[2] MovieLens. (n.d.). *MovieLens datasets*. GroupLens Research. ttps://movielens.org/

[3] Scikit-learn developers. (n.d.). *KMeans clustering*. In *scikit-learn documentation*. https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html

[4] The Movie Database. (n.d.). *TMDB: The Movie Database*. https://www.themoviedb.org/

[5] Đỗ Như Tài. (202). PTDL25 - 11 - cluster_analysis [Tài liệu bài giảng]. Phân tích Dữ liệu, Đại học Sài Gòn. https://drive.google.com/file/d/1vxK5n7XJ49jhp-6HqJuzGPoq4DX5U4hA/view

[6] Đỗ Như Tài. (202). PTDL25 - 10a - Cay quyet dinh [Tài liệu bài giảng]. Phân tích Dữ liệu, Đại học Sài Gòn. https://drive.google.com/file/d/13od7qwy6Dl0aCdJSDuF2E593ifm2QZX6/view

[7] Đỗ Như Tài. (202). PTDL25 - 09a - Linear_Regression [Tài liệu bài giảng]. Phân tích Dữ liệu, Đại học Sài Gòn. https://drive.google.com/file/d/1-FqP_cNOoaGjUlgGWQxjlCMHKw-Bgah1/view

[8] Đỗ Như Tài. (202). Lab03 - Thuat toan phan cum [Tài liệu bài giảng]. Phân tích Dữ liệu, Đại học Sài Gòn. https://drive.google.com/file/d/1QQgY-ECN7zgi1yv3J2s2Jhp7JDJyMxNQ/view

[9] Salloum, S., & Rajamanthri, D. (2021). *Implementation and evaluation of movie recommender systems using collaborative filtering*. Journal of Advances in Information Technology, 12(3), 155-161.